Level 2. Data Science

역량강화 실전과정



검정 개요

- ▶ 출제문항: 필기 20문항(40점) / 실기 6문제(2set x 3문항, 60점)
- ▶ 합격기준: 총점 70점 이상(과락기준 - 필기 24점 / 실기 36점)
- ▶ 응시시간: 3시간
- ▶ 객관식에 계산 문제가 있으며 풀이를 위해 SW 계산기 또는 Python 사용 가능
- ▶ 실기 문제 풀이는 Jupyter Notebook 환경으로 진행됨(이외 환경은 담당자 별도 문의)
- ▶ 실기 문제 답안 제출 시 답안 도출을 위해 작성한 Jupyter Notebook 파일도 함께 제출
- ▶ 실기 시험은 부분점수가 없음

필기 문제 유형 - 진위형

Q. k-Means는 모든 클러스터의 중심점이 더 이상 변화하지 않을 때까지 반복 수행하도록 동작하기도 한다.

① O ✓
② X

필기 문제 유형 - 선다형

Q. 다중공선성(multicollinearity)에 대한 설명으로 가장 적절한 것은 무엇인가?

① 독립변수들 간에 강한 상관관계가 존재하여 회귀계수의 추정이 불안정해지는 현상 ✓
② 회귀모형에서 종속변수와 독립변수 간의 관계가 비선형일 때 발생하는 문제
③ 잔차들이 정규분포를 따르지 않을 때 발생하는 문제
④ 회귀분석에서 독립변수가 종속변수에 미치는 영향을 측정할 수 없는 경우를 의미

실기 시험 문항 상세

- ▶ 전처리 단계와 3개 문항이 1세트이며 총 2세트가 출제됨
- ▶ 전처리 단계는 점수에 포함이 되지 않지만 여기서 실수가 일어날 경우 뒷 문제에서 오답 도출 가능성 有
- ▶ 전처리 단계는 단일 또는 복수 문항과 연관되어 있을 수 있음
- ▶ 문제 1/2/3 은 서로 별개의 문항이나 간혹 연계 되어있기도 함
- ▶ 문제간 연계가 되어있는 경우 문제에서 해당 사항을 별도로 안내(ex. 문제 2에서 만든 "df2"를 사용하여)
- ▶ 한 세트에 속해 있는 3개 문항은 8점/10점/12점 이 기본이며 순서 또는 배점은 변경될 수 있음



실기 시험 답안의 산출과 제출

▶ 실기문항의 정답의 경우 해당 값 만 주피터 노트북에서 출력할 필요는 없음
▶ 문제에서 요구하는 답안을 주피터 노트북에서 산출하고 해당 값을 별도의 값 입력 창에 직접 옮겨 적게 됨

문제에서 “Score” 변수와 “Age Group” 변수의 상관계수를 반올림하여 소수점 두 자리수 까지 표기하도록 요구한 경우 다음의 두 경우 모두 가능하며 반올림은 암산하여 답 제출 칸에 직접 입력하여도 됨

```
1 df_corr
```

	Age Group	Score	Credit
Age Group	1.000000	0.679185	0.996241
Score	0.679185	1.000000	0.676632
Credit	0.996241	0.676632	1.000000

```
1 round(df_corr.loc["Age Group", "Score"], 2)
```

```
0.68
```

필기 대비 – 이론 리뷰 및 문제풀이



01

통계 분석



1) 확률 및 확률분포

확률(Probability)

▶ 하나의 사상(事象) 혹은 사건이 일어날 수 있는 가능성의 정도. 또는, 그 수치
▶ 0에서 1 사이의 값을 가지며 모든 사건에 대한 확률의 합은 1

$$\text{특정 사건이 발생 할 확률} = \frac{\text{특정 사건의 경우의 수}}{\text{전체 경우의 수}}$$

$$P(A) = \frac{\text{사상 } A\text{와 관련된 사상 수}}{\text{표본공간에 속하는 전체 사상 수}}$$

1) 확률 및 확률분포

확률의 연산

▶ 덧셈 법칙: 각 사건이 상호 배반일 때 각 사건이 일어날 확률은 각 사건의 확률 합
▶ 곱셈 법칙: 각 사건이 동시에 일어날 확률은 각 사건의 확률 곱

- 덧셈 법칙(일반)

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- 덧셈 법칙(특별): 배반사건(disjoint event)

$$P(A \cup B) = P(A) + P(B)$$

- 곱셈 법칙(일반)

$$P(A \cap B) = P(B) \times P(A|B)$$

- 곱셈 법칙(특별): 독립 사상

$$P(A \cap B) = P(A) \times P(B)$$

1) 확률 및 확률분포

확률의 연산 예제

▶ 확률이 20%인 사건이 있다고 하자. 다섯번 시도했을 때 적어도 한 번은 사건이 발생할 확률은?
▶ 적어도 1번 = P(1번) + P(2번) + P(3번) + P(4번) + P(5번) = 1 – P(0번)

$$1 - (1 - P)^5 = 1 - \left(1 - \frac{1}{5}\right)^5 = 1 - 0.32768 = 0.67232 = 67.232\%$$

경제 : 경제정책

성공률 20% 뚫을까…대왕고래 프로젝트 시추 본격화 입력 2024.12.20 00:02

1) 확률 및 확률분포

조건부 확률(conditional probability)

▶ 주어진 사건이 일어났다는 가정 하에 다른 한 사건이 일어날 확률
▶ "오늘 치킨을 시켜먹을 확률" vs. "어제 치킨을 먹었지만 오늘 또 치킨을 먹을 확률"

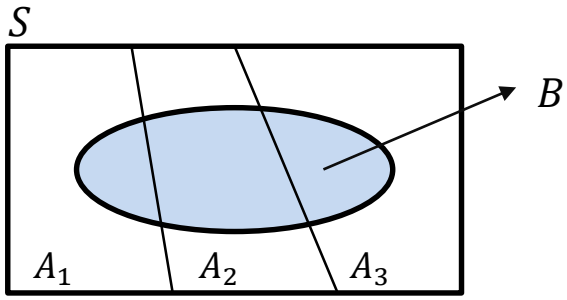
$$\mathrm{P}(A|B) = \frac{P(A \cap B)}{\mathrm{P}(B)}$$



1) 확률 및 확률분포

전확률의 법칙(Law of Total Probability)

▶ 특정 사건의 확률은 조건부확률의 합으로 표현 가능



$$
\begin{aligned}
P(B) &= P(A_1 \cap B) + P(A_2 \cap B) + P(A_3 \cap B) \\
&= P(A_1)P(B|A_1) + P(A_2)P(B|A_2) + P(A_3)P(B|A_3) \\
&= \sum_{i=1}^{3} P(A_i)P(B|A_i)
\end{aligned}
$$

1) 확률 및 확률분포

베이즈 정리(Bayes' theorem)

- 두 확률 변수의 사전확률과 사후확률 사이의 관계를 나타내는 정리
- 새로운 정보가 기존의 추론에 어떠한 영향을 미치는지 확인 가능
- P(H): 사전 확률(prior, probability of Hypothesis)로, 아직 사건에 관한 어떠한 정보도 알지 못하는 것을 의미
- P(H|E): 사후 확률(posterior). 사건에 대한 정보 기반으로 계산된(갱신된) 확률
- P(E|H): 가능도(likelihood). 사건이 발생했을 때 증거의 확률
- P(E): 증거(Evidence)

$$\mathrm{P}(H|E) = \frac{P(H \cap E)}{\mathrm{P}(E)} = \frac{P(H)\,P(E|H)}{\mathrm{P}(E)}$$

$$\underbrace{\mathrm{P}(A_i|B)}_{\text{사후 확률}} = \frac{P(A_i)\,P(B|A_i)}{\mathrm{P}(B)} = \frac{P(A_i)P(B|A_i)}{P(A_1)P(B|A_1) + P(A_2)P(B|A_2) + \cdots + P(A_i)P(B|A_i)}$$

사전정보 조건부 확률

1) 확률 및 확률분포

확률 변수(Random Variable)

- 확률적인 과정(무작위 실험)의 결과를 수치적으로 표현하는 변수(일반적으로 X로 표기)
- 상태공간(state space): 확률변수 X가 취하는 모든 실수 집합
- 이산확률변수(discrete random variable): 유한개의 값으로 구성되어 있는 변수
- 연속확률변수(continuous random variable): 주어진 실수 범위 내에서 연속적인 범위의 값을 지니는 변수

확률 함수

- 확률 변수에 의하여 정의된 실수를 0과 1 사이의 실수(확률)에 대응시키는 함수
- 확률 변수의 종류에 따라 확률 질량 함수와 확률 밀도 함수로 나뉘어짐



1) 확률 및 확률분포

확률 질량 함수(PMF, Probability Mass Function)

- 이산 확률 변수에서 특정 값에 대한 확률을 나타내는 함수
- 확률 변수 X : S → ℝ 가 표본 공간(S)에 의해 정의되는 이산 확률 변수일 때 확률 질량 함수는 아래와 같다.

$$f_X(x)\colon \mathbb{R} \rightarrow [0,1]$$

$$f_X(x) = \Pr(X = x) = \Pr(\{s \in S : X(x) = x\})$$

$$\sum_{x=0}^{n} f(x) = 1$$

확률 밀도 함수(PDF, Probability Density Function)

- 연속 확률 변수의 분포를 나타내는 함수
- ① 확률 밀도 함수 $f(x)$와 구간 $[a,b]$에 대해서 확률 변수 X가 구간에 포함될 확률 $P(a \le X \le b)$는 아래와 같다.
- ② 확률 밀도 함수 $f(x)$는 다음의 조건을 만족해야 한다.

① $P(a \le X \le b) = \int_a^b f(x)\,dx$

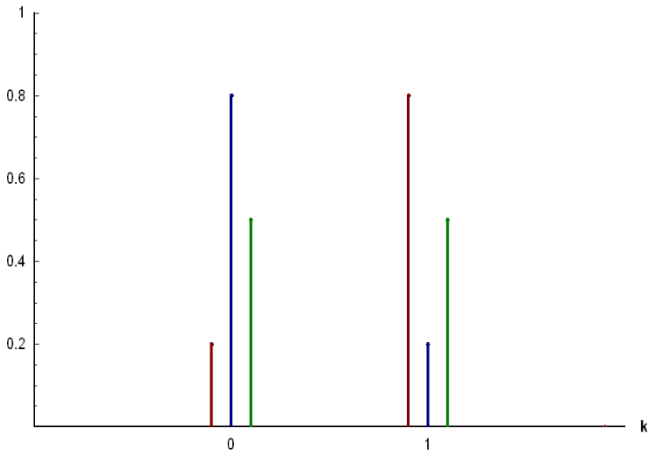
② $\int_{-\infty}^{\infty} f(x)\,dx = 1$, $f(x) \ge 0 \quad (x \in \forall \mathbb{R})$

1) 확률 및 확률분포

이산 확률 분포 – 베르누이 분포(Bernoulli Distribution)

▶ 베르누이 시행(Bernoulli trial): 결과가 두 가지 중 하나로만 나오는 시행(trial)
※ 동전 던지기(앞/뒤)
▶ 베르누이 확률변수(Bernoulli random variable): 베르누이 시행 결과를 0과 1로 변환한 것

확률 질량 함수의 그래프



https://en.wikipedia.org/wiki/Bernoulli_distribution

관련 공식

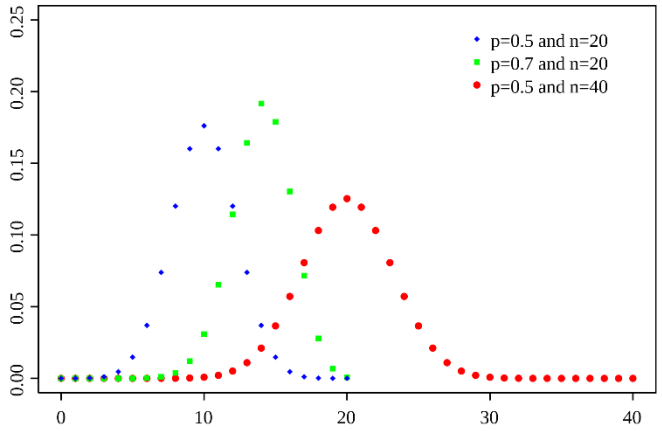
확률: p
평균: p
분산: $p(1-p)$

1) 확률 및 확률분포

이산 확률 분포 – 이항 분포(Binomial Distribution)

- 연속된 n번의 독립적 베르누이 시행에서 각 시행이 확률 p를 가질 때의 이산 확률 분포
- n번 시행 중에 k번 성공할 확률은 확률 질량 함수로 표현
- n이 1인 경우 베르누이 분포

확률 질량 함수의 그래프



https://en.wikipedia.org/wiki/Binomial_distribution

관련 공식

확률: $\mathrm{P}(x) = \binom{n}{x} p^x (1-p)^{n-x}$

평균: $E(X) = np$

분산: $Var(X) = np(1-p)$

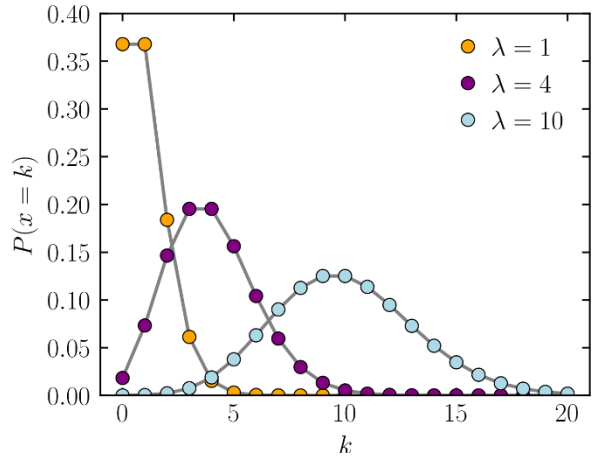
$$※ \binom{n}{x} = \frac{n!}{x!(n-x)!}$$

1) 확률 및 확률분포

이산 확률 분포 – 포아송 분포(Poisson Distribution)

- 단위 시간이나 공간에서 발생하는 사건의 수를 나타낸 이산 확률 분포 한정된 무언가.. 시행횟수는 x
- 모수 λ(lambda)는 일정한 단위 시간 또는 단위 공간에서 임의로 발생하는 사건의 평균 횟수
- 이항 분포를 따르는 확률변수 X가 n이 매우 크고 p가 매우 작은 경우 $\lambda = np$ 인 포아송 분포로 근사 가능

확률 질량 함수의 그래프



https://en.wikipedia.org/wiki/Poisson_distribution

관련 공식

확률: $f_X(x) = \frac{e^{-\lambda}\lambda^x}{x!}$

평균: λ

분산: λ

1) 확률 및 확률분포

이산 확률 분포 – 포아송 분포(Poisson Distribution)의 포아송 확률과정

- 두 개 이상의 사건이 동시에 발생할 확률은 0에 근사
- 어떤 단위구간의 사건의 발생은 다른 단위구간의 발생으로부터 독립
- 특정 구간에서의 사건 발생확률은 그 구간의 크기에 비례

이산 확률 분포 – 포아송 분포(Poisson Distribution)의 응용

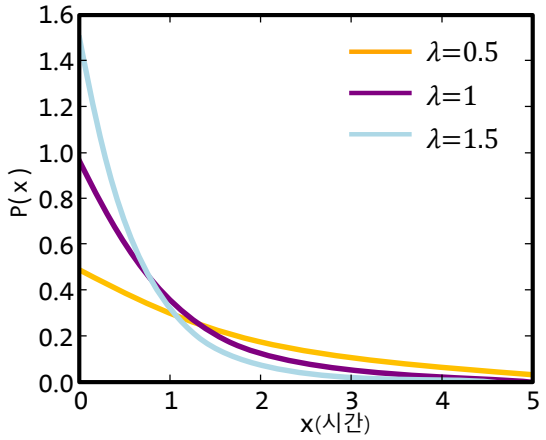
- 일정 주어진 시간 동안에 도착한 고객의 수
- 1킬로미터 도로에 있는 흠집의 수
- 일정 주어진 생산시간 동안 발생하는 불량 수
- 하룻동안 발생하는 출생자 수
- 어떤 시간 동안 톨게이트를 통과하는 차량의 수
- 어떤 페이지 하나를 완성하는 데 발생하는 오타의 발생률
- 어떤 특정 량의 방사선을 DNA에 쬐 였을 때 발생하는 돌연변이의 수
- 어떤 특정 면적의 다양한 종류의 나무가 섞여 자라는 삼림에서 소나무의 수
- 어떤 특정 진도 이상의 지진이 발생하는 수

1) 확률 및 확률분포

연속 확률 분포 – 지수 분포(Exponential Distribution)

- 첫 번째 사건이 일어날 때까지 걸리는 시간에 대한 연속 확률분포
- 감마 분포의 특수한 분포로 $\alpha = 1, \beta = 1/\lambda$ 인 감마 분포
- 무기억성: 어떤 시점 부터 소요되는 시간은 과거 시간에 영향을 받지 않음

확률 밀도 함수의 그래프



관련 공식

확률: $\lambda e^{-\lambda x}$

평균: $1/\lambda$

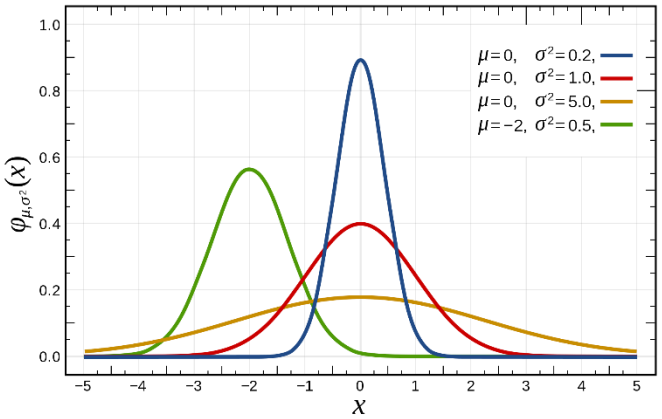
분산: $1/\lambda^2$

1) 확률 및 확률분포

연속 확률 분포 – 정규 분포(Normal Distribution)

- 연속 확률 분포 중 하나이며 가우시안 분포(Gaussian Distribution) 라고도 불린다.
- 평균이 0이고 표준편차가 1인 정규분포를 **표준정규분포**라고 한다.
- 좌우 대칭이며 (초과)첨도(kurtosis)가 0이고 왜도(skewness)가 0이다.

확률 밀도 함수의 그래프



https://en.wikipedia.org/wiki/Normal_distribution

관련 공식

확률: $\frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$

평균: μ

분산: σ^2

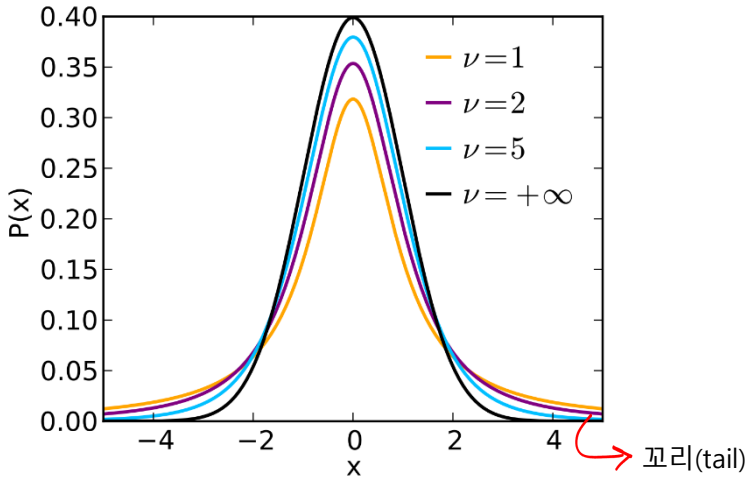
1) 확률 및 확률분포

연속 확률 분포 – t 분포(t Distribution)

- 정규모집단에서 크기가 n인 표본을 무작위로 추출하는 경우 표본통계량 t는 자유도(n-1)인 t분포를 따름
- 모수의 자유도에 따라 분포의 모양이 변하며, 자유도(v)가 커질수록 정규분포에 근사
- 자유도가 낮을 경우 분포의 끝(꼬리, tail)이 두꺼워 지고(heavy tailed), 클 경우 얇아짐(light tailed)
- 모표준편차를 모를 때 모집단이 정규분포 이거나 표본 크기가 작을 때(n<30) 모평균의 추정과 검정에 사용

※ 자유도(degree of freedom): 데이터 내에서 독립적으로 변할 수 있는 값의 수(너무 낮으면 추정의 신뢰성이 떨어짐)

확률 밀도 함수의 그래프



https://en.wikipedia.org/wiki/Student%27s_t-distribution

관련 공식

$$\text{확률: } \frac{\Gamma\left(\frac{v+1}{2}\right)}{\sqrt{v\pi}\,\Gamma\left(\frac{v}{2}\right)}\left(1+\frac{x^2}{v}\right)^{-\left(\frac{v+1}{2}\right)}$$

$$\text{평균: } 0 \ (v>0)$$

좌우대칭

$$\text{분산: } \frac{v}{v-2} \ (v>2)$$

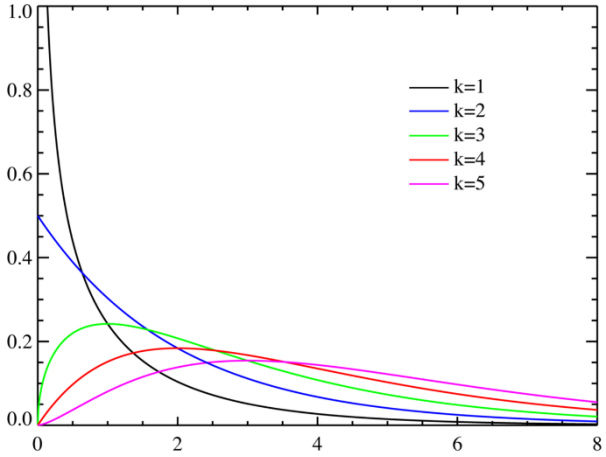
$$※\ \Gamma(z) = \int_0^\infty t^{z-1}e^{-t}\,dt$$

1) 확률 및 확률분포

연속 확률 분포 – 카이제곱 분포(Chi-squared Distribution)

- k개의 **서로 독립적인 표준정규 확률변수**를 각각 제곱한 다음 합해서 얻어지는 분포
- 자유도(k)가 커질수록 정규분포에 가까워 짐
- 감마 분포의 특수한 형태로 감마 분포에서 $k = v/2, \theta = 2$ 인 분포

확률 밀도 함수의 그래프



https://ko.wikipedia.org/wiki/카이제곱_분포

관련 공식

확률: $\frac{1}{2^{k/2}\,\Gamma\left(\frac{k}{2}\right)} x^{\frac{k}{2}-1} e^{-\frac{x}{2}}$

평균: k

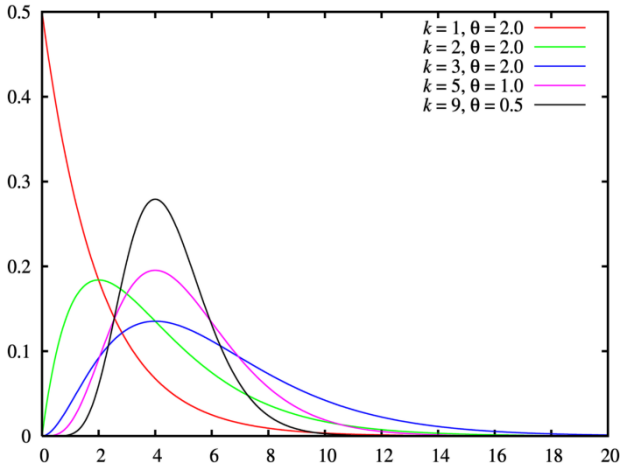
분산: $2k$

1) 확률 및 확률분포

연속 확률 분포 – 감마 분포(Gamma Distribution)

- k번째 사건이 일어날 때까지 걸리는 시간에 대한 연속 확률분포
- $k(>0)$는 모양 매개변수(shape parameter, 형상모수), $\theta(>0)$는 크기 매개변수(scale parameter, 척도모수)
- $k=1, \theta=1/\lambda$ 는 지수분포, $k=\nu/2\ \theta=2$ 는 카이제곱 분포 (ν: 자유도)

확률 밀도 함수의 그래프



https://ko.wikipedia.org/wiki/감마_분포

관련 공식

확률: $x^{k-1}\frac{\exp(-x/\theta)}{\Gamma(k)\theta^k}$

평균: $1/\lambda$

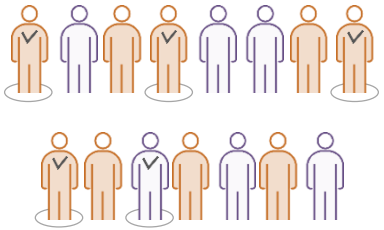
분산: $1/\lambda^2$

2) 표본 추출

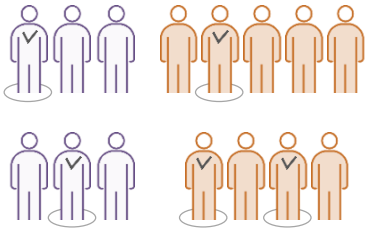
확률적 표본 추출(Probability sampling method)

- 각 요소가 표본으로 추출될 확률이 알려져 있고 임의적으로 추출되는 방법
- 단순 임의 추출(Simple Random Sampling): 별도의 규칙이 존재하지 않은 보통의 임의 추출
- 층화 표본 추출(Stratified Random Sampling): 계층별로 지정한 비율(또는 개수) 만큼의 데이터를 임의 추출
  ※ 특정 계층의 누락 방지
- 계통 추출(Systematic Sampling): 첫 표본을 무작위로 추출하고 표집 간격 k 만큼 떨어진 곳의 데이터 추출
  ※ 데이터의 주기성에 주의. 데이터에 주기성이 있을 경우 표본이 편향될(biased) 수 있음
- 군집 추출(Cluster Sampling): 소수의 군집으로 분할하고 일정 수의 소집단을 임의 표본 추출

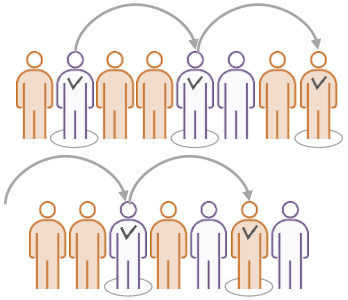
단순 임의 추출



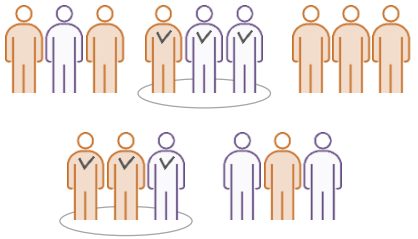
층화 표본 추출



계통 추출



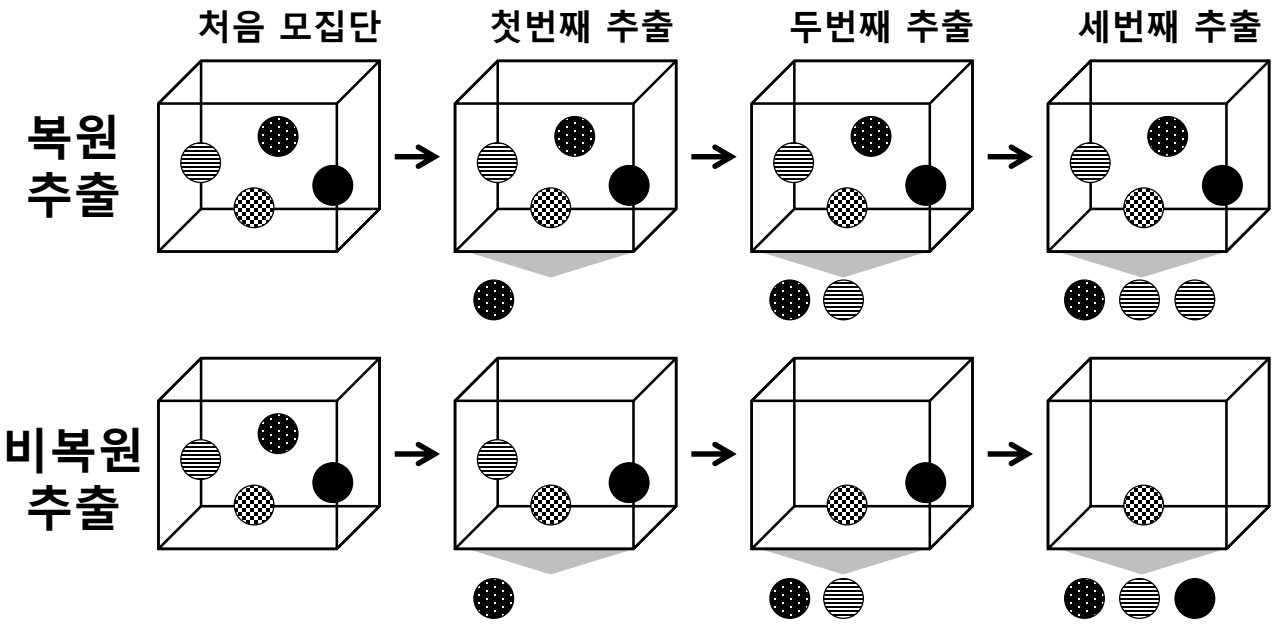
군집 추출



2) 표본 추출

복원 추출과 비복원 추출

- 복원 추출: 한번 표본으로 뽑힌 요소를 다시 모집단으로 되돌려 보내 놓고(복원) 다시 추출하는 방식
- 비복원 추출: 추출 시행 시 한번 표본으로 뽑힌 요소를 다시 모집단으로 되돌려 놓지 않는 방식



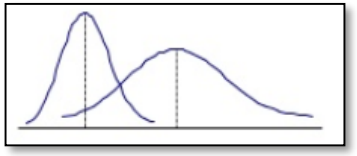
3) 기술 통계

기술 통계량

▶ 데이터의 특징을 요약한 수

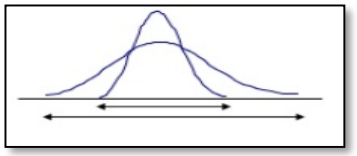
위치 통계량(Measures of Location)

▶ 대표값, 자료의 중심점
▶ 평균, 중앙값 등



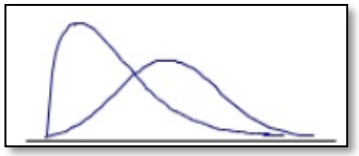
변이 통계량(Measures of Dispersion)

▶ 자료의 퍼짐/흩어짐 정도
▶ 분산, 표준편차 등



모양 통계량(Measures of Shape)

▶ 왜도(Skewness): 중심위치로부터 어느 한쪽으로 치우친 정도
▶ 첨도(Kurtosis): 분포의 뾰족한 정도(정규분포 기준)



3) 기술 통계

위치 통계량 – 평균

- **산술 평균**: 데이터의 합계를 데이터의 총 개수로 나눈 값
- **가중 평균**: 산술평균에서 각 원소의 가중치가 다름(주로 가중치의 합을 1로 설정하고 가중치는 음수도 가능)
- **기하 평균**: 곱의 평균이며 변화량(성장률)의 평균을 계산하는데 주로 사용
- **조화 평균**: 역수의 산술평균의 역수
- 산술평균의 경우 이상치 같은 상대적으로 매우 크거나 작은 숫자가 포함될 경우 값이 크게 달라짐(상대적으로 민감)

산술 평균

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

가중 평균

$$\overline{x_w} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_n x_n}{w_1 + w_2 + \cdots + w_n}$$

기하 평균

✨계산문제 기출✨

$$\overline{x_g} = \sqrt[n]{x_1 \cdot x_2 \cdot x_3 \cdots x_n}$$

조화 평균

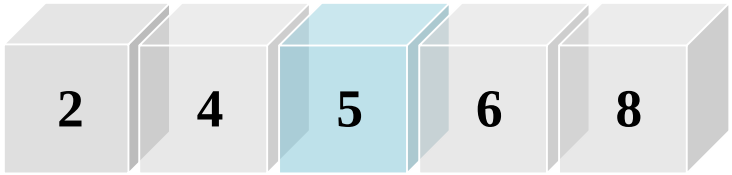
$$\overline{x_h} = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \cdots + \frac{1}{x_n}}$$

3) 기술 통계

위치 통계량 - 중앙값

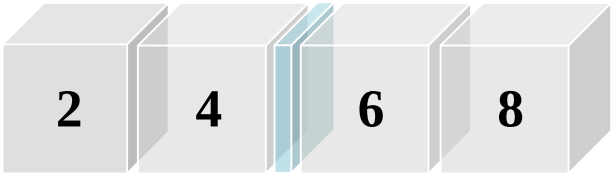
- 중앙값: 주어진 숫자 중 가장 가운데 위치한 값
- 산술평균과 다르게 매우 크거나 작은 이상치에 영향을 덜 받음
- 짝수개의 숫자의 중앙값은 중앙에 가까운 두 값의 평균으로 계산

숫자 개수가 홀수인 경우



※ **중앙에 위치한 수(5)**

숫자 개수가 짝수인 경우

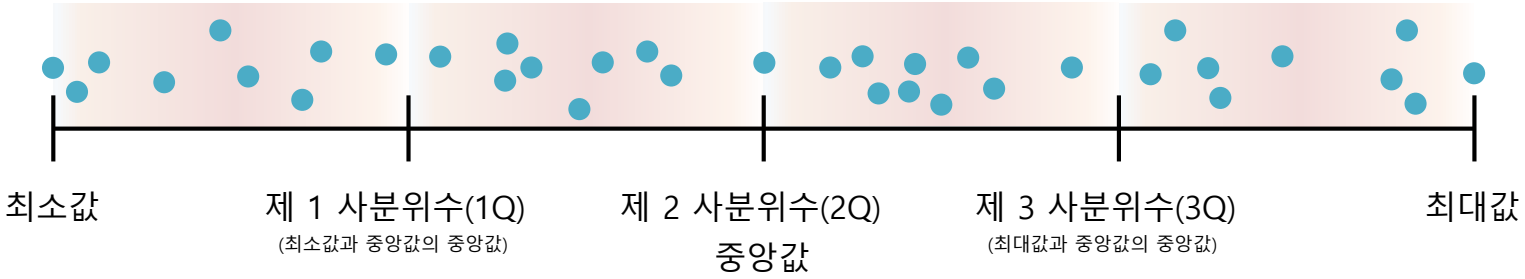


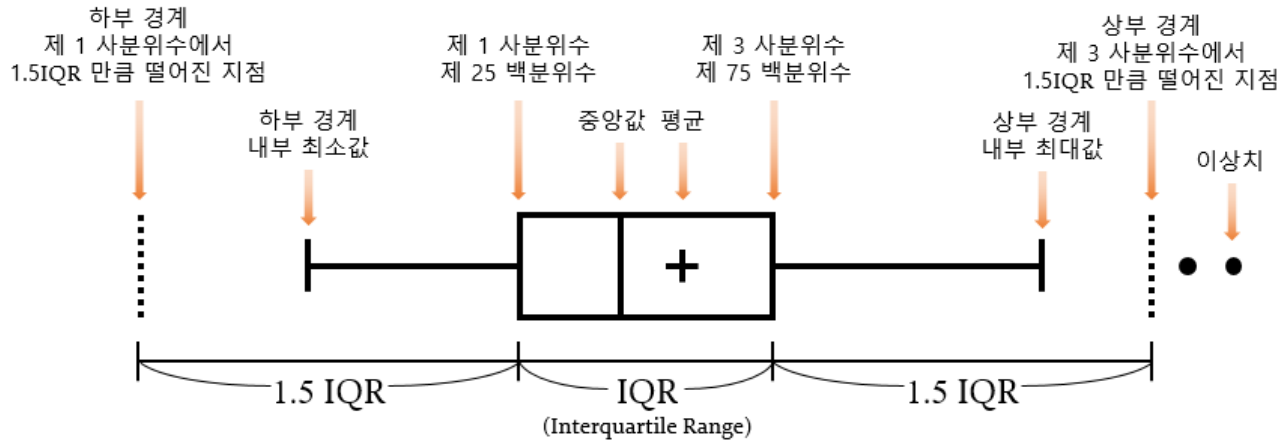
※ **중앙에 가까운 두 개의 값의 평균(5)**

3) 기술 통계

위치 통계량 – 분위수

▶ 사분위수: 데이터 표본을 4개의 동일한 부분으로 나눈 값
▶ 제 1 사분위수의 경우 제 25 백분위수와 같음
▶ 사분위 범위(IQR, Inter Quartile Range, 변이 통계량): 제 3 사분위수(3Q, 75%)와 제 1 사분위수(1Q, 25%)의 범위
※ IQR = 3Q – 1Q

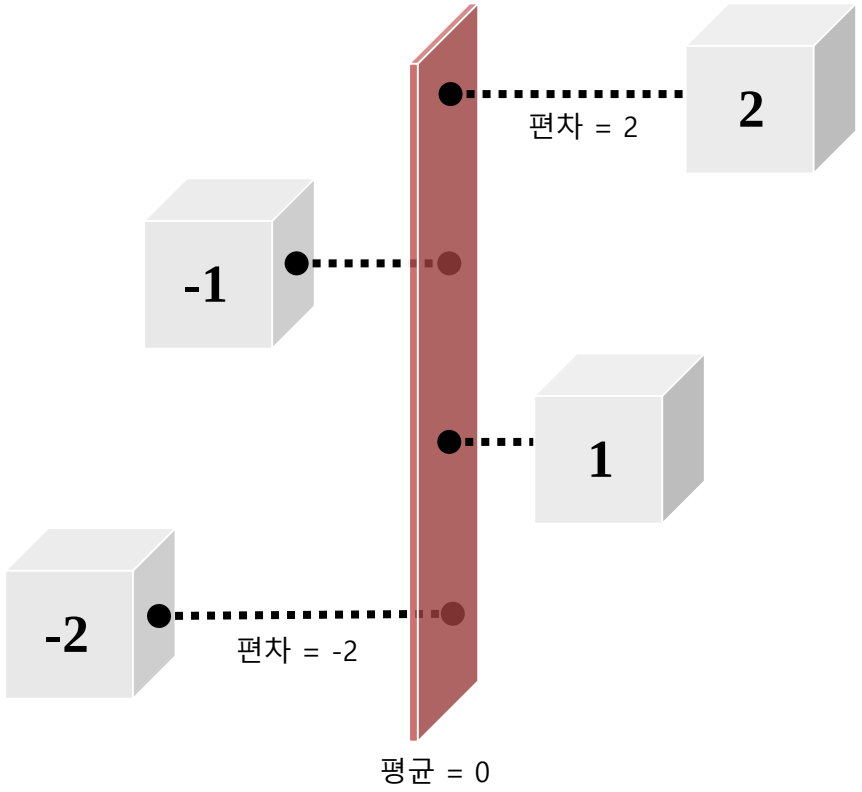




3) 기술 통계

변이 통계량 – 분산/표준편차

▶ 분산: 자료의 퍼짐 정도를 확인하는 통계량
▶ 표준편차: 분산의 제곱근



- 편차: $(x - \bar{x})$

마이너스에 의해 상쇄되는거 막으려고

- 편차 제곱: $(x - \bar{x})^2$
- 편차 제곱합: $\sum(x - \bar{x})^2$
- 분산: $\frac{\sum(x-\bar{x})^2}{n}$

※ 편차 제곱의 평균

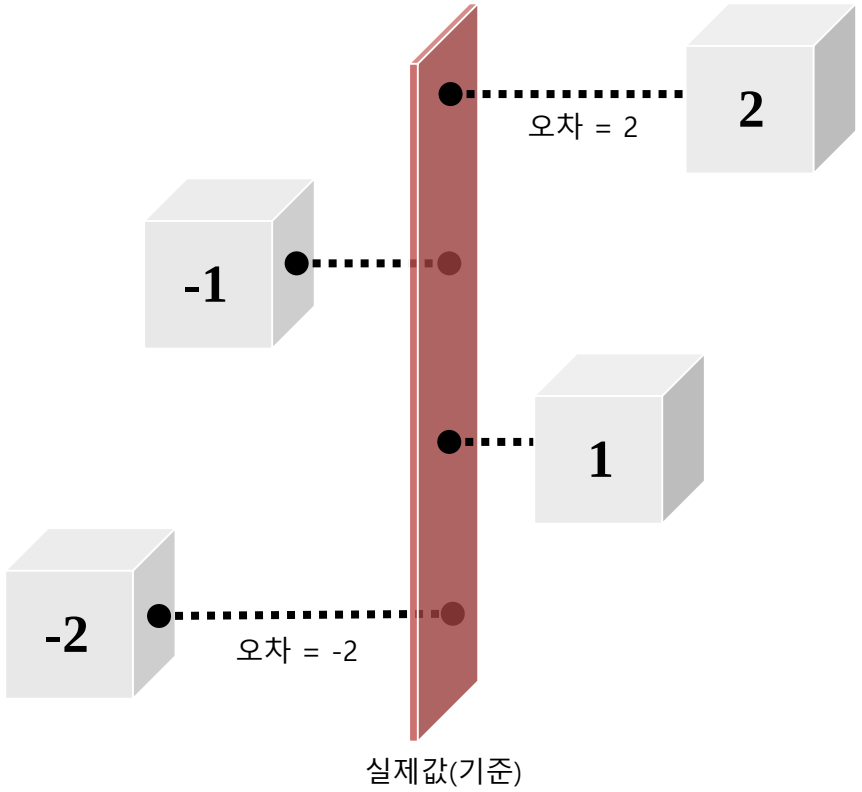
값이 너무 커져서 루트 씌움

- 표준 편차: $\sqrt{\frac{\sum(x-\bar{x})^2}{n}}$

3) 기술 통계

변이 통계량 – MSE/RMSE

▶ MSE(Mean Squared Error): 오차 평가지표의 하나로 분산의 수식과 구조가 같음
▶ RMSE(Root Mean Squared Error): 오차 평가지표의 하나로 표준편차의 수식과 구조가 같음



- 오차(E): $(y - \hat{y})$
- 오차 제곱(SE): $(y - \hat{y})^2$
- 오차 제곱합(SSE): $\sum(y - \hat{y})^2$
- MSE: $\frac{\sum(y-\hat{y})^2}{n}$
  ※ 오차 제곱의 평균
- RMSE: $\sqrt{\frac{\sum(y-\hat{y})^2}{n}}$

여기도 비슷

3) 기술 통계

변이 통계량 - 변동계수

▶ 변동계수(CV, coefficient of variation): 표준편차의 평균에 대한 비율
▶ 평균이 0인 경우 계산이 불가하며 필요시 다른 지표를 고려하거나 데이터 변환 실시
▶ 무명수(단위가 없는 수)로 서로 다른 단위를 가지는 변량 비교시 활용 가능
※ 예) KOSPI(한국종합주가지수)의 변동과 개별 주가의 변동 비교
▶ 숫자가 큰 표본집단과 숫자가 상대적으로 작은 표본집단의 경우 단순 표준편차 산출 시 그 비교가 어려울 수 있음

$$CV = \frac{\sigma}{\mu} \times 100$$

μ: 모평균(모집단의 평균)
σ: 모표준편차(모집단의 표준편차)

표준편차를 평균으로 나누면 단위가 사라지고 숫자만 남음 (?)

(표준편차가 크면 평균도 크고 작으면 평균도 작아서)
기존의 데이터의 크고 작음에 상관없이 정규화의 효과가 있음

3) 기술 통계

모양 통계량

▶ 첨도(kurtosis): 분포의 뾰족한 정도를 나타내는 척도로 정규분포 기준 0이며 정규분포보다 뾰족하면 양수

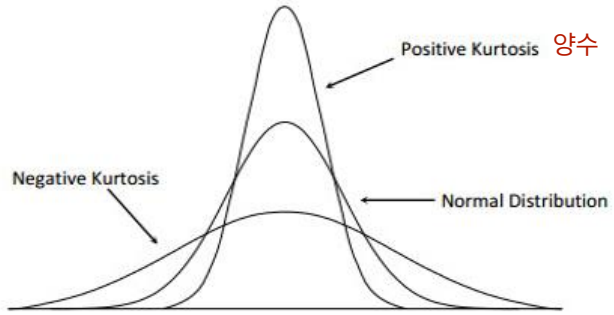
※ 첨도는 주로 초과 첨도(excess kurtosis)를 뜻함

▶ 왜도(skewness): 분포의 치우침 정도를 나타내는 척도로 좌우 대칭인 경우 0이며 오른쪽 꼬리 분포면 양수

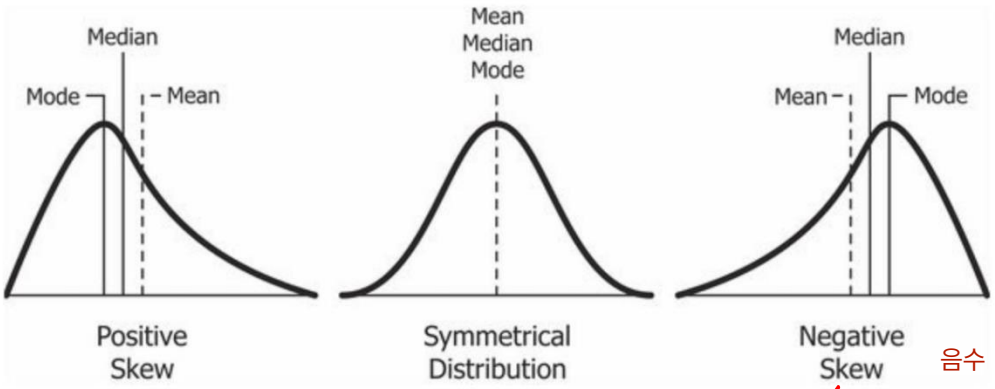
▶ 왜도가 0인 경우 좌우 대칭으로 평균과 중앙값이 같으나 다봉 분포의 경우 최빈값은 다를 수 있음

※ 대칭인 쌍봉분포는 중앙값(median)과 평균값(mean)은 같으나 최빈값(mode)이 다를 수 있음

첨도



왜도



왼쪽으로 치우친

https://zetawiki.com/wiki/비대칭도

3) 기술 통계

확률변수의 선형변환

▶ 확률변수 X와 두 상수 a, b에 대하여 다음이 성립한다. (단, $a \neq 0$)

- 평균: $E(aX+b) = aE(X)+b$
- 분산: $V(aX+b) = a^2V(X)$
- 표준편차: $a(aX+b) = |a|\sigma(X)$

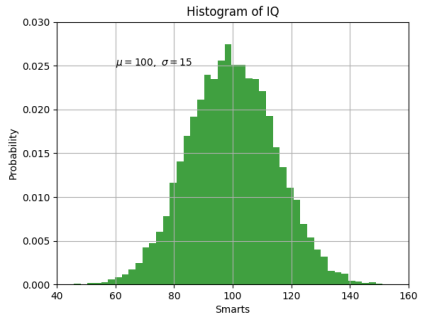
$$
\begin{aligned}
V(Y) &= E\left[\left(Y - E(Y)\right)^2\right] = V(aX+b) \\
&= E\left[\left(aX+b - (aE(x)+b)\right)^2\right] \\
&= E\left[\left(aX - aE(x)\right)^2\right] \\
&= E\left[a^2\left(X - E(x)\right)^2\right] \\
&= a^2E\left[\left(X - E(x)\right)^2\right] \\
&= a^2V(X)
\end{aligned}
$$

3) 기술 통계

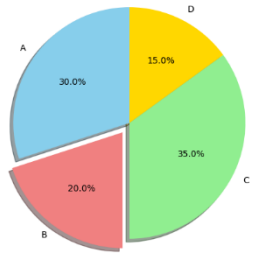
일변량 차트

▶ 히스토그램(histogram): 표로 되어 있는 도수 분포를 정보 그림으로 나타낸 것
▶ 원 그래프(pie chart): 전체에 대한 각 부분의 비율을 부채꼴 모양으로 백분율로 나타낸 그래프
▶ 막대 그래프(bar graph): 직사각형 막대의 높이 또는 너비를 값에 비례하여 표현하는 그래프
▶ 상자 그림(box plot): 5가지 요약수치를 기반으로 데이터의 분포를 표현하는 그래프
※ 5가지 요약수치: 최소값, 제 1 사분위수, 제 2 사분위수, 제 3 사분위수, 최대값

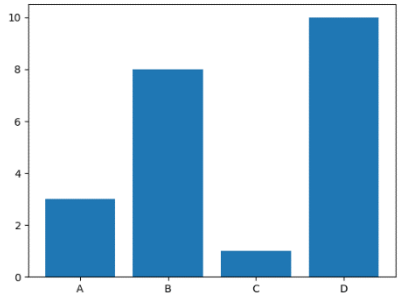
히스토그램



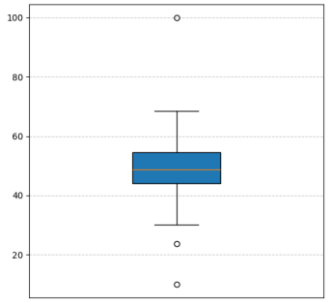
원 그래프



막대 그래프



상자 그림

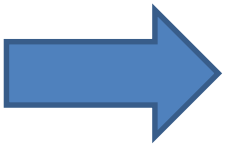


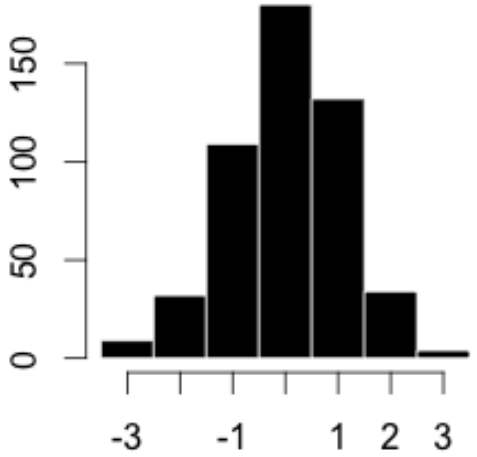
3) 기술 통계

일변량 차트 – 히스토그램

- 표로 되어 있는 도수 분포(도수분포표)를 정보 그림으로 나타낸 것
- 하나의 수치형 변수로 그리며 분포 파악이 용이
- 주로 가로축을 계급, 세로축을 도수로 표현
- 막대그래프와 달리 x축 설정에 따라 막대의 너비, 개수가 달라질 수 있음

Bin	Count
-3.5	23
-2.5	32
-1.5	109
-0.5	180
0.5	132
1.5	34
2.5	4
3.5	90



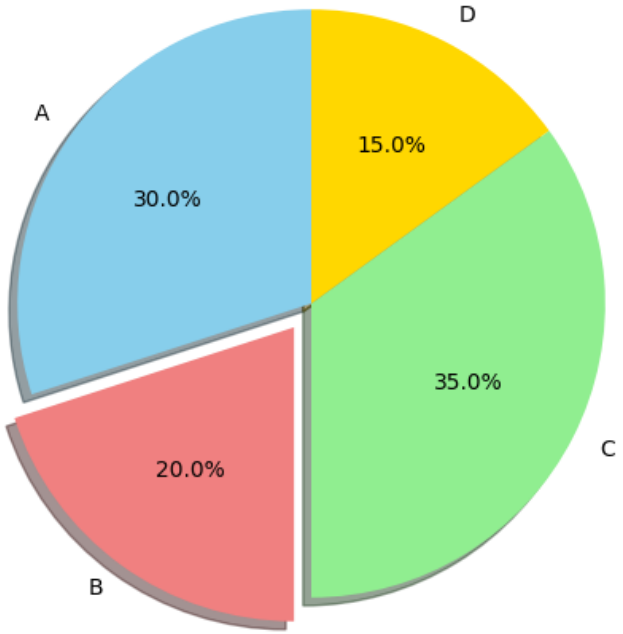


https://ko.wikipedia.org/wiki/히스토그램

3) 기술 통계

일변량 차트 – 원 그래프

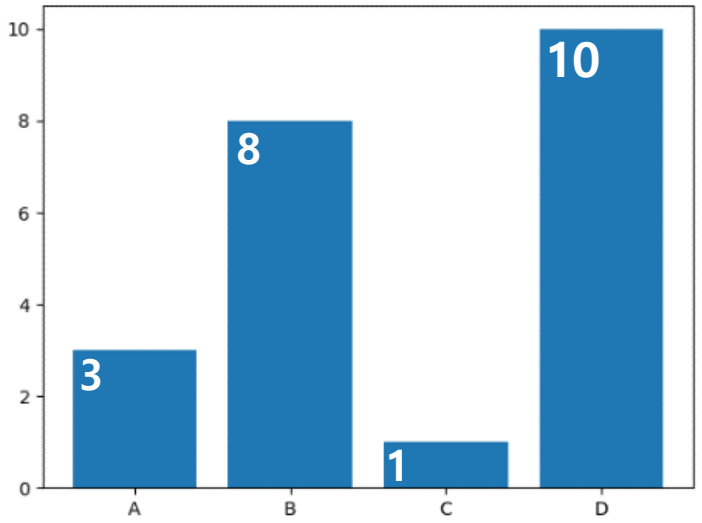
- 원 그래프(Pie chart)는 전체에 대한 각 부분의 비율을 부채꼴 모양으로 백분율로 나타낸 그래프
- 하나의 범주형 변수의 각 항목의 비율을 보다 쉽게 확인하기 위해 사용
- 각 부채꼴의 중심각이 전체에서 차지하는 비율을 나타냄

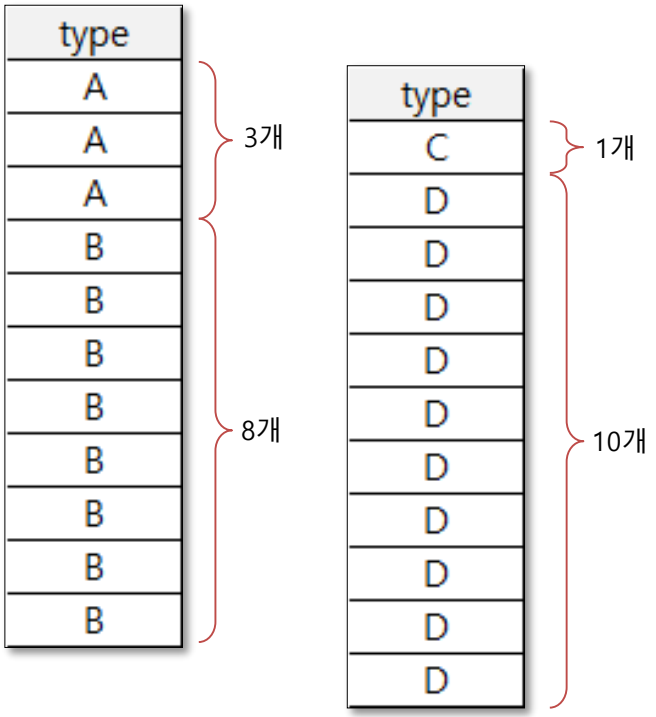


3) 기술 통계

일변량 차트 – 막대 그래프

- 연속인 수치형 변수와 이산인 수치형 변수 또는 범주형 변수를 활용하여 그리는 그래프
- 연속인 수치형 변수는 보통 y축에 배치
- 누적의 의미를 강조할 때 활용

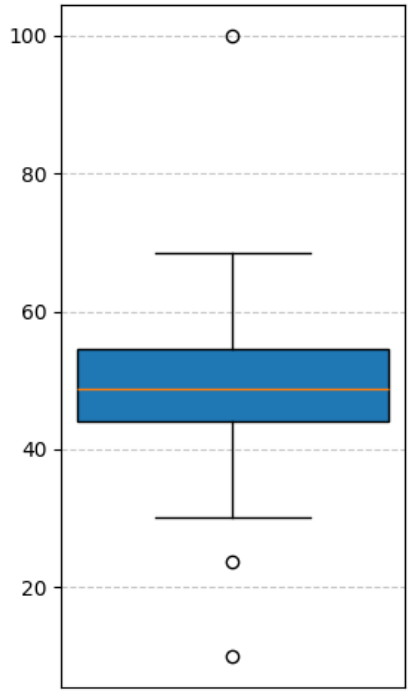


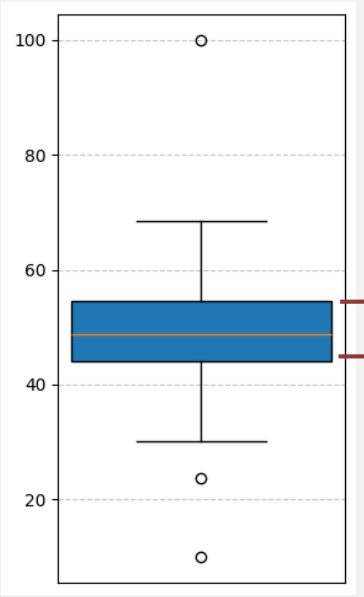


3) 기술 통계

일변량 차트 – 상자 그림

- 단일 수치형 변수의 분포를 분위수 등 여러 숫자를 기반으로 구현한 그래프
- 사분위 범위를 활용하여 일정 이상 떨어져 있는 경우 별도로 이상치를 표기
- 상자 그림을 2개 이상 이어 붙여 이변량 차트로 만든 후 변수간 분포 비교를 손쉽게 하기도 함





Q. 주어진 데이터의 각 변수별 지수 I를 산출하고 I값 중 가장 큰 값을 반올림하여 소수점 둘 째 자리까지 기술 하시오.

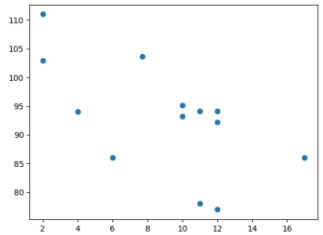
$$I = A - B$$

3) 기술 통계

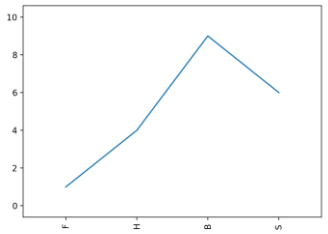
이변량 차트

- ▶ 산점도(scatter plot): 두 변수간 교차점을 점을 사용하여 직교 좌표계에 표기한 그래프
- ▶ 선 그래프(line graph): 산점도의 점과 점을 순서대로 선분으로 이은 그래프
- ▶ 막대 그래프: 특정 기준으로 묶어서 표현하는 경우 존재
- ▶ 상자 그림: 다수의 상자그림을 한 번에 표현하는 경우 존재

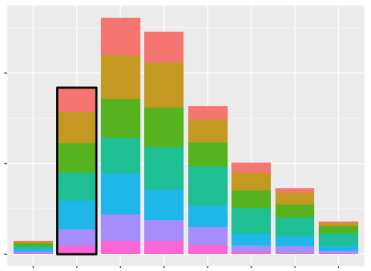
산점도



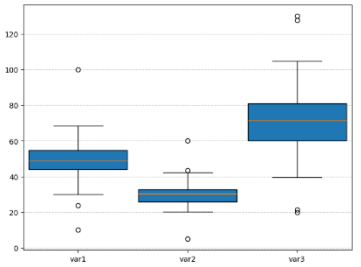
선 그래프



막대 그래프



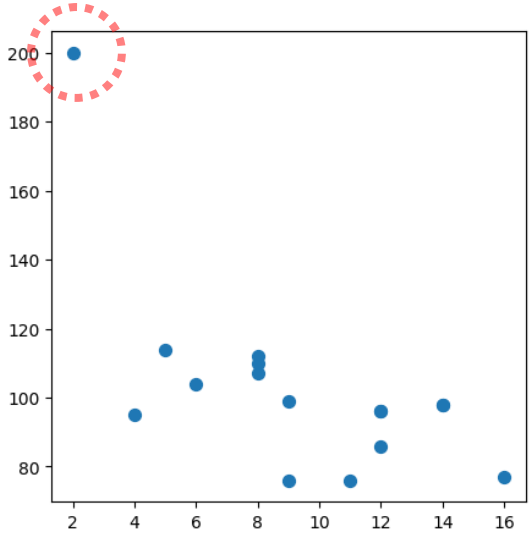
상자 그림

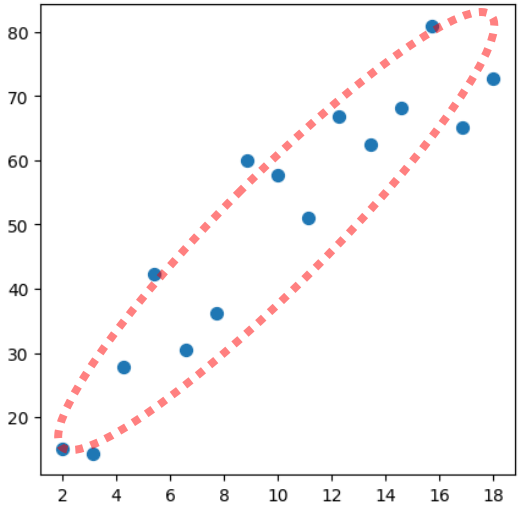


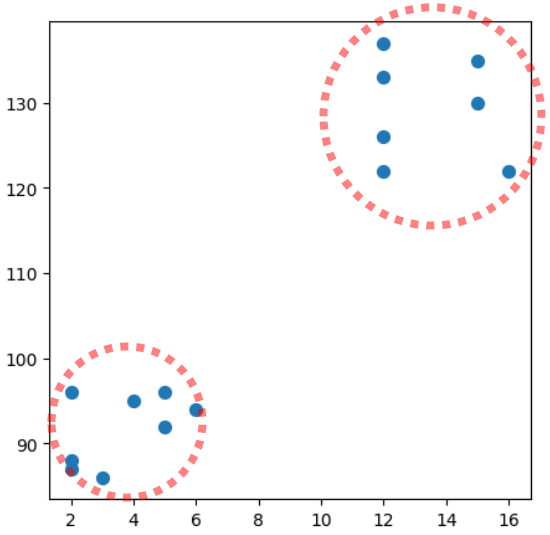
3) 기술 통계

이변량 차트 – 산점도

- 두 수치형 자료를 기반으로 구현하는 그래프
- 연속과 이산은 크게 관계 없으나 x축이 연속이거나 시계열 속성이 있으면 선 그래프로 변환 권장
- 모든 데이터 포인트를 점으로 표기하기에 여러 패턴 관찰 가능(이상치, 선형 관계, 군집 등)



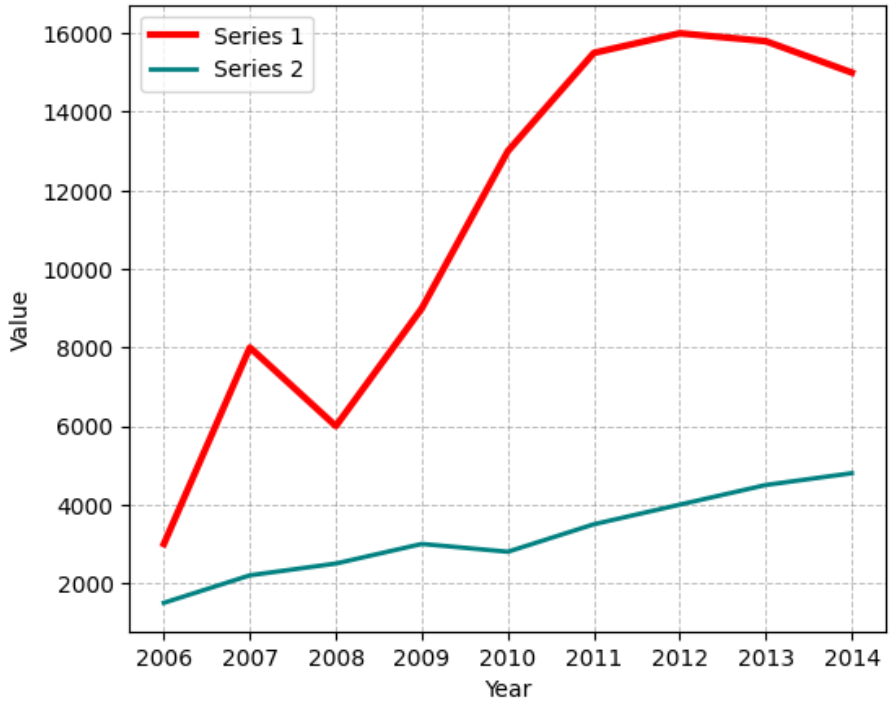




3) 기술 통계

이변량 차트 – 선 그래프

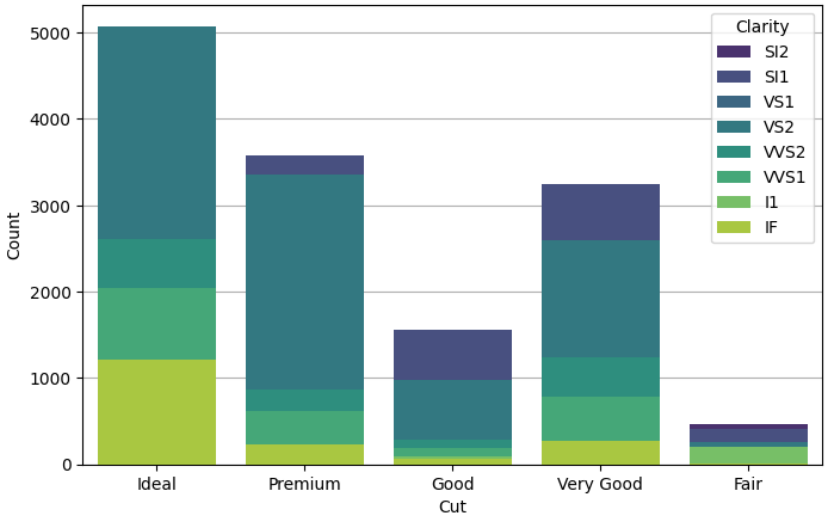
▶ 연속인 두 수치형 변수를 활용하여 그리는 그래프
▶ x축이 시계열이거나 연속성을 강조하고자 하는 경우 산점도 보다 선 그래프 권장

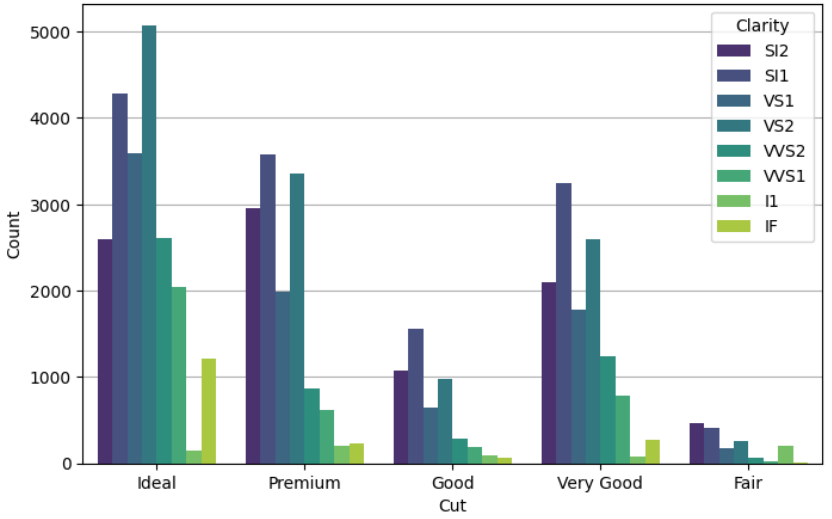


3) 기술 통계

이변량 차트 – 막대 그래프

▶ 위로 쌓는 누적 막대 그래프의 경우 그룹별 총량과 하위 구성 원소의 대략 적인 비율 확인 가능
▶ 옆으로 배치하는 그룹형 막대 그래프의 경우 그룹별 총량 파악은 힘드나 그룹별 원소별 수치 확인 용이





4) 추론 통계

추론 통계(Inferential Statistics)

- 모집단에 대한 어떤 미지의 양상을 알기 위해 통계학을 이용하여 추측하는 과정
- 추정(estimation)과 가설검정(hypothesis testing)으로 나뉨

시험 x

용어 정리

- 추정(Estimation): 표본을 통해 모집단 특성을 추측하는 과정
- 추정량(Estimator): 모집단 특성을 추정하기 위하여 이용되는 통계량
- 추정치(Estimate): 추정량을 통하여 계산된 구체적인 수치
- 점 추정치(Point Estimate): 하나의 수치에 의해 추정된 모집단의 특성
- 편의(Bias): 추정량의 기댓값과 실제 모수와의 차이
- 불편성(Unbiasedness): 추정량이 여러 번 계산되었을 때 그 기댓값이 실제 모집단 모수와 일치하는 성질
- 유효성(Efficiency): 추정량이 모수를 얼마나 정확하게 추정하는지를 나타냄
- 불편 추정량(Unbiased Estimator): 추정량의 기대값이 모수와 같은 추정량
- 유효 추정량(Efficient Estimator): 추정량의 분산이 상대적으로 작은 추정량(보통 분산으로 측정)

→ 큰 분산(큰 변동)은 추정을 어렵게 함

4) 추론 통계

점 추정(point estimate)

- 표본으로부터 모수에 가까울 것으로 예상되는 하나의 값을 산출하는 것
- 점 추정량은 변동이 있으며 너무 적은 표본의 점 추정량은 모집단 추론에 한계가 있음

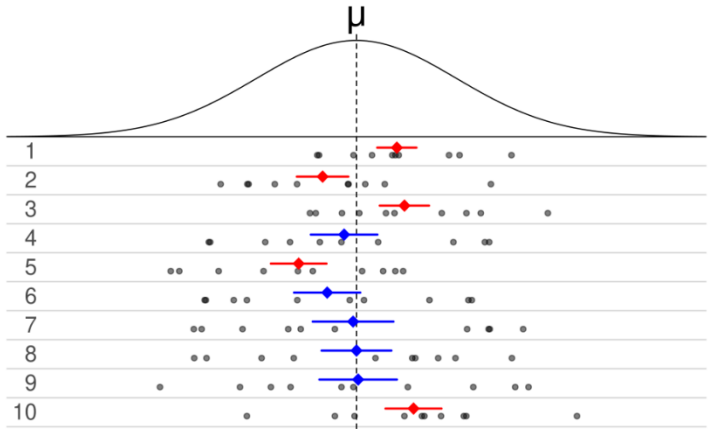
좋은 점 추정량의 조건

- 불편성(unbiasedness): 추정량이 모수와 같아야(최소가 되어야) 함
- 일치성(consistency): 표본 크기가 모집단의 크기에 가까울 수록 오차가 줄어듦
- 유효성(efficiency): 모수에 대한 추정량의 분산이 작을 수록 좋음
- 충분성(sufficiency): 표본은 모집단을 대표할 수 있어야 함

4) 추론 통계

구간 추정(interval estimate) 점추정량을 기준으로 (+ 구간)

- ▶ 일정 확신으로 모수가 포함될 구간을 추정하는 것
- ▶ 오차 한계: 모수 추정에서 발생하는 임의 표본추출 오차를 수치화 한 것
- ▶ 신뢰 구간(CI, confidence interval): 알 수 없는 모집단 모수를 포함할 가능성이 높은 값의 범위
  - ※ 점 추정량과 오차한계를 활용하여 신뢰 구간 산출
- ▶ 신뢰 수준(confidence level): 신뢰구간 중 특정 비율이 모집단 평균을 포함한 비율
  - ※ 신뢰 수준이 높을수록(95% → 99%) 신뢰 구간은 넓어짐
- ▶ 유의수준(α): 분석 결과가 우연에 의해 나타났을 가능성을 얼마나 낮게 설정할지를 결정하는 기준 1 - 신뢰수준



https://en.wikipedia.org/wiki/Confidence_interval

신뢰구간 계산식

★ $\bar{X} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$

오차한계(허용 오차) 계산식

$z_{\alpha/2} \times \frac{\sigma}{\sqrt{n}}$

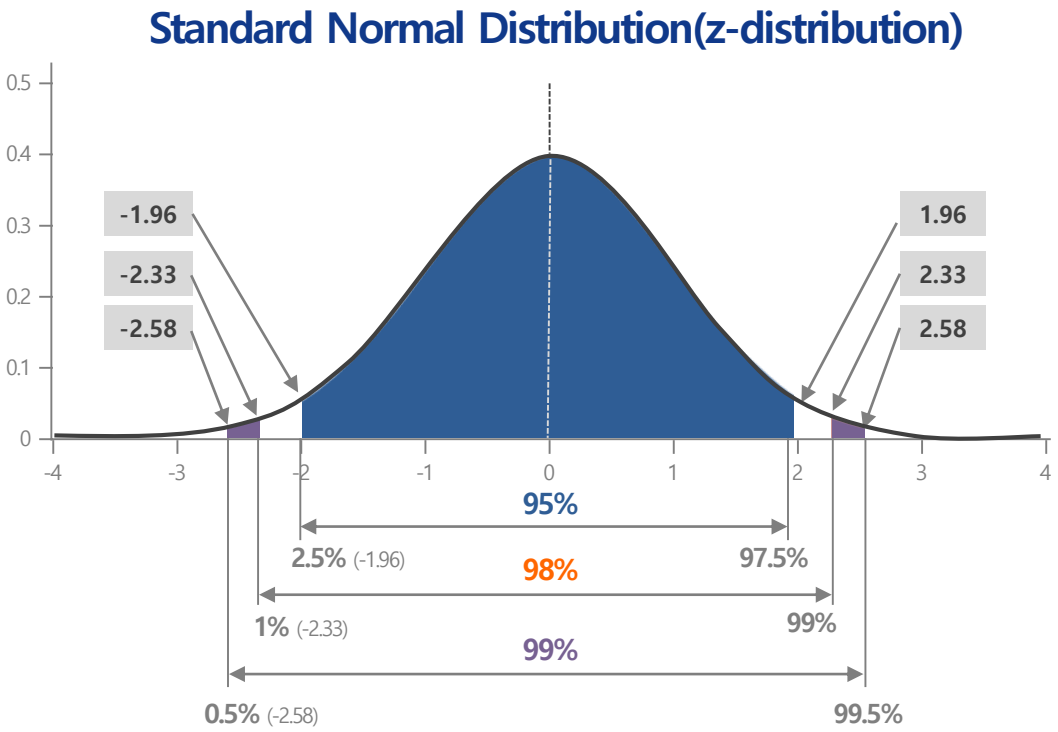
※ σ: 표준 편차, α: 유의 수준

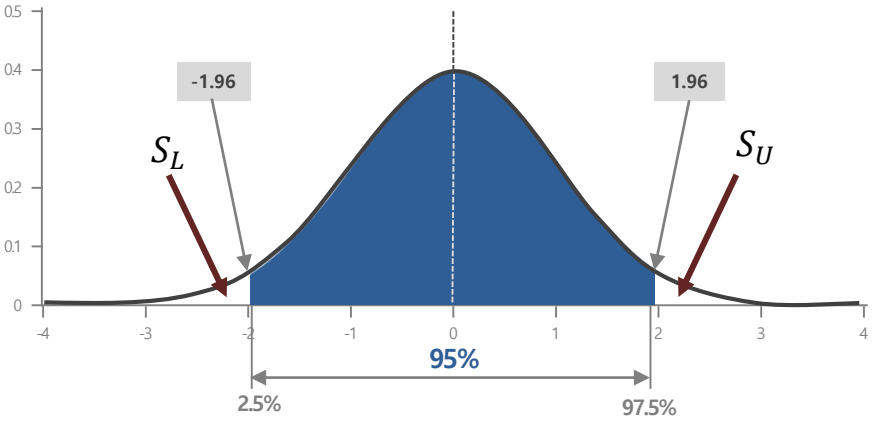
※ Margin of Error: 허용오차, 오차한계

4) 추론 통계

z분포와 구간

▶ z분포를 기준으로 ±1.96σ(표준편차)의 경우 면적이 0.95임





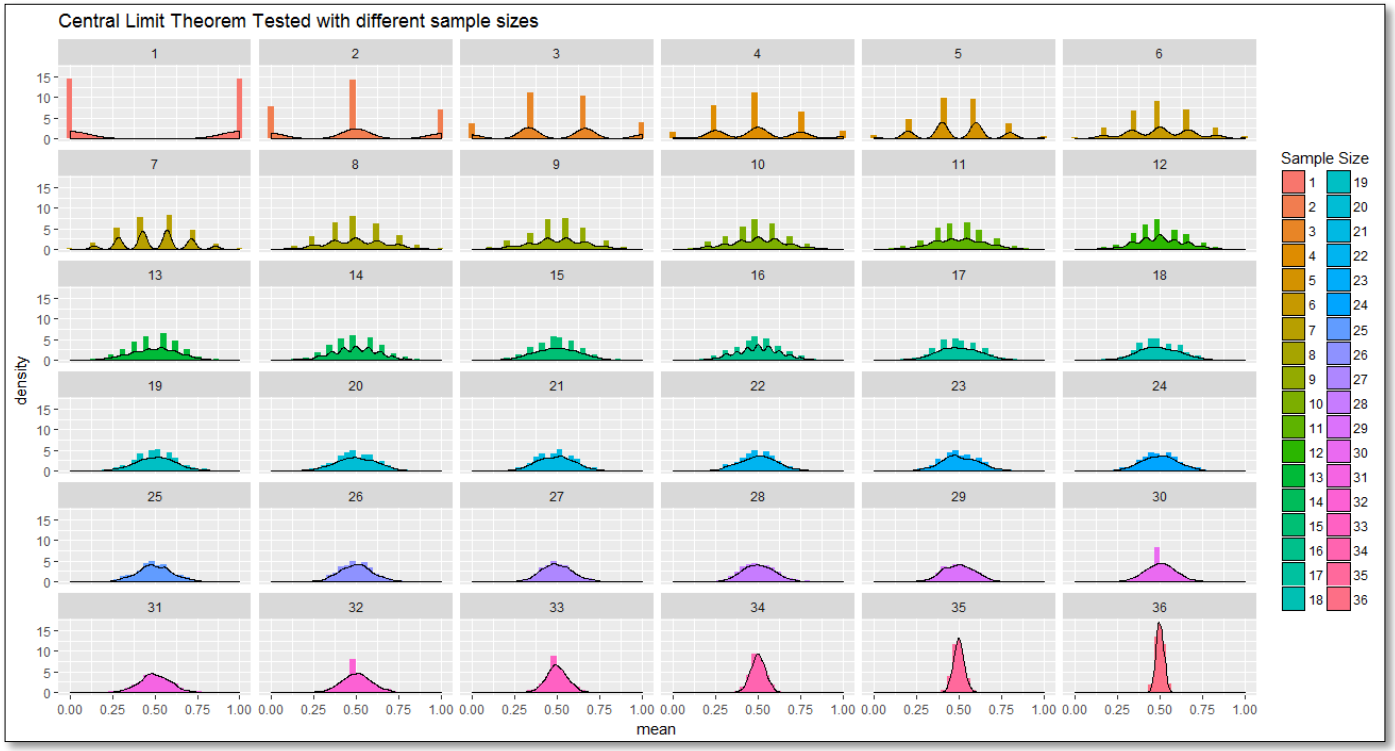
$$\int_{-1.96\sigma}^{1.96\sigma} f(x)dx = 0.95$$

4) 추론 통계

중심 극한 정리(CLT, Central Limit Theorem)

▶ 모집단의 평균이 μ이고 표준편차가 σ인 임의의 분포를 이룬다고 할 때 이 모집단으로 부터 추출된 표본 n의 크기가 충분하다면 표본평균들이 이루는 분포는 평균이 μ이고 표준편차가 $\sigma/\sqrt{n}$인 정규분포에 근접한다는 이론

※ 각 표본은 독립이라고 가정

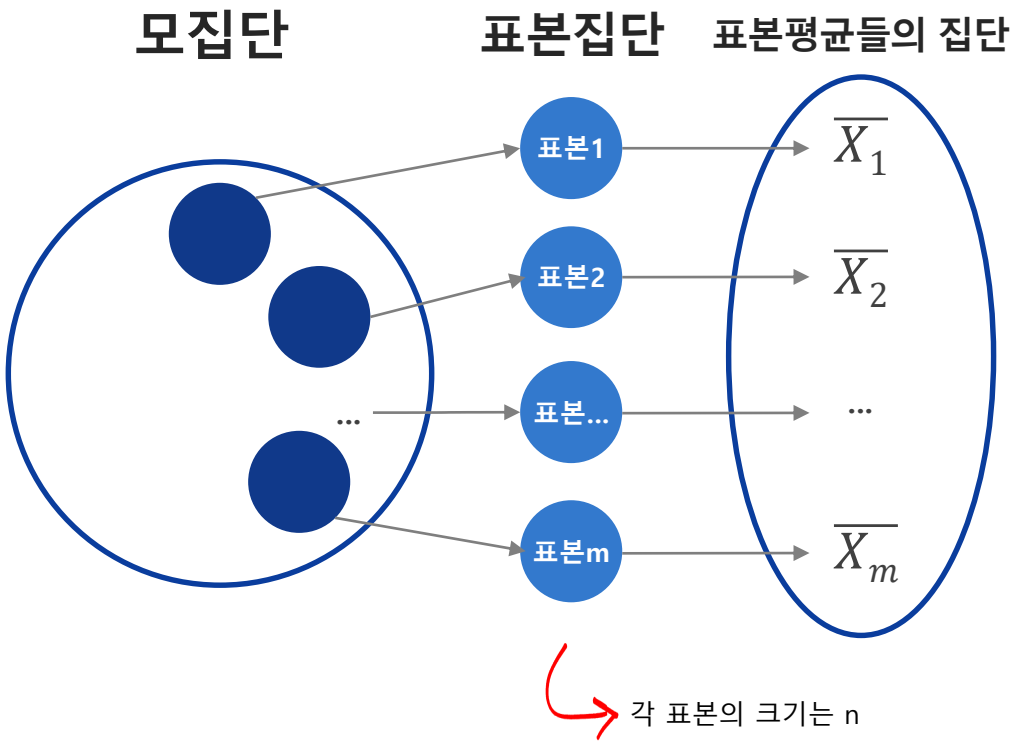


4) 추론 통계

표준 오차

▶ 표준 오차(SE, Standard Error): 통계의 표본 분포의 표준 편차
▶ 평균의 표준 오차(SEM, Standard Error of Mean): 표본 평균 분포의 표준 편차

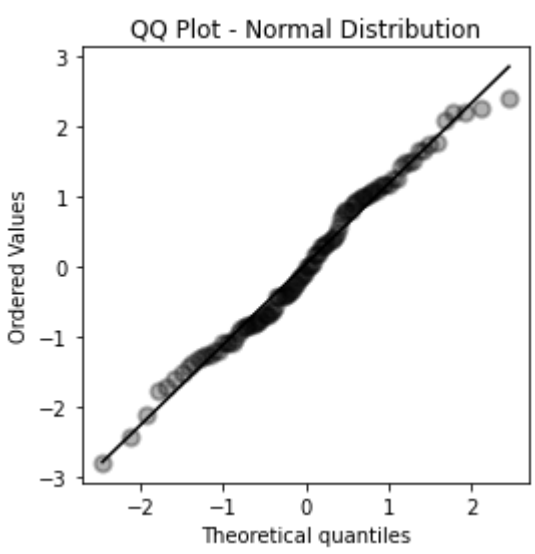
☆ $S_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$

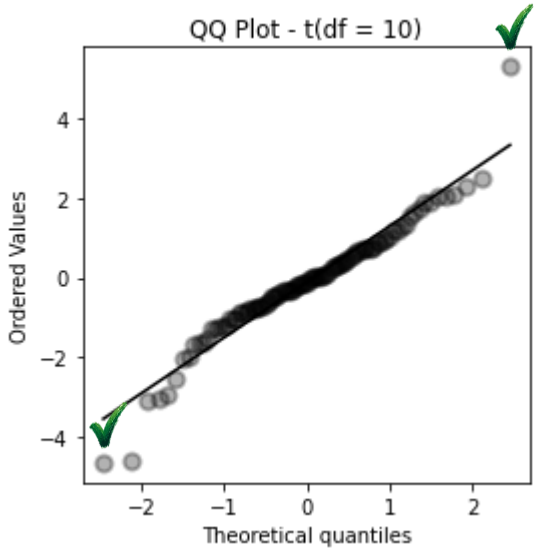


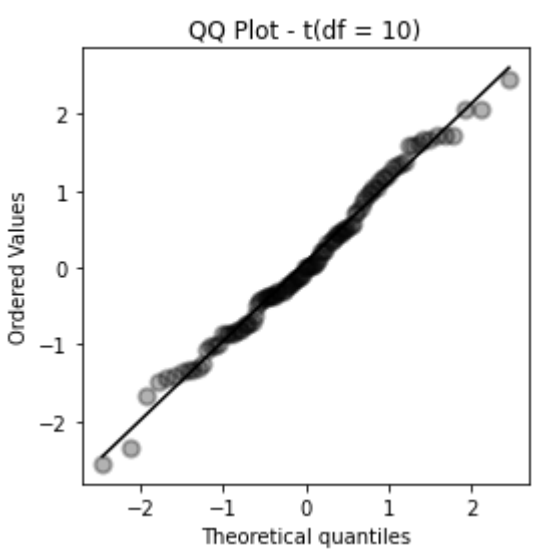
4) 추론 통계

정규성 확인 – QQplot (Quantile-Quantile plot)

- 주어진 분포가 정규분포와 가까운지 알아보기 위해 QQplot(정규분포 분위수 대조도)을 활용
- 주어진 분포가 정규분포와 유사하다면 대각선 근처에 점이 찍힘
- 보다 명확한 확인을 위해서는 정규성 검정(Normality test) 필요

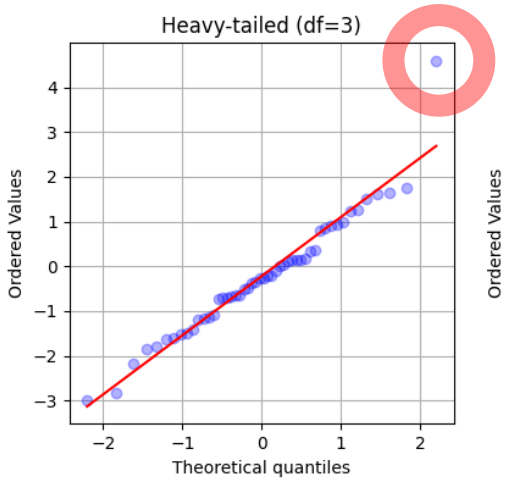


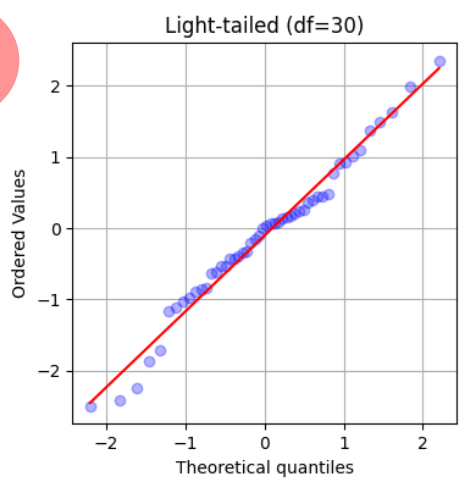


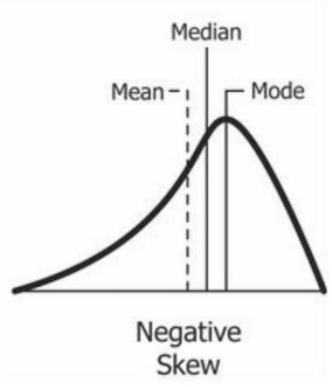


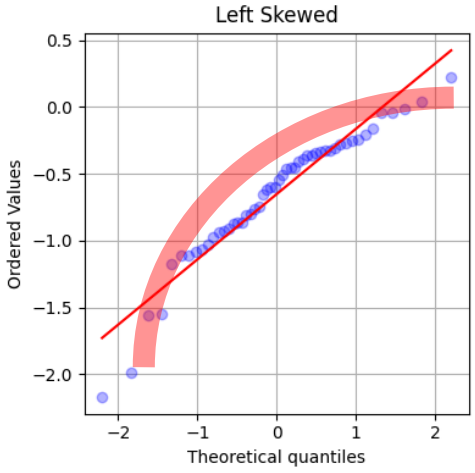
4) 추론 통계

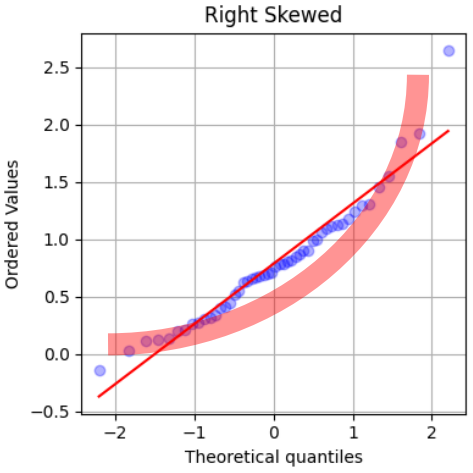
정규성 확인 – 다양한 QQplot (Quantile-Quantile plot)

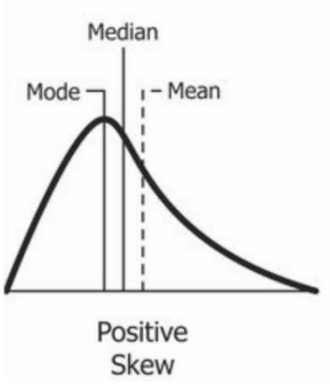












4) 추론 통계

상관 분석(Correlation Analysis)

▶ 두 변수간 어떤 선형(linear)적 관계를 갖고 있는지 분석하는 방법
※ 선형 관계가 없다고 두 변수간 관계가 없는 것이 아님(비선형 관계 가능)
▶ 다양한 상관 분석 기법이 있으며 상관 분석 결과 산출되는 상관 계수(correlation coefficient)와 p-value로 최종 판단
※ p-value는 시험범위 아님

상관 분석의 종류

▶ 대상 변수의 속성에 따라 알맞는 상관 분석 방법 선택 필요

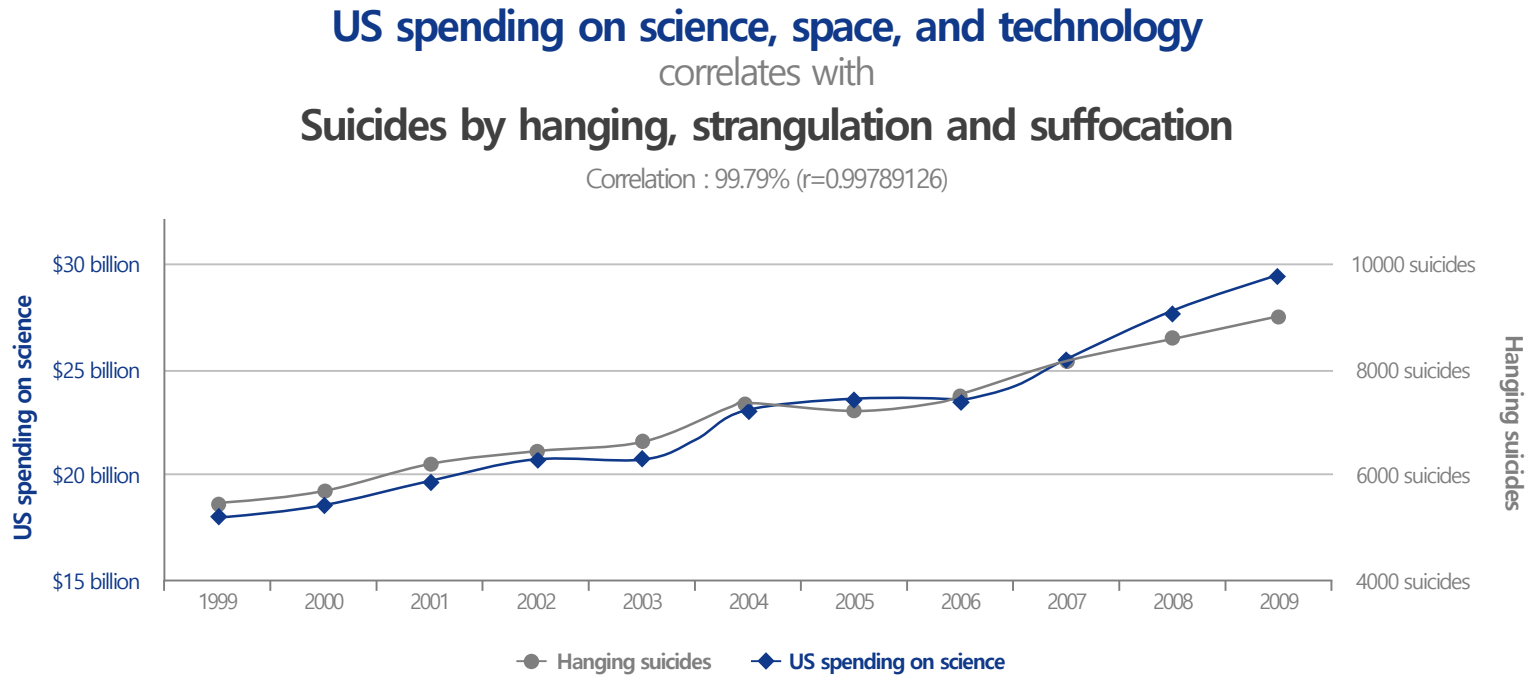
	Quantitiative	Ordinal	Nominal
Quantitiative	Pearson's	Biserial	Point Biserial
Ordinal	Biserial	Spearman	Rank Biserial
Nominal	Point Biserial	Rank Biserial	Phi, L, C Lambda

: 시험 범위

4) 추론 통계

상관과 인과

▶ 상관이 있다고 반드시 인과 관계가 성립하는 것은 아님



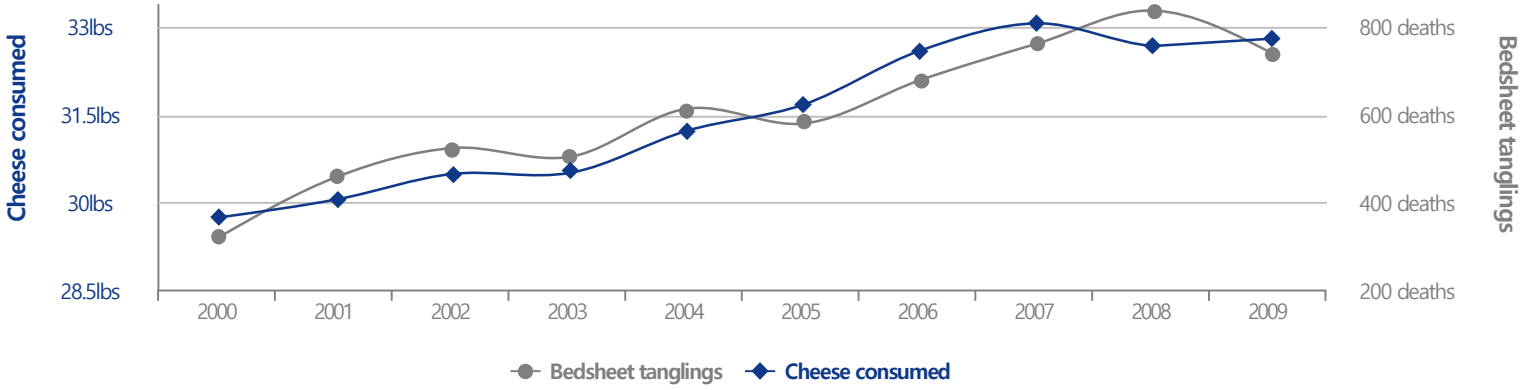
Data sources : U.S Office of Management and Budget and Center for Disease Control & Prevention

4) 추론 통계

상관과 인과

▶ 상관이 있다고 반드시 인과 관계가 성립하는 것은 아님

Per capita cheese consumption
correlates with
Number of people who died by becoming tangled in their bedsheets

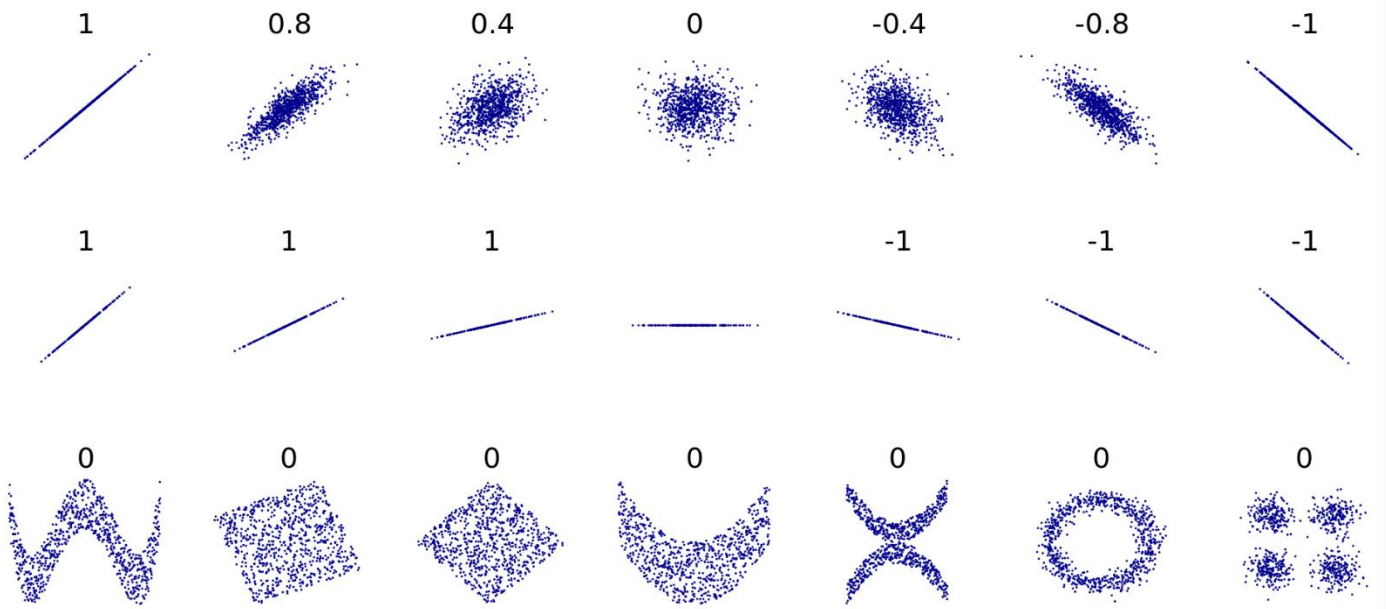


Data sources : U.S Office of Management and Budget and Center for Disease Control & Prevention

4) 추론 통계

상관 계수(Correlation Coefficient)

- 기울기에 관계없이 두 변수의 관계가 직선에 가까우면 상관 계수의 절대값은 1에 근사함
- 상관 분석 결과가 유의하고 상관 계수가 올바르게 산출되더라도 비선형 관계로 보이면 0으로 취급
- 상관 계수의 값 범위는 -1부터 1까지
- 상관 계수는 절대값이 0.7이상인 경우 강하다고 표현하는 경우가 많으나 주관적 해석으로 기준은 없음



https://en.wikipedia.org/wiki/Correlation

4) 추론 통계

상관 분석 – Pearson's Correlation Analysis 자료가 정규분포를 따를 때 잘 된다고..? 근데 그냥 많이 씀

- 두 수치형 변수간 선형적(직선적, linear) 관계가 있는지 분석하는 방법
- 정식 명칭은 피어슨의 곱적률 상관(Pearson's product-moment correlation) 이다.
- 공분산으로 부터 유도하며, 두 변수의 표준편차를 나누어 상관계수(correlation coefficient) 유도 가능
- 상관 계수의 제곱은 단순선형회귀의 결정계수와 같음
- 상관 계수의 부호가 양수인 경우 "양의 상관 관계" 음수인 경우 "음의 상관 관계"

상관계수의 계산

$$r = \frac{\sum z_x z_y}{n-1} = \frac{1}{n-1}\sum\left(\frac{X_i - \bar{X}}{S_X}\right)\left(\frac{Y_i - \bar{Y}}{S_Y}\right) = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2 \sum(Y_i - \bar{Y})^2}} = \frac{COV(X,Y)}{\sigma_X \sigma_Y}$$

4) 추론 통계

상관 분석 – Spearman's Correlation Analysis 모수가 정해져있지 않을 때..

- 두 순서형 변수간 선형관계를 갖고 있는지 분석하는 방법
- 두 변수가 정규성을 따르지 않는 경우 사용하기도 하며 비모수적 방법
- 각 변수의 순위를 매긴 후 그 순위의 차를 활용하여 계산

상관계수의 계산

$$\gamma_s = 1 - \frac{6\sum d_i^2}{n^3 - n}$$

※ d_i : i번째 쌍의 순위 차

원자료		순위		순위차
A	B	Rank A	Rank B	diff
12	2	1	3	-2
5	4	4	2	2
2	-2	5	5	0
7	9	3	1	2
9	0	2	4	-2

4) 추론 통계

상관 분석 예제 코드

```
import pandas as pd
from scipy.stats import pearsonr
from scipy.stats import spearmanr

df = pd.read_csv("iris.csv")
pearsonr(df["SepalLength"], df["SepalWidth"])
spearmanr(df["SepalLength"], df["SepalWidth"])
df.corr(method = "pearson") # method 기본값은 "pearson"
df.corr(method = "spearman")
```

5) 필기 예상 문제

Q01. 눈이 1 부터 6까지 있는 주사위를 두 번 던질 때 나오는 수 중 3의 배수가 존재할 확률은?

① 4/9

② 2/3

③ 5/9

④ 7/9

5) 필기 예상 문제

Q02. 1부터 6까지 적힌 주사위가 있을 때 5는 3의 배수보다 나올 확률이 3배 높고, 3의 배수는 4의 약수 보다 나올 확률이 2배 높을 때 5이상의 숫자가 나올 확률은?

① 6/13

② 1/3

③ 8/13

④ 12/169

5) 필기 예상 문제

Q03. 단위 시간 안에 어떤 사건이 몇 번 발생할 것인지를 표현하는 이산 확률 분포는?

① 포아송 분포

② 이항 분포

③ 정규 분포

④ 베르누이 분포

5) 필기 예상 문제

Q04. 상관분석을 통하여 두 수치형 변수의 연관성을 알 수 있으므로 다른 추가적인 분석은 필요하지 않다.

① O

② X

5) 필기 예상 문제

Q05. 다음 중 이상치에 상대적으로 민감한 위치 통계량은?

① 평균

② 중앙값

③ 최빈값

④ 표준편차

5) 필기 예상 문제

Q06. 어떤 데이터: 9, 12, 4, 6, 7, 8에 대한 중앙값을 구하시오.

① 7.5

② 7

③ 8

④ 7.67

5) 필기 예상 문제

Q07. 어떤 데이터: 8, 8, 8, 8, 8, 8에 대한 설명 중 맞는 것은 무엇인가?

① 분산은 8이다

② 표준편차는 8이다

③ 변동계수는 0이다

④ 사분위 범위(IQR)는 8이다

5) 필기 예상 문제

Q08. 정규분포의 특성으로 맞지 않는 것은?

① 정규곡선은 종모양으로 나타난다

② 정규분포는 평균을 중심으로 좌우대칭이다

③ 정규분포의 형태와 위치는 평균과 범위가 결정한다

④ 정규곡선 밑의 면적은 1이다

5) 필기 예상 문제

Q09. 주사위를 5회 던졌다고 가정했을 때 주사위의 숫자 중 관심있는 숫자 5가 3회 이상 나타날 확률은(소수 세째자리 이후 절삭)?

① 0.003

② 0.035

③ 0.032

④ 0.016

5) 필기 예상 문제

Q10. 학생들이 본 시험 점수 평균이 70이고 표준편차가 8인 정규분포를 따르면서 내가 받은 점수는 90점이라고 한다. 다음 중 제대로 해석한 것은?

① 내 점수는 평균보다 20점 높으므로, 전체 학생의 약 20%만이 이보다 높은 점수를 받았을 것이다

② 내 점수는 전체 시험자 중 상위 3% 안에 들어가는 점수이다

③ 내 점수는 상위 10%에는 못 미치는 점수이다

90 = 70 + 2.5 * 8

1.96 s 가 2.5% 컷이니까..
답은 2번

④ 내 점수 90점은 평균보다 20점 높지만, 표준편차 8의 영향으로 보통 수준의 성적이라고 볼 수 있다.

5) 필기 예상 문제

Q11. 다음 중 추정에 대한 설명으로 부적절한 것은?

① 통계량을 통해 모수를 추정하는 방법으로 점추정과 구간추정이 있다

② 표본의 크기가 커질수록 허용오차(margin of error)는 감소하는 경향이 있다

신뢰구간 공식 생각하면 된다..

③ 추정치는 표본에서 산출할 수 있는 값이다.

④ 모집단의 분포가 정규분포인 경우만 표본평균은 정규분포를 따른다

5) 필기 예상 문제

Q12. 어느 농장에서 수확한 사과의 무게는 정규분포를 따른다고 한다. 이 사과 중에서 임의 추출한 n개의 무게를 조사했더니 평균이 20g, 표준편차가 5g였다. 이를 기반으로 추정한 평균에 대한 신뢰구간이 [19.02, u] 라고 할 때 u는 얼마인가?

① 20.02

② 19.98

③ 20.98

④ 25

신뢰구간은 좌우대칭! 표준편차는 문제에 나왔지만 안쓰는거..

5) 필기 예상 문제

Q13. 점추정을 하기 위한 사전 조건으로 적합하지 않은 것은?

① 표본의 크기가 작을수록 추정값이 모수와 거의 같아진다

② 추정량의 분산은 작을수록 좋다

③ 모평균의 불편추정량은 표본평균이다

④ 표본은 모집단을 대표할수록 좋다

5) 필기 예상 문제

Q14. 기판 5개당 결함이 총 10개가 생산되는 생산라인이 있다고 하자. 이 생산라인에서 제조된 한 기판을 조사하였을 때, 결함이 3개 나올 확률을 구하시오.

① 0.4510

② 0.1804

③ 2

④ 0.5121

평균이 2이고 사건 발생 값은 3

포와송 분포로 접근 --> 공식으로 계산...ㄷㄷ

5) 필기 예상 문제

Q15. 전체 인구 중에서 걸릴 확률이 0.1인 질병이 있다고 하자. 실제 질병이 있는 사람을 검사하였을 때 양성이 나올 확률은 0.9이다. 그리고 전체 인구를 대상으로 검사하였을 때는 양성일 확률이 0.2이다. 그렇다면, 양성이 나온 사람 중에서 실제 질병이 있는 사람의 확률은 무엇인가?

① 0.5

② 0.09

③ 0.45 ✓

④ 0.18

P(질병) = 0.1

P(양성|질병) = 0.9

P(양성) = 0.2

P(질병|양성) = P(질병) * P(양성|질병) / P(양성) = 0.09 / 0.2

5) 필기 예상 문제

Q16. Histogram, Pie Chart, Box Plot, 산점도는 일변량 차트로 사용한다

① O

② X

5) 필기 예상 문제

Q17. 산점도 그래프를 통해 알 수 있는 정보로 옳지 않은 것은?

① 이상치 존재 유무

② 선형 관계 존재 유무

③ 군집 존재 유무

④ 입력 변수의 기술통계량



02

데이터 처리



1) 데이터 이해

데이터의 분류

- 명목척도(nominal scale): 속성을 분류하는 척도
- 서열척도(ordinal scale): 순서 관계를 밝혀주는 척도
- 등간척도(interval scale): 순서 사이의 간격이 균등한 척도
- 비율척도(ratio scale): 순서 사이의 간격이 균등하고, 절대값(0)이 존재하는 척도

데이터 분류별 상세

- **명목척도(nominal scale)**: 가장 낮은 수준의 척도로 단지 측정대상의 특성만 구분하기 위하여 숫자나 기호를 할당한 것으로 특성간 양적 분석 및 특성간 대소 비교 불가
- **서열척도(ordinal scale)**: 측정대상의 특성 구분과 더불어 대상간 상대적인 크기를 나타낼 수 있고, 서로 간에 비교가 가능한 척도
- **등간척도(interval scale)**: 명목척도와 서열척도의 특징을 모두 가지고 있으면서 크기가 어는 정도나 되는지, 특성간의 차이가 어느 정도나 되는지 파악이 가능한 척도
- **비율척도(ratio scale)**: 가장 높은 수준의 척도로서, 가장 자세한 정보를 제공, 서로의 구분, 크기의 비교, 크기의 차이, 그리고 특성들 간의 계산까지 가능한 수준, 모두 숫자로 표현되고 그것들의 계산이 가능한 척도

1) 데이터 이해

데이터 특성별 예시

▶ 수치형(Numerical): 숫자로 이루어져 있으며 이산형과 연속형으로 나뉨
ㄴ 이산형(Discrete): 수치적 의미를 가지나 서로 떨어져 있고 주로 정수로 표현
ㄴ 연속형(Continuous): 수치적 의미를 가지며 측정 가능하고 주로 유리수로 표현
▶ 범주형(Categorical): 숫자 또는 문자로 이루어져 있으며 순서형과 명목형으로 나뉨
ㄴ 순서형(Ordinal): 각 범주간 우열 관계가 존재
ㄴ 명목형(Nominal): 각 범주간 우열 관계가 없고 단순 분류를 위한 데이터



price	carat	cut	color
326	0.23	Ideal	E
326	0.21	Premium	E
327	0.23	Good	E
336	0.24	Very Good	I
337	0.26	Very Good	H

수치형	범주형(순서형)	범주형(명목형)

2) 데이터 탐색 및 정제

결측치(Missing Value)

- 데이터가 있어야 할 자리에 누락이 되어있는 것
- 전체 데이터 대비 결측치 비율에 따라 결측치 제거 또는 대치(imputation) 실시
- 결측치 판별 및 처리에 절대적인 기준은 없음

결측치(Missing Value)의 종류

- MCAR(Missing Completely At Random): 완전 무작위 결측
- MAR(Missing At Random): 무작위 결측, 결측값 발생이 특정 변수와는 관계있는 경우
- MNAR(Missing Not At Random): 비무작위 결측

결측치(Missing Value)의 처리

- 보통 MCAR이거나 결측 비율이 매우 낮을 때 삭제(deletion)를 실시하며 그 외에는 대치(imputation)
- 단순 대치법: 결측치를 단일 값으로 채워 넣는 방법(평균 등)
- 다중 대치법: 결측치를 다중 값으로 채워 넣는 방법(k-NN 등)

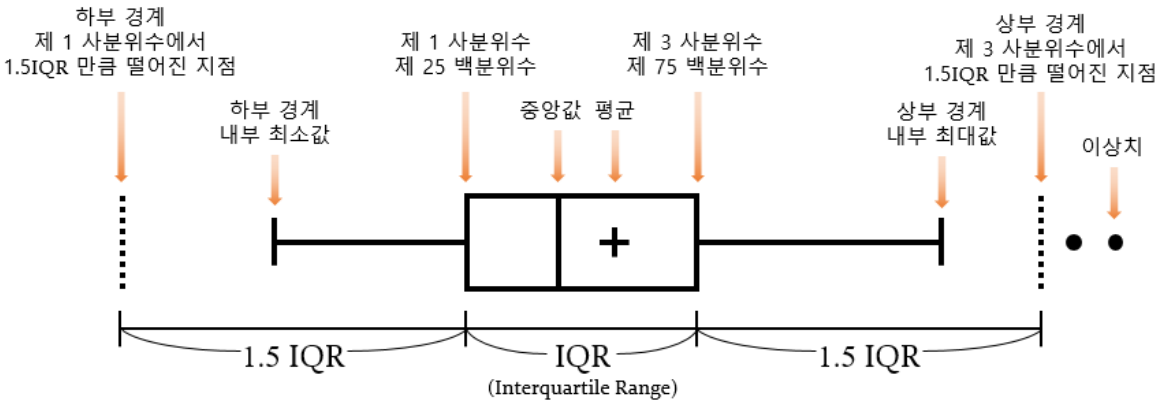
2) 데이터 탐색 및 정제

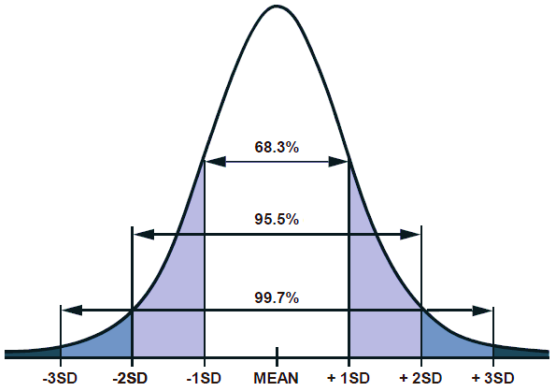
이상치(Outlier)

- 데이터의 중심 경향에서 일정 이상 멀리 떨어진 값
- 분산, 우도(likelihood), 밀도, 군집분석, 최근접 이웃 등 다양한 방법으로 판별
- 이상치 판별 및 처리에 절대적인 기준은 없음

이상치(Outlier)의 판별 - 분산

- 데이터의 분포와 함께 분산(또는 표준편차)을 활용한 판단
- 기하평균 또는 사분위수 활용





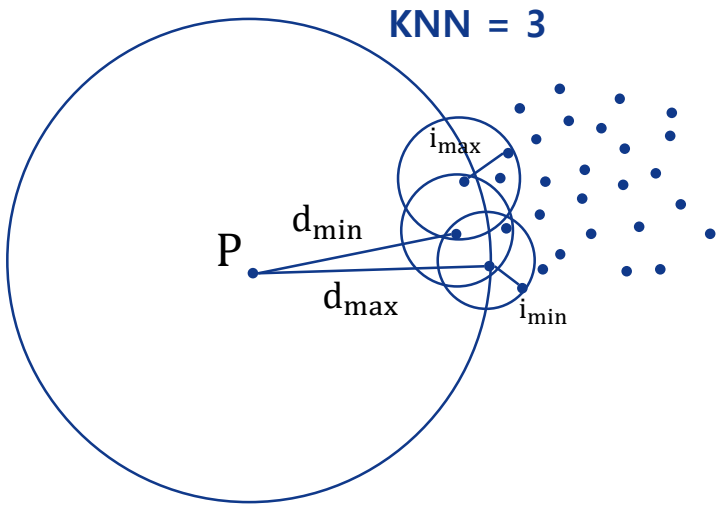
2) 데이터 탐색 및 정제

이상치(Outlier)의 판별 – Likelihood

▶ 베이즈 정리에 의해 데이터 셋이 가지는 두가지 샘플(정상/이상)에 대한 발생 확률(Likelihood)로 이상치 판별

이상치(Outlier)의 판별 – k-NN

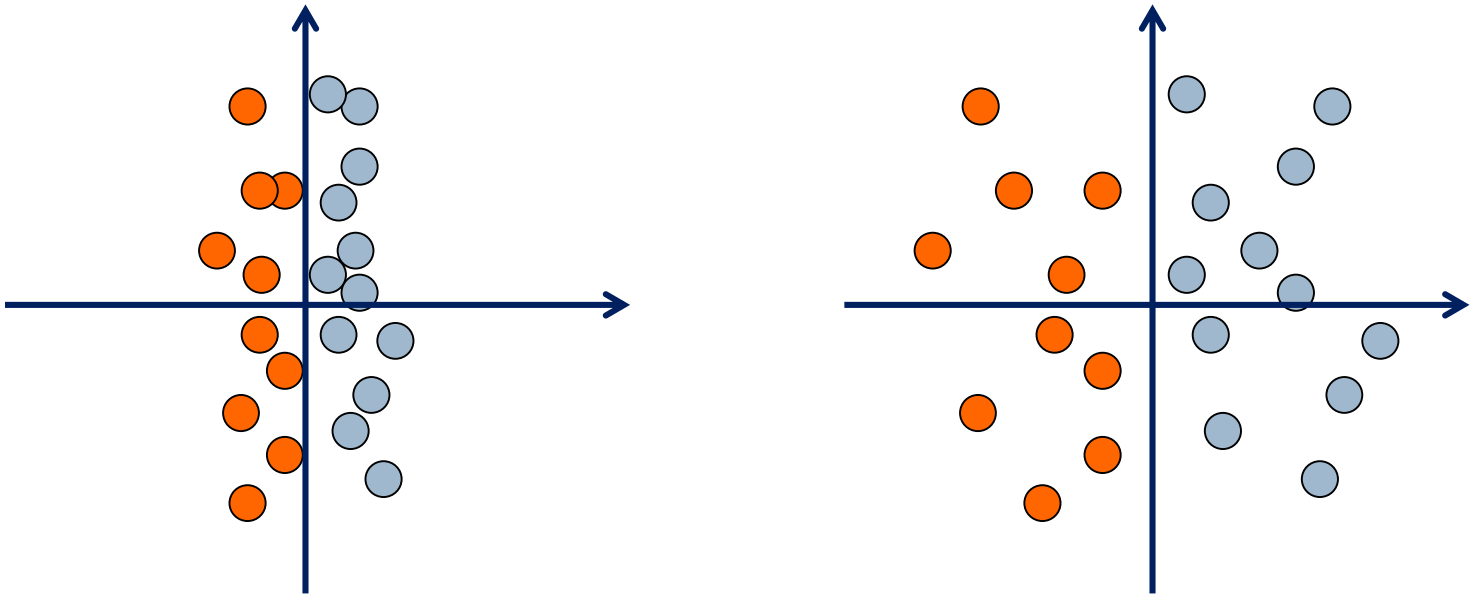
▶ k-NN 알고리즘을 기반으로 특정 데이터와 주변 데이터간 거리를 비교하는 방법
▶ 특정 데이터와 이웃 데이터간 거리값이 상대적으로 크다면 해당 데이터는 이상치일 확률이 높음



3) 데이터 변환

수치형 데이터 변환 – 정규화(normalization)

- 두 개 이상의 표본이 서로 단위가 다른 경우 그 비교가 어렵다.
- 특정 기준에 따라 자료의 단위를 변환하여 자료간 비교를 용이하게 할 수 있다.
- 거리 계산 알고리즘 사용시 결과 편향을 사전에 예방하기위한 정규화 권장



3) 데이터 변환

수치형 데이터 변환 – 구간화(Min-Max Scaling) 최소-최대 정규화

- 데이터의 범위를 일치시키거나 분포를 유사하게 만들어 주는 방법
- 단위가 상이한 두 개 이상의 변수를 비교할 때 사용
- 보통 Quantile 정규화(0~1의 범위로 변환)를 사용

$$N_Q = \frac{x - \min(x)}{\max(x) - \min(x)}$$

range

수치형 데이터 변환 – 표준화(Standardization) 분포는 바뀌지 않고 값이 바뀌는 것

- 단위가 상이한 두 개 이상의 변수를 비교할 때 사용하며 변환 후 평균이 0, 표준편차가 1로 됨
- 변환 전의 데이터가 정규분포를 따를 경우 변환 후는 표준 정규분포를 따름
- 표준화된 값은 Standard score, z score 또는 z-value 라고 불린다.
- 표본에 대해 z변환을 실시할 경우 표본 크기를 고려한 변환식 사용(자유도: n – 1)

$$z = \frac{x - \bar{x}}{s}$$

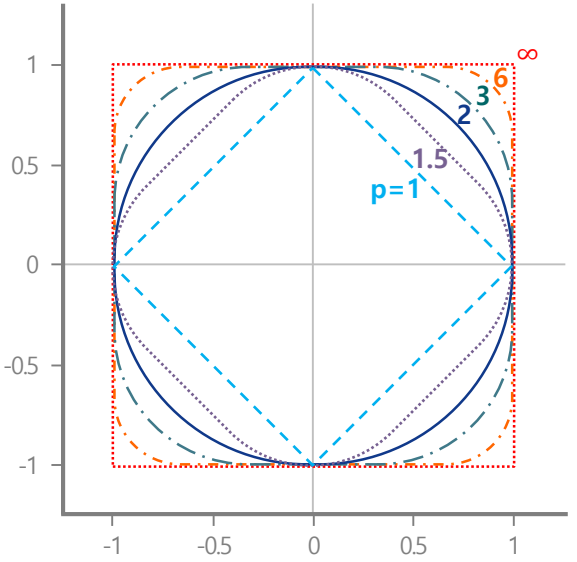
3) 데이터 변환

수치형 데이터 변환 – Lp-norm

- norm: 벡터의 길이(또는 크기)를 측정하기 위한 함수
- L1-norm: 절대값 계산을 활용하며 멘하탄 거리(Manhattan distance) 산출식과 같음
- L2-norm: 제곱 연산을 활용하며 유클리드 거리(Euclidean distance) 산출식과 같음
- L1 / L2-norm은 k-NN 및 k-means 에서도 활용

$$L_1 = \sum_{i=1}^{n} |x_i| = |x_1| + |x_2| + \cdots + |x_n|$$

$$L_2 = \sqrt{\sum_{i=1}^{n} x_i^2} = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$$



3) 데이터 변환

반드시 모두 암기

관련 메서드 및 클래스(sklearn > preprocessing)

메서드 및 클래스	설명
MinMaxScaler()	Min-Max Scaling, [0, 1]
StandardScaler()	표준화
.fit()	모델 학습
.transform()	학습된 모델을 기반으로 신규 데이터 변환
.fit_transform()	모델 학습과 변환을 동시에 실시
.inverse_transform()	역변환을 지원하는 메서드

3) 데이터 변환

MinMaxScaler() 예제

```
df1 = pd.DataFrame(dict(A = [1, 2, 3], B = [4, 5, 6], C = [7, 8, 9]))
df2 = pd.DataFrame(dict(A = [10, 11], B = [12, 13], C = [14, 15]))
```

```
MinMaxScaler().fit_transform(df1) # 정규화 객체가 필요 없는 경우
```

```
array([[0. , 0. , 0. ],
       [0.5, 0.5, 0.5],
       [1. , 1. , 1. ]])
```

```
model_nor_mm = MinMaxScaler().fit(df1) # 정규화 객체가 필요한 경우
model_nor_mm.transform(df1)
```

```
array([[0. , 0. , 0. ],
       [0.5, 0.5, 0.5],
       [1. , 1. , 1. ]])
```

3) 데이터 변환

StandardScaler() 예제

```
model_nor_ss = StandardScaler().fit(df1)
arr_df1_nor = model_nor_ss.transform(df1)
df1_nor = pd.DataFrame(arr_df1_nor, columns = df1.columns)
df1_nor
```

	A	B	C
0	-1.224745	-1.224745	-1.224745
1	0.000000	0.000000	0.000000
2	1.224745	1.224745	1.224745

```
model_nor_ss.transform(df2)
```

```
array([[ 9.79795897,  8.5732141 ,  7.34846923],
       [11.02270384,  9.79795897,  8.5732141 ]])
```

```
StandardScaler().fit_transform(df2)
```

```
array([[-1., -1., -1.],
       [ 1.,  1.,  1.]])
```

3) 데이터 변환

StandardScaler() + .inverse_transform() 예제

```
1 df1
```

	A	B	C
0	1	4	7
1	2	5	8
2	3	6	9

```
1 model_nor_ss = StandardScaler().fit(df1)
2 arr_df1_nor = model_nor_ss.transform(df1)
3 model_nor_ss.inverse_transform(arr_df1_nor)
```

```
array([[1., 4., 7.],
       [2., 5., 8.],
       [3., 6., 9.]])
```

3) 데이터 변환

StandardScaler() / MinMaxScaler() 에러 예시

▶ StandardScaler() 또는 MinMaxScaler() 에서 실수로 소괄호를 빼먹는 경우 다음과 같은 에러가 발생

```
1 model_nor_ss = StandardScaler.fit(df1)
```

```
---------------------------------------------------------------------------
TypeError                                 Traceback (most recent call last)
~\AppData\Local\Temp\ipykernel_24796\4039763231.py in <module>
----> 1 model_nor_ss = StandardScaler.fit(df1)

TypeError: fit() missing 1 required positional argument: 'X'
```

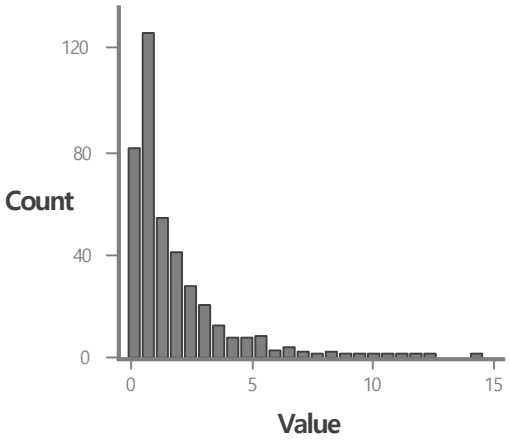
3) 데이터 변환

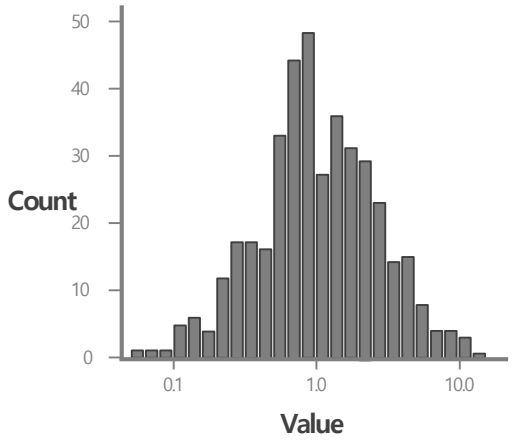
수치형 데이터 변환 – 기타

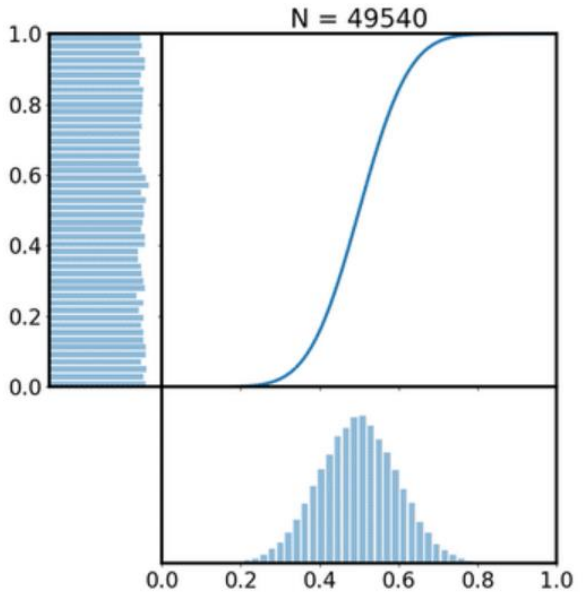
변환을 왜 하는가 - 해석을 편하게 하기 위함

- ▶ 정규성을 만족하지 않는 분포의 수치형 데이터를 다양한 방법으로 변환
- ▶ 지수변환: 왜도가 양수인 경우 1 미만의 지수(ex. 0.5), 왜도가 음수인 경우 1 초과의 지수(ex. 2) 권장
- ▶ 로그(log)변환: 로그를 사용한 변환. 작은 숫자를 키워주며 왜도가 양수인 분포에 사용하기 적합
- ▶ 역(inverse)변환: 역함수 변환이자 지수가 -1인 멱변환으로 균등분포의 경우 정규분포에 근사하게 변환 가능

※ 멱변환(power transform): 거듭제곱의 지수를 고정하고 밑을 변수로 하는 함수





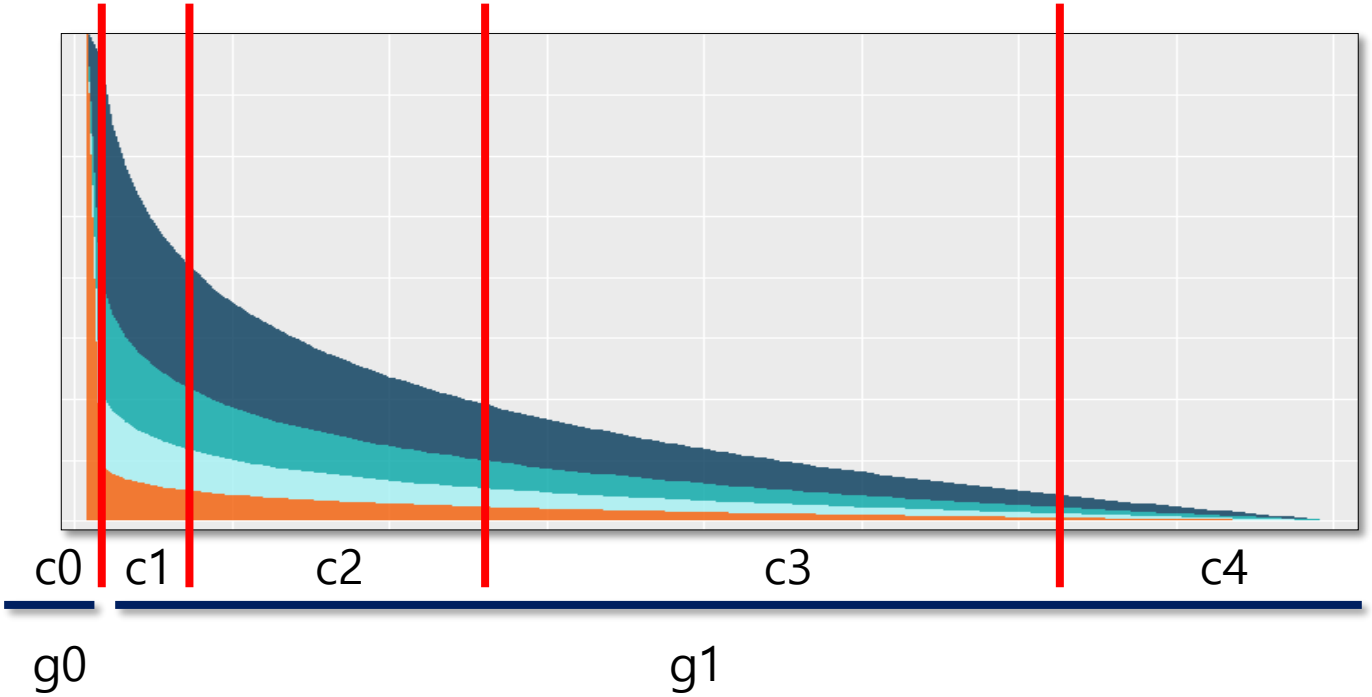


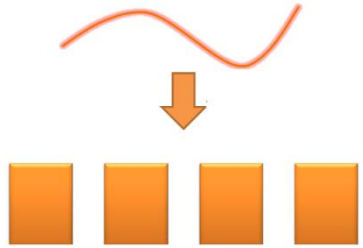
https://en.wikipedia.org/wiki/Inverse_transform_sampling

3) 데이터 변환

범주화 – 이산화(discretization)

- 수치형 자료를 필요에 따라 순서형 또는 명목형으로 변환
- 범위가 매우 큰 경우 로그 변환 활용 가능
- 연령 데이터를 5, 10살 단위로 나눠 연령대 변수 생성
- 소비금액을 기반으로 소비 등급 변수 생성





3) 데이터 변환

관련 함수 및 메서드(pandas)

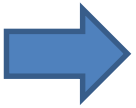
함수 및 메서드	설명
cut()	데이터를 지정한 값을 기준으로 구간을 나눌 때 사용하는 함수로 bins 인자에 구간 구분 기준값을 할당하고 labels 인자에는 각 구간에 붙일 이름을 할당. ※ 개구간, 폐구간과 관련된 설정인 right 인자의 사용에 유의
qcut()	데이터를 동일한 개수의 구간으로 나누는 데 사용하는 함수로 cut() 함수와 유사하나 분위수(quantile)를 기준으로 분할하는 것이 특징

3) 데이터 변환

범주형 데이터 변환 – OHE(One Hot Encoding)

▶ OHE: 하나의 명목형 변수를 해당 변수의 범주 개수만큼의 새로운 가변수(dummy variable)로 변환
※ 더미(dummy) 코딩이라고도 함
▶ 가변수는 0과 1의 값을 가진다.
▶ 가변수는 회귀모델에서 0 또는 상수값으로 영향을 미친다(절편, offset)
▶ 가변수는 1개 제외하여도 모든 정보를 표현가능하기 때문에 경우에 따라 특정 가변수를 분석에서 제외

Color
E
G
H



Color_E	Color_G	Color_H
1	0	0
0	1	0
0	0	1

Color_E	Color_G
1	0
0	1
0	0

H 관련 가변수가 없더라도
나머지 가변수의 값이 모두 0이면
H 표현 가능

3) 데이터 변환

관련 함수 및 메서드(pandas)

함수 및 메서드	설명
get_dummies()	One Hot Encoding을 실시하는 함수로 자동으로 Object 타입의 변수를 대상으로 동작 필요시 columns 인자에 대상 변수를 지정 가능하며 리스트와 유사한 형태의 객체를 할당해야 함 ※ Pandas 1버전 이전 버전의 경우 반드시 대상 변수를 지정해야 함 경우에 따라 첫 번째 가변수를 제거하는 drop_first인자를 사용

3) 데이터 변환

get_dummies() 예제

```
df = pd.DataFrame(dict(A = [1, 2, 3, 4], B = ["a", "a", "c", "b"]))
df
```

	A	B
0	1	a
1	2	a
2	3	c
3	4	b

```
# pd.get_dummies(df, columns = "B") # 에러로 안됨!
pd.get_dummies(df, columns = ["B"])
```

	A	B_a	B_b	B_c
0	1	1	0	0
1	2	1	0	0
2	3	0	0	1
3	4	0	1	0

```
pd.get_dummies(df, columns = ["B"], drop_first = True)
```

	A	B_b	B_c
0	1	0	0
1	2	0	0
2	3	0	1
3	4	1	0

3) 데이터 변환

범주형 데이터 변환 – Label Encoding

▶ n개의 범주형 데이터를 0부터 n-1까지의 연속적 수치 데이터로 표현하는 것
▶ 표기는 숫자이나 실제 데이터는 범주형이기 때문에 변수 사용에 유의

No	Class
12	A
34	B
56	C



No	Class
12	0
34	1
56	2

3) 데이터 변환

범주형 데이터 변환 – 순서형(ordinal)

▶ 순서형 변수는 그 관계 또는 순위에 따라 처리한다.
▶ 보통 항목간 수준을 등간격으로 처리하나 경우에 따라서는 차등을 두어야 할 수 있다.

관측값	처리값
A	4
B	3
C	2
D	1
F	0

- A와 B의 간격은 1이 적당한가?
- B와 C의 간격은 1이 적당한가?
- A와 C의 간격은 2가 적당한가?
- A가 큰 값, F가 작은 값을 가지는 것은 적당한가?

4) 필기 예상 문제

Q01. 다음 중 연속형 데이터의 변환 중 수집된 데이터의 가장 작은 값을 0으로 가장 큰 값을 1로 변환시켜 주는 정규화 방법은?

① z-score

② MinMax

③ One-Hot

④ Dummy

4) 필기 예상 문제

Q02. 주어진 데이터를 표준화(standardization) 하는 경우 관련 내용으로 옳지 않은 것은?

① 표준화는 데이터의 평균을 0, 분산을 1로 변환하는 과정이다.

② 표준화는 데이터의 상대적인 관계는 유지하지만 절대적인 크기를 변경한다.

분포가 바뀌지 않는다

③ 변환된 데이터는 표준정규분포를 따른다

기존 데이터가 정규분포인 경우만!

④ 표준화된 데이터의 최대/최소값은 정해져 있지 않고,
변환 전 데이터의 값에 따라 다르다

4) 필기 예상 문제

Q03. 이상치와 관련된 내용으로 옳지 않은 것은?

① 변환을 통해 이상치 문제를 완화시킬 수 있다

② 데이터에 이상치가 추가될 경우 평균값이 크게 달라질 수 있다

③ 상자수염 그림으로만 이상치를 결정지을 수 있다

④ 대부분의 자료보다 상대적으로 멀리 떨어져 있는 자료이다

4) 필기 예상 문제

Q04. 다음 중 이상치 판별에 활용되는 것으로 보기 어려운 것은?

① 표준편차

② 최빈값

③ 군집

④ 최근접 이웃

4) 필기 예상 문제

Q05. 다음의 상황에서 언급하는 결측값과 관련된 내용으로 옳지 않은 것은?

투입 원료에 따른 생산제품의 물성 수치를 확인하고 그 관계식을 만들고자 한다. 그런데 종종 동작 중에 발생하는 원인을 알 수 없는 결측치는 기계 담당 직원이 직접 가장 가까운 값으로 채워 넣은 값을 활용한다.

① 결측값을 적절한 방법으로 보완하지 않으면 분석 결과가 왜곡될 수 있다

② 결측값을 사람이 직접 보완하면 항상 정확한 데이터로 복원할 수 있다

③ 향후 비결측 데이터를 활용한 관계식으로 결측을 대치할 수 있다

머신러닝 기반 결측 대치

④ 이 상황의 결측치는 완전 무작위 결측에 가깝다



03

머신러닝



머신러닝(Machine Learning)

- 기계학습 이라고도 하며 컴퓨터가 학습할 수 있도록 하는 알고리즘과 기술을 개발하는 분야
- 추정 및 추론에 중점을 두는 통계와는 달리 주로 예측에 초점을 맞추고 있음
- 주어진 데이터 기반으로 학습을 하여 비교적 일반화된 수식 또는 규칙이 담긴 모델을 생성하고 교정함
- 생성한 모델은 각 알고리즘의 고유한 평가지표 또는 범용 평가지표를 활용하여 평가함

머신러닝(Machine Learning)의 분류

- 지도학습(Supervised Learning): 종속변수 존재, 모델 성능 평가 가능
- 비지도학습(Unsupervised Learning): 종속변수 부재, 모델 성능 평가가 어려움, 과적합 개념이 없음
- 강화학습(Reinforcement Learning): 어떤 환경 안에서 정의된 에이전트가 보상을 최대로 하는 행동을 선택
- 지도학습은 크게 회귀 모델과 분류 모델로 나뉨

지도학습 알고리즘 시험 범위

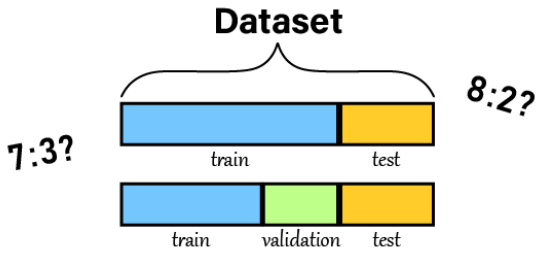
- K-최근접 이웃(k-Nearest Neighbors) – 회귀/분류
- 선형 회귀(Linear Regression) – 회귀
- 로지스틱 회귀(Logistic Regression) – 분류
- 의사결정 나무(Decision Tree) – 회귀/분류
- 랜덤 포레스트(Random Forest) – 회귀/분류
- 나이브 베이즈(Naïve Bayes) – 분류 모델만

비지도학습 알고리즘 시험 범위

- 군집분석: k-means

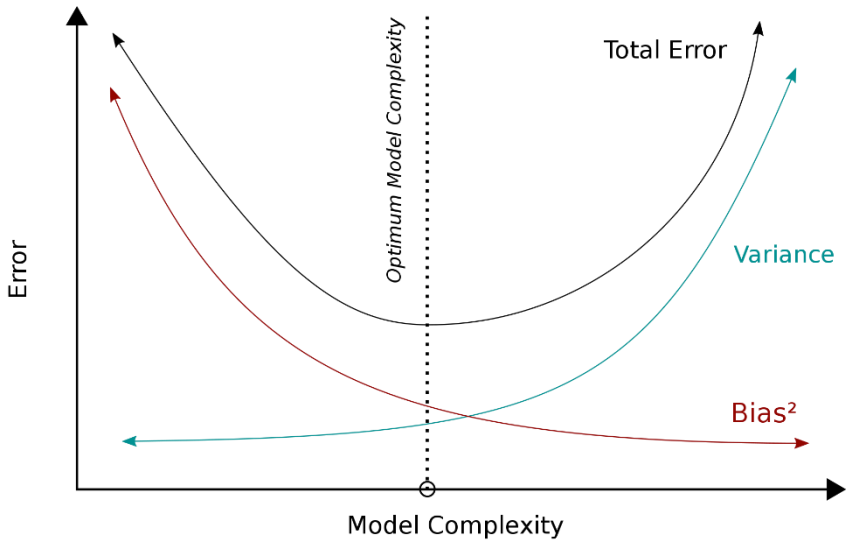
용어 정리

- 종속변수: 결과값이 있으며 추론(예측 또는 분류) 대상이 되는 변수
- 독립변수: 결과값을 산출하기 위한 입력값이 있는 변수
- 모델: 어떤 현상을 설명하기 위한 수식 또는 규칙
- 모델튜닝: 모델의 성능 향상이나 해석을 위해 취하는 일련의 조치
- 하이퍼파라미터(hyperparameter): 어떤 것을 조정하기 위한 설정값
- 학습 데이터셋(train dataset): 모델의 학습에 사용되는 데이터셋
- 검증 데이터셋(validation dataset): 모델의 최종 평가 이전에 학습 상태를 점검하기 위해 사용되는 데이터셋
- 평가 데이터셋(test dataset): 모델의 최종 평가에 사용되는 데이터셋
- 과적합(overfitting): 모델이 학습 데이터에 과하게 맞춰진 상태이며 신규 데이터 기반 추론시 저성능 야기
- 과소적합(underfitting): 모델이 학습 데이터에 대충 맞춰진 상태이며 전반적으로 추론 결과가 좋지 않음



편향-분산 균형(Bias-Variance Tradeoff)

- 편향(Bias): 지나치게 단순한 모델로 발생되는 오차. 큰 편향은 과소적합(under fitting) 야기
- 분산(Variance): 지나치게 복잡한 모델로 발생되는 오차. 큰 분산은 과대적합(over fitting) 야기
- 편향과 분산을 둘 다 극단적으로 줄이기 어렵기에 타협점을 찾아야 함



$$Error(x) = \underbrace{\left(f(x) - \frac{1}{k}\sum_{i=1}^{k} f(x_i) \right)^2}_{\text{편향의 제곱}} + \underbrace{\frac{\sigma_\epsilon^2}{k}}_{\text{분산}} + \underbrace{\sigma_\epsilon^2}_{\text{불가피한 오차}}$$

https://en.wikipedia.org/wiki/Bias-variance_tradeoff

2) 머신러닝의 평가

평가 지표 – 회귀 모델

- 수치형 변수의 평가는 관측값(actual value)과 예측값(predicted value)의 오차를 기반으로 한다.
- 오차를 기반으로 하는 평가는 값이 작을 수록 좋다.
- MSE는 오차를 제곱하기에 상대적으로 RMSE와 MAE보다 값이 큼
- RMSE, MAPE가 많이 사용되는 편이며 특히 MAPE는 백분율로 표기되어 해석에 용이하다.
- MAPE는 특성상 실제값(y)에 0이 있는 경우 문제(발산)가 발생할 수 있음

관련 수식

$$\mathrm{MSE} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$$

$$\mathrm{MAPE} = \frac{\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|}{n} * 100$$

$y_i - \hat{y}_i$: $error$

y_i : 실제값, $\hat{y}_i$: 예측값

2) 머신러닝의 평가

평가 지표 – 회귀 모델의 결정계수

- 결정계수(coefficient of determination, R^2): 회귀모델이 주어진 자료에 얼마나 적합한지를 평가하는 지표
- 종속변수의 변동량과 예측값의 변동량을 비교하는 지표
- 기본적으로 값 범위는 0~1이며 예측값이 매우 좋지 않을 경우(모델 성능이 낮을 경우) 음수가 산출될 수 있음

$$R^2 = 1 - \frac{\sum(\text{오차})^2}{\sum(\text{편차})^2} = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y_i})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

R^2=1– 그냥 평균으로 예측했을 때 오차 / 모델 쓰고 남은 오차

2) 머신러닝의 평가

평가 지표 – 분류 모델

- 범주형 변수의 평가는 정분류와 오분류 결과를 기반으로 함
- Accuracy, Precision, Recall, F1 score는 1에 가까울수록 좋음 (최소값은 0)
- Accuracy를 가장 먼저 확인하지만 분석 목표에 따라 Precision/Recall/F1 score를 추가로 확인
- F1 score는 F-β score의 β가 1인 경우이며 Precision과 Recall의 조화평균

관련 수식

- TP: True Positive, TN: True Negative, FP: False Positive, FN: False Negative

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \qquad Precision = \frac{TP}{TP + FP} \qquad Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

2) 머신러닝의 평가

평가 지표 – 분류 모델

- 혼동행렬(confusion matrix)은 실제와 예측의 정/오 분류 결과를 표로 표기한 것
- 분류 성능의 평가를 위해 다양한 지표를 산출하는 근간이 되는 행렬(또는 표)
- 정확도의 경우 TP가 낮아도 꽤 높게 나올 수 있기 때문에 TP를 분자로 하는 지표를 같이 확인해야 함

		Predicted Class: Positive	Predicted Class: Negative	
Actual Class	Positive	True Positive(TP)	False Negative(FN) **Type II Error**	**Sensitivity** $\frac{TP}{(TP+FN)}$
	Negative	False Positive(FP) **Type I Error**	True Negative(TN)	**Specificity** $\frac{TN}{(TN+FP)}$
		Precision $\frac{TP}{(TP+FP)}$	**Negative Predictive Value** $\frac{TN}{(TN+FN)}$	**Accurracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$

Recall

T(True, 참): 올바르게 예측한 경우
F(False, 거짓): 잘못 예측한 경우
P(Positive, 양성): 양성으로 예측한 경우
N(Negative, 음성): 음성으로 예측한 경우

2) 머신러닝의 평가

관련 함수 및 메서드(sklearn > metrics)

함수 및 메서드	설명
mean_absolute_error()	MAE(Mean Absolute Error)
mean_squared_error()	MSE(Mean Squared Error)
root_mean_squared_error()	RMSE(Root Mean Squared Error)
mean_absolute_percentage_error()	MAPE(Mean Absolute Percentage Error)
accuracy_score()	Accuracy
precision_score()	Precision
recall_score()	Recall
f1_score()	F1-score

시험 버전에서 지원하지 않음

직접 구해야 함

2) 머신러닝의 평가

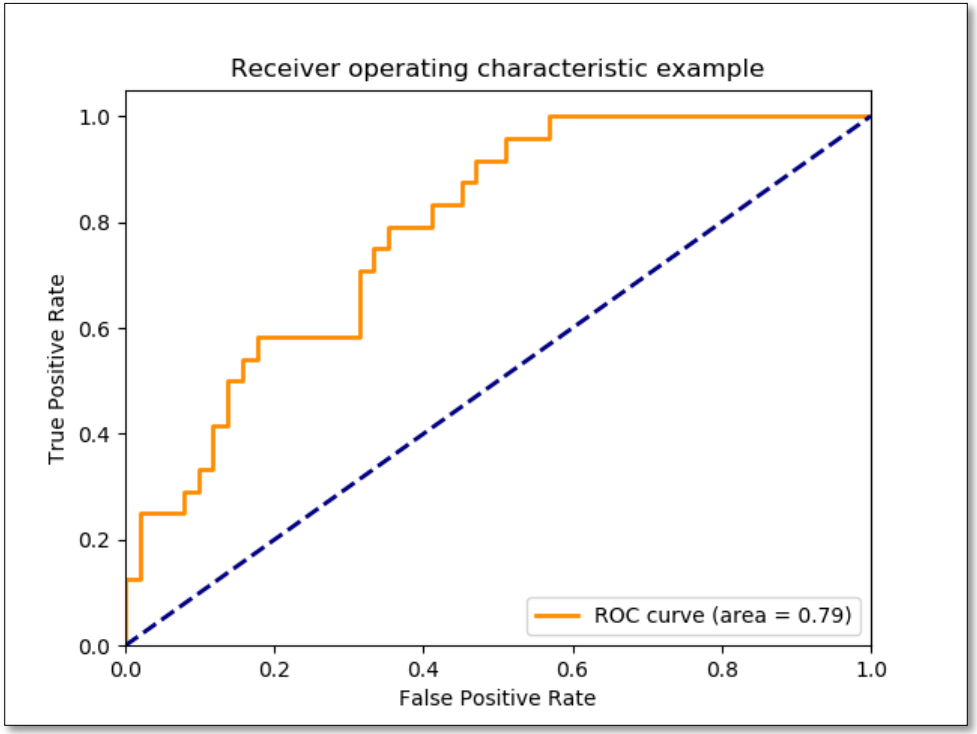
평가 지표 – 분류 모델: ROC(Receiver Operating characteristic) Curve

- FP(1-Specificity) 값의 비율로 하고 세로축을 TP(Sensitive) 값의 비율로 하여 시각화 한 그래프
- 분류 모델의 전반적인 성능을 가늠할 수 있음
- 곡선 아래면적을 AUC(Area Under Curve)라고 하며 이 값의 최대값은 1

false positive 가 조금 커져도
true positive가 금방 높아져야
좋은 모델

TPR

$$TPR = \frac{TP}{TP + FN}$$



FPR

$$FPR = \frac{FP}{FP + TN}$$

https://scikit-learn.org/stable/auto_examples/model_selection/plot_roc.html

2) 머신러닝의 평가

평가 지표 – 분류 모델: ROC(Receiver Operating characteristic) Curve

sklearn - roc_curve()

▶ ROC 곡선을 그릴 때 사용하는 함수(시험x)
▶ y_true, y_score 인자에 각각 종속변수와 예측(확률)값 할당

sklearn - roc_auc_score()

▶ AUC를 산출하는 sklearn의 함수
▶ y_true, y_score 인자에 각각 종속변수와 예측(확률)값 할당

2) 머신러닝의 평가

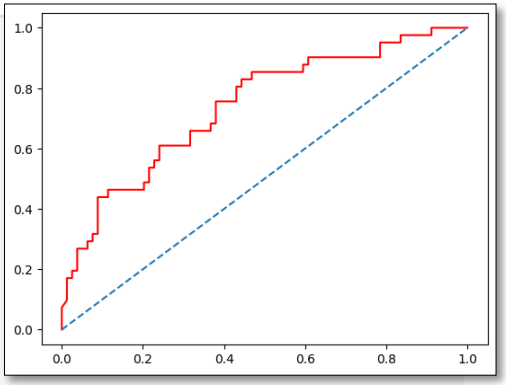
평가 지표 – 분류 모델: ROC(Receiver Operating characteristic) Curve 예제 코드

```python
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_curve

df = pd.read_csv("logistic_regression_01.csv")
df_dum = pd.get_dummies(data = df, columns = ["rank"], drop_first = True)
df_train, df_test = train_test_split(df_dum, train_size = 0.7, random_state = 123)

model = LogisticRegression(random_state=123)
model.fit(X = df_train.drop("admit", axis = 1), y = df_train["admit"])

pred = model.predict_proba(df_test.drop("admit", axis = 1))
fpr, tpr, thresholds = roc_curve(df_test["admit"], pred[:, 1])
plt.plot(fpr, tpr, color = "#FF0000")
plt.plot([0, 1], [0, 1], linestyle = "--")
```



2) 머신러닝의 평가

가설 함수와 비용 함수(cost function)

▶ 가설 함수: 학습 데이터에 없는 새로운 데이터를 넣었을 때 그에 따른 적절한 출력을 산출하는 함수

▶ 비용 함수: 원래의 값과 가장 오차가 작은 가설 함수를 도출하기 위해 사용하는 함수이며 **목적함수** 라고도 함

※ MSE, MAE 등 다양한 함수를 비용 함수로 사용 가능

선형 회귀의 경우 회귀 계수

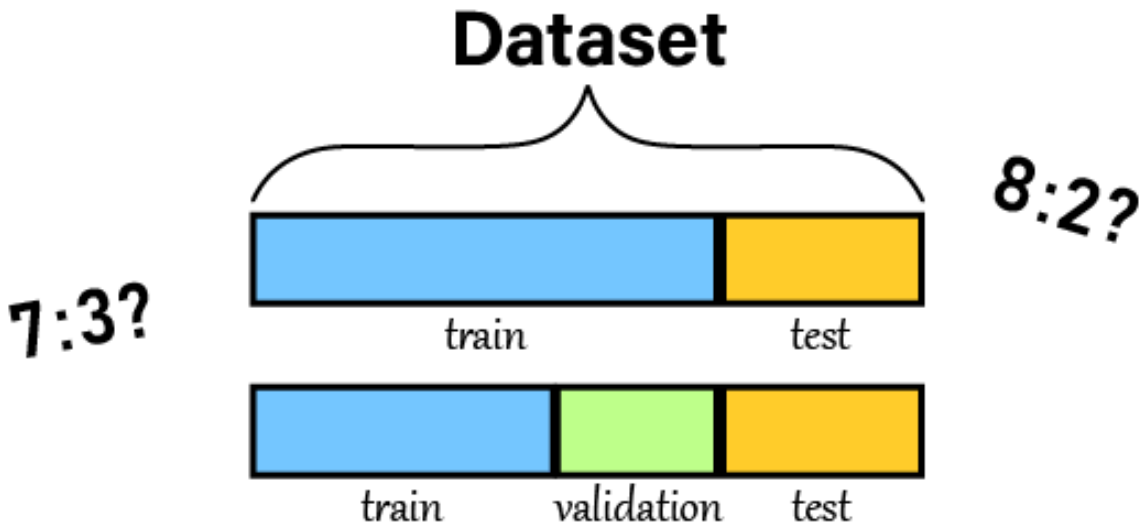
$$H(x) = W * X + b$$

$$cost(W, b) = \frac{1}{m}\sum_{i=1}^{m}\left(H\left(x^{(i)}\right) - y^{(i)}\right)^2$$

2) 머신러닝의 평가

Holdout Test

▶ 모델의 과적합을 막기 위한 방법으로 주어진 데이터를 두 개 이상으로 나누어 학습 및 평가
▶ 두 개로 나누는 경우는 훈련(train)/평가(test) 세트로 분할하며 일반적으로 7:3 또는 8:2로 분할
※ 분할 비율은 정답이 없음
▶ 세 개로 나누는 경우는 훈련(train)/검증(validation)/평가(test) 세트로 분할하며 일반적으로 5:3:2로 분할
▶ 검증 데이터 세트는 반복 학습과 평가를 통한 모델 튜닝에 사용



2) 머신러닝의 평가

Holdout Test 예제 코드

```
1 import pandas as pd
2 from sklearn.model_selection import train_test_split
3
4 df = pd.read_csv("iris.csv")
5 df_train, df_test = train_test_split(df, train_size = 0.7,
6                                       random_state = 123)
```

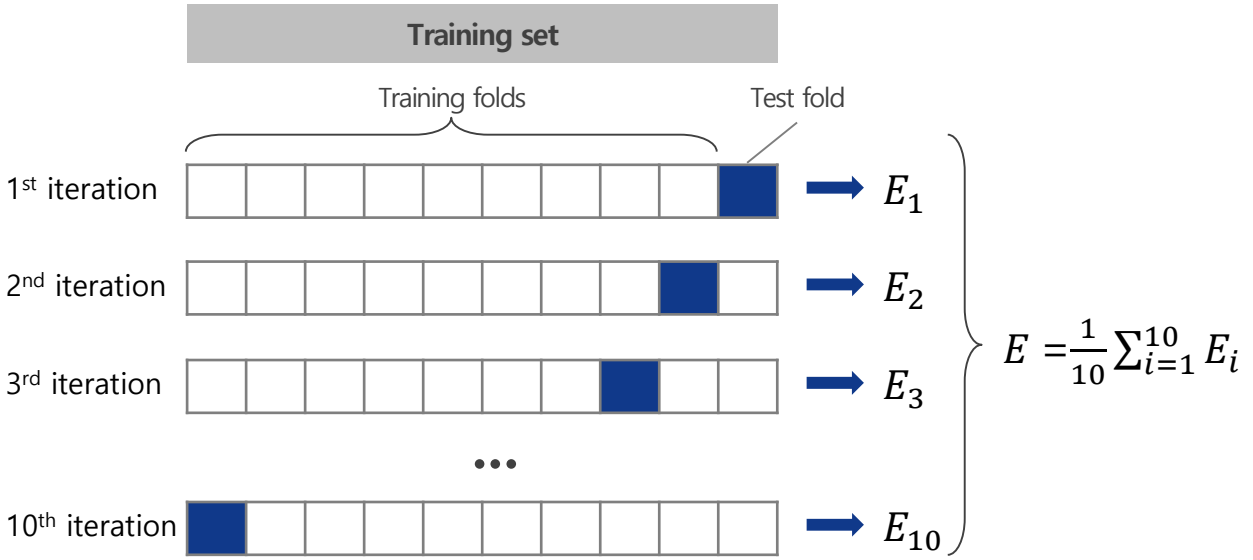
2) 머신러닝의 평가

교차 검증(CV, Cross Validation)

- ▶ 모델의 평균적인 성능을 가늠하기 위해 holdout test를 데이터를 바꿔가며 여러 번 실시하는 것
- ▶ 모델의 하이퍼 파라미터는 고정하고 학습/평가 데이터 세트만 바꿔서 그 결과를 확인하고 결과를 취합
- ▶ 데이터를 10개로 분할하여 교차 검증 하는 경우 10-fold CV 라고 함

※ 일반적으로 데이터를 분할 시 중복되는 데이터가 없도록 비복원 추출 실시

※ Fold 개수가 늘어나면 교차 검증 시간이 늘어남

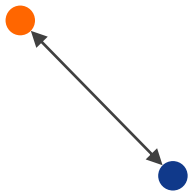


3) 머신러닝 기초 이론

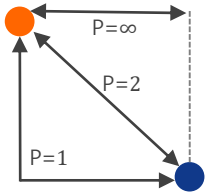
거리 및 유사도 개요

- 자료간 거리를 측정하여 유사도, 동질성 등 판단
- 자료의 특성과 분석의 목적에 맞는 계산법 채택
- 스칼라(scalar)와 벡터(vector)의 구분이 필요

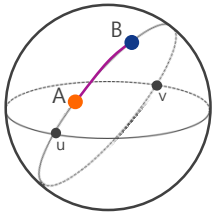
Euclidean



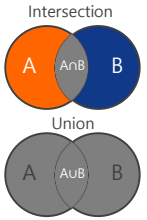
Minkowski



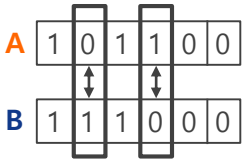
Haversine



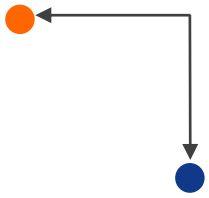
Jaccard



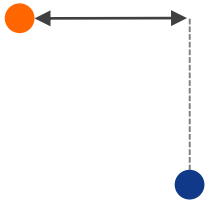
Hamming



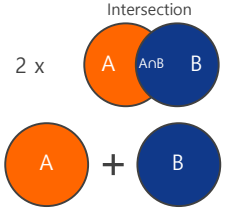
Manhattan



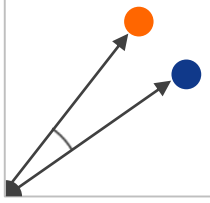
Chebyshev



Sørensen-Dice



Cosine

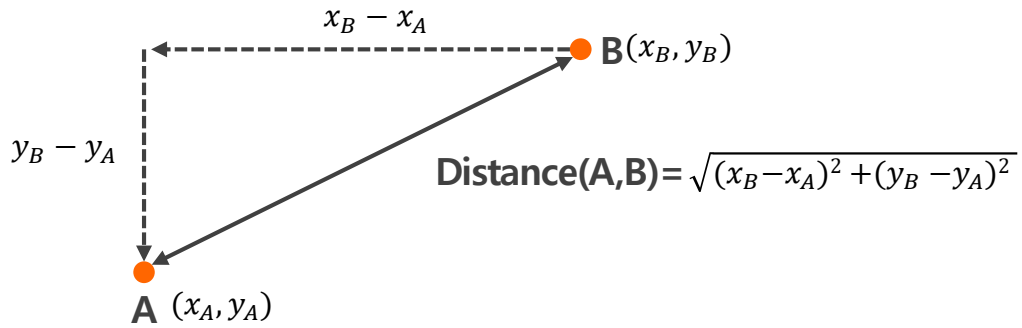


3) 머신러닝 기초 이론

거리 및 유사도 – 유클리드 거리(Euclidean Distance)

- n차원의 공간에서 두 점간의 최단거리를 계산
- 직각삼각형의 빗변 거리 계산식의 일반식

$$d(n,m) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_n - q_n)^2} = \sqrt{\sum_{n=1}^{n}(p_i - q_i)^2}$$



이름	나이	연봉(만원)	경력(년)
김출근	30	5000	5
김퇴근	40	6000	10

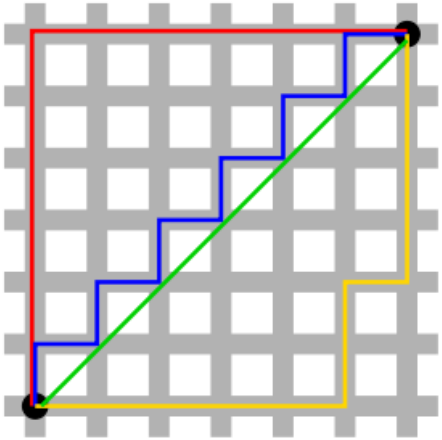
김출근과 김퇴근의 유클리드 거리는 연봉이 영향이 큼

--> 숫자가 크다는 이유로 가중치가 커짐
--> 그래서 데이터 정규화 필요

거리 및 유사도 – 맨하탄 거리(Manhattan Distance)

▶ City Block Distance라고도 하며 두 점 좌표간 절대값 차이 계산

$$d(n,m) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \cdots + |x_{ip} - x_{jp}|$$



https://en.wikipedia.org/wiki/Taxicab_geometry

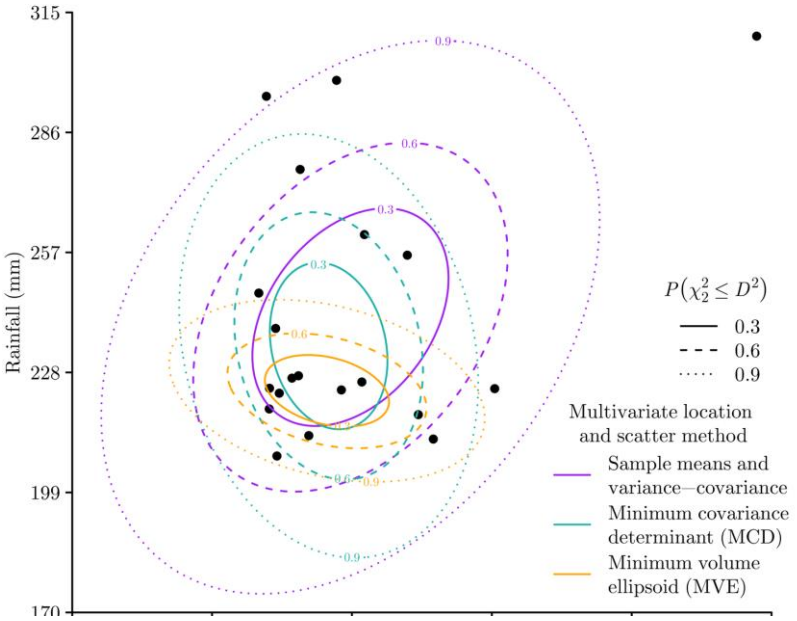
거리 및 유사도 – 마할라노비스 거리(Mahalanobis Distance)

- 각 변수의 분산과 공분산(상관성)구조를 함께 고려한 통계적 거리
- 평균과의 거리가 표준편차의 몇 배인지를 나타내는 값(z-score와 유사)
- 각 변수들의 공분산의 크기에 따라 가중치를 고려하여 거리를 계산
- 공분산 행렬이 정규화 작업을 거쳐 단위행렬이 되는 경우 마할라노비스 거리는 유클리디안 거리와 같음

$$d_M(A,B) = \sqrt{(A-B)\sum^{-1}(A-B)^T}$$

공분산 행렬

※ 행 벡터 기준 수식



https://en.wikipedia.org/wiki/Mahalanobis_distance

거리 및 유사도 – 민코프스키 거리(Minkowski Distance)

- m차원의 민코프스키 공간에서의 거리 — 맨하탄 거리, 유클리드 거리를 하나의 식으로 일반화
- 1-norm의 경우 맨하탄 거리와 같으며 2-norm의 경우 유클리드 거리와 같음
- 민코프스키 승수(r)가 무한대로 발산할 경우 민코프스키 거리는 두 점 사이의 거리 중 최대값이 됨

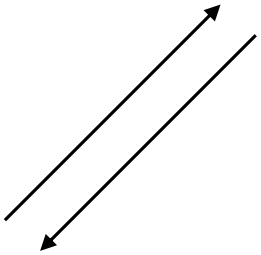
$$d_M(x,y) = \left(\sum_j^m |x_j - y_j|^r \right)^{1/r}$$

$$d_M(x,y) = \lim_{r\to\infty} \left(\sum_j^m |x_j - y_j|^r \right)^{1/r} = \max |x_j - y_j|$$

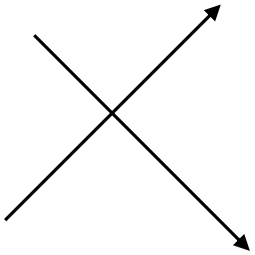
3) 머신러닝 기초 이론

거리 및 유사도 – 코사인 유사도(Cosine Similarity)

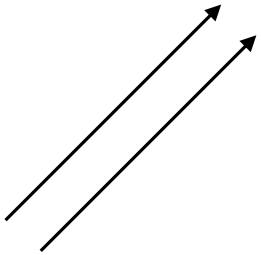
- 내적공간의 두 벡터간 각도의 코사인값을 이용하여 측정된 벡터간의 유사한 정도
- 벡터의 크기가 아닌 방향의 유사도를 판단하는 목적으로 사용
- 두 벡터의 방향이 완전히 같을 경우 1, 90°의 각을 이룰 경우 0, 180°로 완전히 반대 방향인 경우 -1



코사인 유사도 : -1



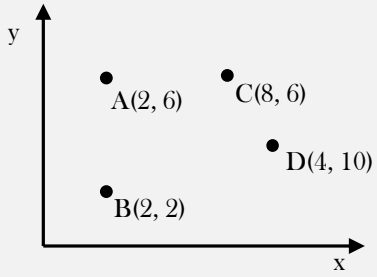
코사인 유사도 : 0



코사인 유사도 : 1

$$similarity = \cos(\theta) = \frac{A \cdot B}{\|A\|\|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n}(A_i)^2} + \sqrt{\sum_{i=1}^{n}(B_i)^2}}$$

Q. 두 벡터간 코사인 유사도가 가장 큰 쌍은?

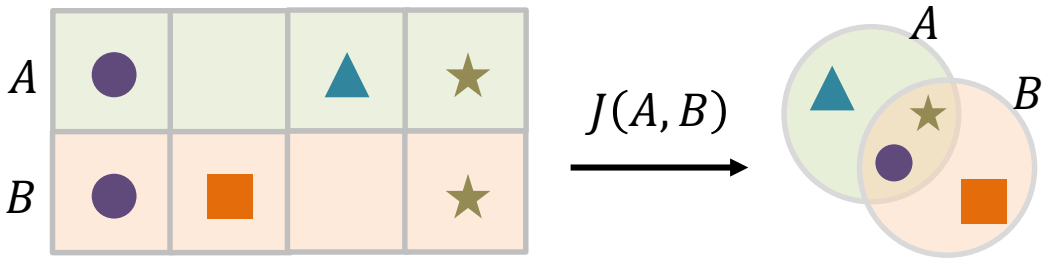


① $\overrightarrow{AB}, \overrightarrow{AC}$
② $\overrightarrow{AC}, \overrightarrow{BD}$
③ $\overrightarrow{DB}, \overrightarrow{AB}$
④ $\overrightarrow{DC}, \overrightarrow{CD}$

3) 머신러닝 기초 이론

거리 및 유사도 – 자카드 유사도(Jaccard Similarity)

- 합집합의 크기와 교집합의 크기를 활용하여 두 집단간 유사도로 판단
- 두 집단의 교집합이 공집합인 경우 0, 동일 집합인 경우 1



$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

3) 머신러닝 기초 이론

관련 함수 및 메서드(scipy > spatial > distance)

함수 및 메서드	설명
euclidean()	유클리드 거리
cityblock()	맨하탄(시티블럭) 거리
cosine()	코사인 유사도
jaccard()	자카드 유사도

3) 머신러닝 기초 이론

euclidean() 예제

```
1 from scipy.spatial.distance import euclidean
2
3 df_vec = pd.DataFrame(dict(vec1 = [1, 2, 3], vec2 = [4, 5, 6]))
4 df_vec
```

	vec1	vec2
0	1	4
1	2	5
2	3	6

```
1 euclidean(df_vec["vec1"], df_vec["vec2"])
```

```
5.196152422706632
```

3) 머신러닝 기초 이론

관련 함수 및 메서드(sklearn > metrics > pairwise)

함수 및 메서드	설명
euclidean_distances()	유클리드 거리
manhattan_distances()	맨하탄(시티블럭) 거리
cosine_similarity()	코사인 유사도

```
from sklearn.metrics.pairwise import euclidean_distances # 시험 버전
```

```
from sklearn.metrics import euclidean_distances # 최신 버전
```

3) 머신러닝 기초 이론

euclidean_distances() 예제

```
1 from sklearn.metrics.pairwise import euclidean_distances
2 df_vec
```

	vec1	vec2
0	1	4
1	2	5
2	3	6

```
1 df_vec_t = df_vec.transpose()
2 df_vec_t
```

	0	1	2
vec1	1	2	3
vec2	4	5	6

```
1 euclidean_distances(df_vec_t)
```

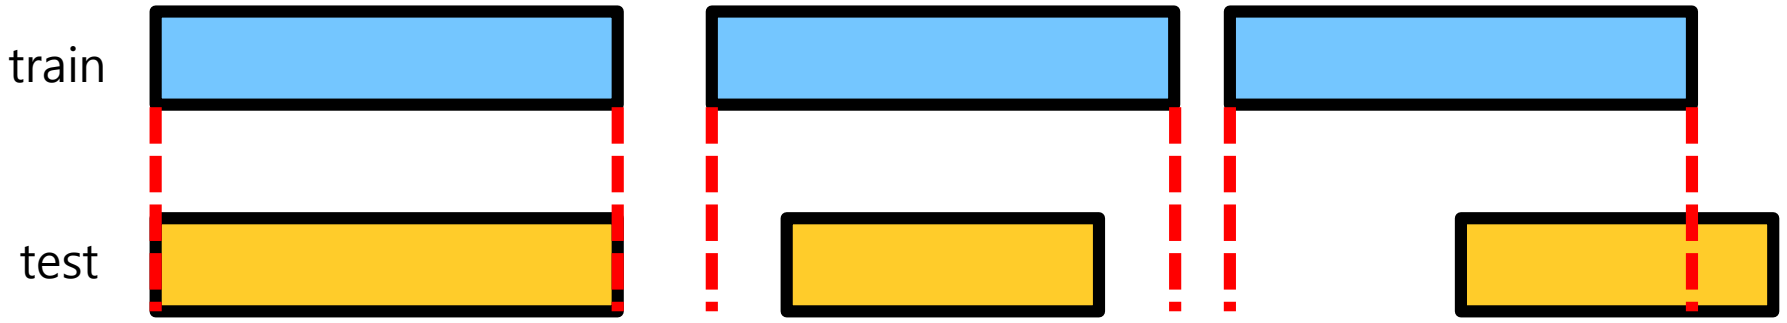
```
array([[0.        , 5.19615242],
       [5.19615242, 0.        ]])
```

3) 머신러닝 기초 이론

머신러닝에서의 정규화(Normalization)

- 거리 계산 알고리즘 사용시 결과 편향을 사전에 예방하기위한 정규화 권장
- 학습 데이터로 학습한 규칙을 기반으로 평가 데이터 세트를 정규화 함
- 학습 데이터와 평가 데이터 세트를 한 번에 정규화 하지 않도록 주의(Data Leakage 문제)

학습, 평가 데이터세트 범위에 따른 정규화



3) 머신러닝 기초 이론

관련 메서드 및 클래스(sklearn > preprocessing)

메서드 및 클래스	설명
MinMaxScaler()	Min-Max Scaling, [0, 1]
StandardScaler()	표준화
.fit()	모델 학습
.transform()	학습된 모델을 기반으로 신규 데이터 변환
.fit_transform()	모델 학습과 변환을 동시에 실시
.inverse_transform()	역변환을 지원하는 메서드

3) 머신러닝 기초 이론

부트스트랩(Bootstrap)

▶ 복원 추출을 허용하는 단순 임의 표본추출로 학습 데이터의 크기를 늘리는 효과 기대

▶ 데이터(특히 종속변수) 불균형인 경우(imbalanced data) 이를 맞춰주기 위해 사용될 수 있음

※ Undersampling, Oversampling

▶ 부트스트랩으로 추출되지 않은 데이터를 OOB(Out Of Bag) 표본이라 하며 데이터가 충분히 클 때 약 36.8% 임

OOB(Out Of Bag) 표본 비율 계산

▶ 부트스트랩 표본의 크기가 n일 때 한 번의 표본 추출과정에서 어떤 표본 하나가 추출되지 않을 확률은 (n-1)/n 임

$$\lim_{n\to\infty}\left(1-\frac{1}{n}\right)^{n} = e^{-1} = 0.368$$

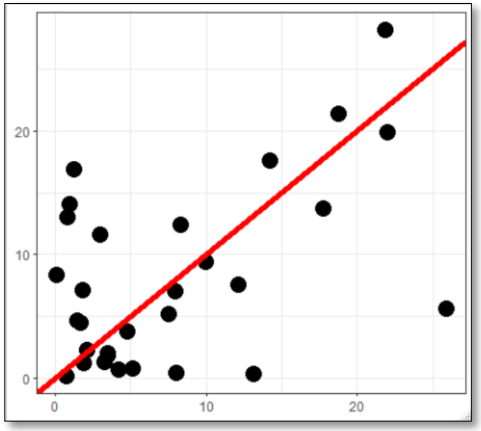
4) 지도학습 – 선형 회귀 분석

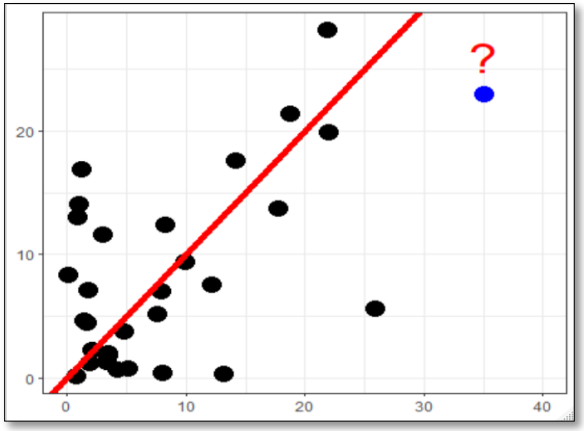
선형 회귀(Linear Regression)

- 일반화 선형 모형(GLM)중 하나 이며, 종속변수가 수치형 자료인 경우 우선적으로 고려하는 모형
- 보통 다중 선형 회귀(Multiple Linear Regression)을 칭하며, 독립변수가 하나인 경우는 단순 선형 회귀이다.

지도학습에서의 예측 – 선형 회귀

- 모델 학습과 평가를 위해 두 개 이상의 데이터 세트로 분할하여 모델 생성
- 과적합 방지를 위하여 주어진 데이터 전체를 활용한 모델 생성 지양
- 모델 생성시 사용된 독립변수의 범위를 벗어나는 값이 입력될 경우 예측값의 신뢰가 어려울 수 있음





4) 지도학습 – 선형 회귀 분석

회귀 분석의 가정

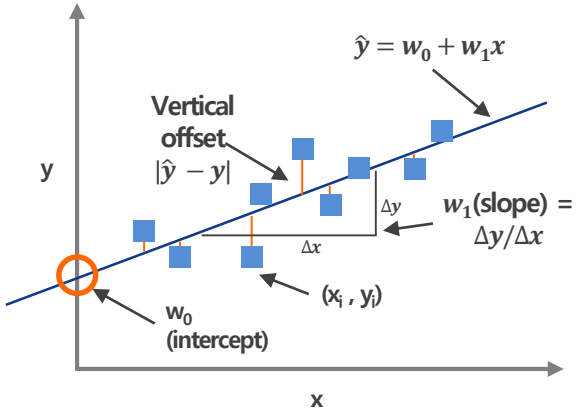
▶ 선형성
- 독립변수와 종속변수는 선형(linear) 관계
- 응답 변수가 예측 변수와 선형 회귀 계수의 선형 조합으로 표현 가능함을 의미

▶ 잔차(residual)의 정규성(Normality)

▶ 잔차(residual)의 등분산(homoscedasticity)
- 관측치와 추정치 사이의 차이인 잔차가 일정한 분산을 가짐

▶ 잔차(residual)의 독립성
- 추정된 잔차는 서로 독립(independent, 서로 무관함)

회귀 모델의 추정 – OLS(Ordinary Least Squares, 최소 제곱법)



$$\sum_{i=1}^{n} \left(y_i - f(x_i)\right)^2$$

4) 지도학습 – 선형 회귀 분석

단순 선형회귀 모델의 수식과 평가 지표

모델 수식

▶ 선형 가법 관계인 경우

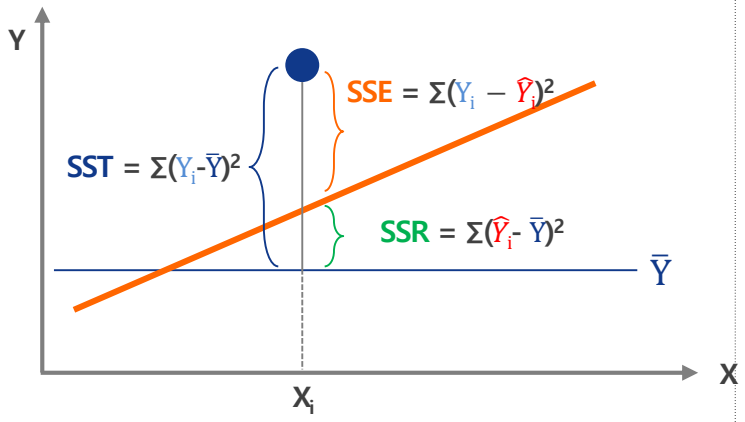
$$\underbrace{\hat{Y}}_{\text{종속변수}} = \beta_o + \beta_1 \underbrace{x_1}_{\text{독립변수}}$$

결정계수(R^2, coefficient of determination, 설명력)

▶ R^2는 총변동(SST, Sum of Squares Total)에서 설명된 부분(SSR, Regression Sum of Squares)이 얼마나 차지하는지 나타내는 값

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (0 \le R^2 \le 1)$$

$\sum_{i=1}^{n}(y_i - \bar{y})^2$: SST
$\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$: SSR
$\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$: SSE



ⓒ 2003 Prentice-Hall, Inc. Business Statistics Chap. 10-22

4) 지도학습 – 선형 회귀 분석

선형회귀 모델구현 클래스

statsmodels - ols()

- 선형회귀 분석을 위한 statsmodels의 클래스
- ols() 클래스 내에 종속변수와 독립변수를 선언
- ols() 클래스의 fit() 메서드로 모델 적합
- 변수명에 온점 등 특정 특수문자가 있는 경우 오류 발생
- 모델 객체의 predict() 메서드로 예측
- OLS() 클래스도 있음

sklearn - LinearRegression()

- 선형회귀 분석을 위한 sklearn의 클래스
- LinearRegression() 클래스 내 fit_intercept로 절편 적합 여부 설정 가능
- LinearRegression() 클래스의 fit() 메서드에 학습 데이터 할당 가능
- 모델 객체의 coef_ 와 intercept_ 어트리뷰트로 각각 계수와 절편 확인 가능
- 모델 객체의 predict() 메서드로 예측

4) 지도학습 – 선형 회귀 분석

메서드 및 클래스(statsmodels > formula > api)

메서드 및 클래스	설명
ols()	선형 회귀
.fit()	모델 학습하며 학습 데이터 입력
.summary()	회귀 분석 레포트 출력
.params	모델객체에서 회귀 계수 및 절편 추출
.resid	잔차 추출

4) 지도학습 – 선형 회귀 분석

관련 메서드 및 클래스(sklearn > linear_model)

메서드 및 클래스	설명
LinearRegression()	선형 회귀
.fit()	모델 학습하며 학습 데이터 입력
.coef_	모델객체에서 회귀 계수 추출
.intercept_	모델객체에서 절편 추출

4) 지도학습 – 선형 회귀 분석

라이브러리 및 데이터 준비

```
from statsmodels.formula.api import ols
from statsmodels.api import OLS
from sklearn.linear_model import LinearRegression
```

```
df_train = pd.DataFrame(dict(y = [1, 2, 3], x1 = [4, 5, 6], x2 = [7, 8, 9]))
df_train
```

	y	x1	x2
0	1	4	7
1	2	5	8
2	3	6	9

```
df_test = pd.DataFrame(dict(y = [10, 11], x1 = [12, 13], x2 = [14, 15]))
df_test
```

	y	x1	x2
0	10	12	14
1	11	13	15

4) 지도학습 – 선형 회귀 분석

ols() 예제

```
1 model_1 = ols(formula = "y ~ x1 + x2", data = df_train).fit()
2 model_1.predict(df_test)
```

```
0     9.727273
1    10.727273
dtype: float64
```

```
1 model_1.params
```

```
Intercept   -0.818182
x1           1.727273
x2          -0.727273
dtype: float64
```

```
1 model_1.rsquared, model_1.rsquared_adj
```

```
(1.0, 1.0)
```

4) 지도학습 – 선형 회귀 분석

OLS() 예제

```
model_2 = OLS(exog = df_train[["x1", "x2"]],
              endog = df_train["y"]).fit()
model_2.predict(df_test[["x1", "x2"]])
```

```
0    10.0
1    11.0
dtype: float64
```

```
model_2.params
```

```
x1     2.0
x2    -1.0
dtype: float64
```

```
model_2.rsquared, model_2.rsquared_adj
```

```
(1.0, 1.0)
```

4) 지도학습 – 선형 회귀 분석

LinearRegression() 예제

```
model_3 = LinearRegression(fit_intercept = True)
model_3.fit(X = df_train.drop(columns = "y"),
            y = df_train["y"])
model_3.predict(df_test)
```

```
array([8.5, 9.5])
```

```
model_3.coef_
```

```
array([0. , 0.5, 0.5])
```

4) 지도학습 – 선형 회귀 분석

단순 선형회귀 모델의 해석 및 평가

$$\hat{y} = 0.9909 + 0.3732x$$

OLS Regression Results

Dep. Variable:	y	R-squared:	0.129
Model:	OLS	Adj. R-squared:	0.089
Method:	Least Squares	F-statistic:	3.257
Date:	Fri, 22 Jul 2022	Prob (F-statistic):	0.0848
Time:	12:24:22	Log-Likelihood:	-53.868
No. Observations:	24	AIC:	111.7
Df Residuals:	22	BIC:	114.1
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	0.9909	0.908	1.091	0.287	-0.893	2.875
x	0.3732	0.207	1.805	0.085	-0.056	0.802

Omnibus:	3.957	Durbin-Watson:	0.999
Prob(Omnibus):	0.138	Jarque-Bera (JB):	1.902
Skew:	0.380	Prob(JB):	0.386
Kurtosis:	1.849	Cond. No.	8.50

4) 지도학습 – 선형 회귀 분석

다중 선형회귀 모델의 수식과 평가 지표

모델 수식

▶ 선형 가법 관계인 경우

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k$$

종속변수 독립변수

수정된 결정계수(R^2_{adj}, adjusted coefficient of determination)

▶ 변수와 데이터 개수를 반영한 결정계수

▶ 결정계수보다 값이 조금 작게 나오며 결정계수 값이 작은 경우 값이 음수가 나오기도 한다.

※ n: 데이터 개수, k: 독립변수 개수

$$R^2_{adj} = 1 - \frac{SSE/(n-k)}{SST/(n-1)} \quad (R^2_{adj} < R^2)$$

4) 지도학습 – 선형 회귀 분석

모델링 예제 코드

```
1  import pandas as pd
2  from statsmodels.formula.api import ols
3
4  df = pd.read_csv("bike.csv")
5  df_model = df.loc[:, "temp":"casual"]
6
7  formula = "casual ~ temp + atemp + humidity + windspeed"
8  model = ols(formula = formula, data = df_model).fit()
9  print(model.summary())
```

4) 지도학습 – 선형 회귀 분석

다중 선형회귀 모델의 해석 및 평가

OLS Regression Results

Dep. Variable:	casual	R-squared:	0.322
Model:	OLS	Adj. R-squared:	0.322
Method:	Least Squares	F-statistic:	1293.
Date:	Fri, 22 Jul 2022	Prob (F-statistic):	0.00
Time:	12:42:16	Log-Likelihood:	-55907.
No. Observations:	10886	AIC:	1.118e+05
Df Residuals:	10881	BIC:	1.119e+05
Df Model:	4		
Covariance Type:	nonrobust		

신뢰 하한 / 신뢰 상한

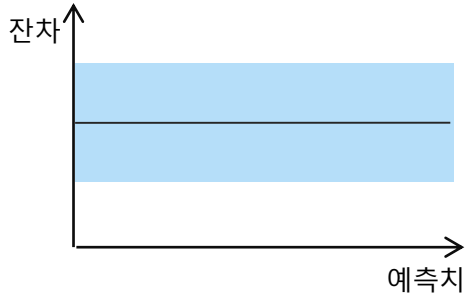
	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	25.6486	2.155	11.903	0.000	21.425	29.872
temp	0.9665	0.301	3.211	0.001	0.377	1.557
atemp	1.7693	0.277	6.388	0.000	1.226	2.312
humidity	-0.8367	0.022	-38.554	0.000	-0.879	-0.794
windspeed	0.0583	0.052	1.119	0.263	-0.044	0.160

$$\hat{y} = 25.6486 + 0.9665x_{temp} + 1.7693x_{atemp} - 0.8367x_{humidity} + 0.0583x_{windspeed}$$

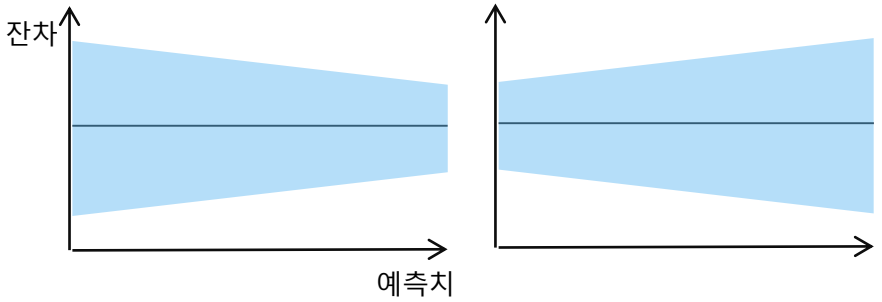
4) 지도학습 – 선형 회귀 분석

잔차 분석

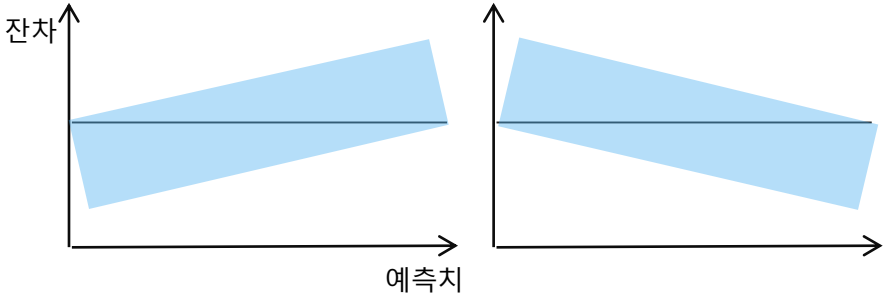
- 생성한 회귀모델의 잔차를 활용하여 회귀모델 해석 및 개선여부 결정
- 정규성, 등분산성 등 잔차의 가정을 다양한 방법으로 확인
- 등분산-사다리꼴, 신규 설명변수-치우침, 2차항-오목/볼록



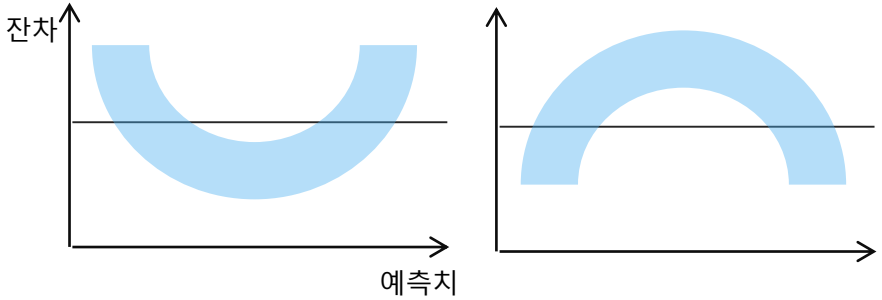
랜덤 → 이상 없음



등분산 가정을 만족하지 못함



새로운 설명변수 필요



설명변수 2차항 필요

4) 지도학습 – 선형 회귀 분석

다중 공선성의 개요 및 확인

▶ 다중 공선성(Multicollinearity)은 회귀 모델의 독립변수간 강한 상관관계가 나타나는 것
▶ 다중 공선성의 문제가 있을 경우 회귀 계수의 분산을 증가시켜 불안정하고 해석하기 어렵게 만듦
▶ 독립변수가 상관관계에 있는 경우 추정된 회귀 계수의 분산이 증가하는 정도를 측정하는 VIF값 확인 필요
▶ 분산 팽창 계수(VIF, Variation Inflation Factor)는 분산 확대 인자, 분산 팽창 요인 등으로 불림
▶ VIF값은 각 변수마다 산출할 수 있으며 일반적으로 10을 초과하는 경우 다중공선성의 문제가 있다고 함
※ 10은 절대적인 기준이 아니며 3 또는 4를 사용하기도 함
▶ VIF는 결정계수를 이용하여 산출하기 때문에 최소값이 1, 최대값이 무한대이다.
▶ 특정 통계 레포트에서 단 하나의 VIF값이 표기되는 경우가 있는데 보통 VIF값 중 최대값을 의미

$$VIF_i = \frac{1}{1 - R_i^2}$$

※ VIF_i : i번째 변수의 분산 팽창 계수

독립변수들끼리 서로 강하게 상관관계가 있을 때,
회귀모델은 각 변수의 독립적인 영향력을 계수로 나타내는데,
변수들이 서로 엮여있으면 "이 효과가 A 때문인지 B 때문인지" 구분을 못해요.

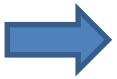
4) 지도학습 – 선형 회귀 분석

다중 공선성 문제의 해결

▶ 다중공선성 문제를 해결하는 방법은 다양하지만 다중공선성의 문제가 되는 변수 제거가 가장 간단
▶ VIF값이 지정 임계치 이상이 되는 경우 해당 임계치를 초과하는 대상 독립변수를 한 번에 모두 제거 지양
▶ 분석가의 주관에 의해 다중공선성 문제가 있는 독립 변수를 하나씩 제거 권장
※ VIF가 큰 변수, 해석이 어려운 변수, 확보에 비용이 많이 드는 변수 등 논리적 근거와 주관 기반 처리
▶ 다중공선성 문제가 있는 독립변수를 제거하는 경우 일반적으로 VIF값들이 일괄 감소

최초 모델

독립변수	VIF
A	1.65
B	11.78
C	11.81
D	4.36



C 제거

독립변수	VIF
A	1.59
B	2.42
D	4.33

4) 지도학습 – 선형 회귀 분석

다중 공선성 확인 관련 함수

patsy - dmatrices()

- 수식을 기반으로 데이터 행렬을 생성하는 pasty의 함수
- 분산 팽창 계수 확인을 위해 입력 데이터를 전처리 할 때 필요한 함수
- return_type 인자에 “dataframe” 으로 설정 시 후처리 용이

statsmodels - variance_inflation_factor()

- 분산 팽창 계수를 연산하기 위한 statsmodels 함수
- 분산 팽창 계수 연산을 위해 반복문 또는 list comprehension 사용

4) 지도학습 – 선형 회귀 분석

별로 안 중요하다는 듯이 말하심

VIF 계산 예제 코드

```
1  import pandas as pd
2  from patsy import dmatrices
3  from statsmodels.formula.api import ols
4  from statsmodels.stats.outliers_influence import variance_inflation_factor as vif
5
6  df = pd.read_csv("bike.csv")
7  df_model = df.loc[:, "temp":"casual"]
8
9  y, X = dmatrices("casual ~ temp + atemp + humidity + windspeed",
10                  df_model, return_type = "dataframe")
11
12 vif = pd.DataFrame()
13 vif["VIF Factor"] = [vif(X.values, i) for i in range(X.shape[1])]
14 vif["features"] = X.columns
```

4) 지도학습 – 선형 회귀 분석

너무 마이너한 지표라고..

정보량 규준(information criterion) - AIC

▶ AIC(Akaike Information Criterion): 최소의 정보 손실을 갖는 모델이 가장 데이터와 적합만 모델로 선택하는 방법
▶ 값이 작을수록 좋음

$$AIC = -2\log(\hat{L}) + 2p$$

적합성 간결성

$$\hat{L} = p(x \mid \hat{\theta}, M) = \frac{SSR}{n}$$

p: 변수(파라미터) 개수, n: 데이터 개수, $\hat{L}$: 우도(likelihood, 모형 적합도)

정보량 규준(information criterion) - BIC

▶ BIC(Bayesian Information Criterion): 표본이 커질 때 부정확해지는 AIC를 개선한 지표
▶ AIC 대비 BIC는 변수 개수를 줄이는 것에 더 큰 중점을 두는 지표
▶ 값이 작을수록 좋음

$$BIC = -2\log(\hat{L}) + plog(n)$$

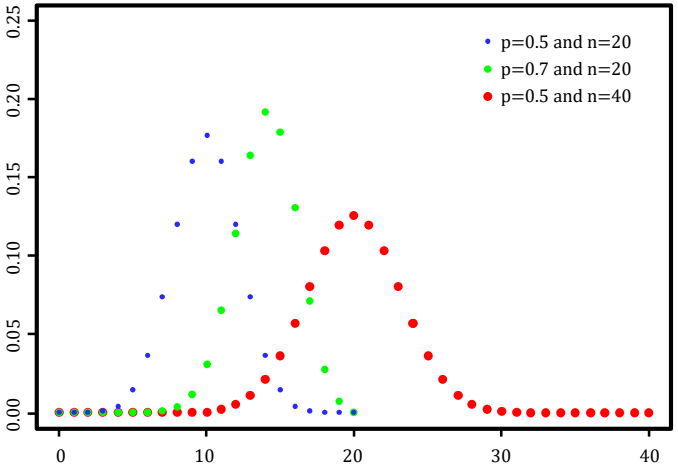
p: 변수(파라미터) 개수, n: 데이터 개수

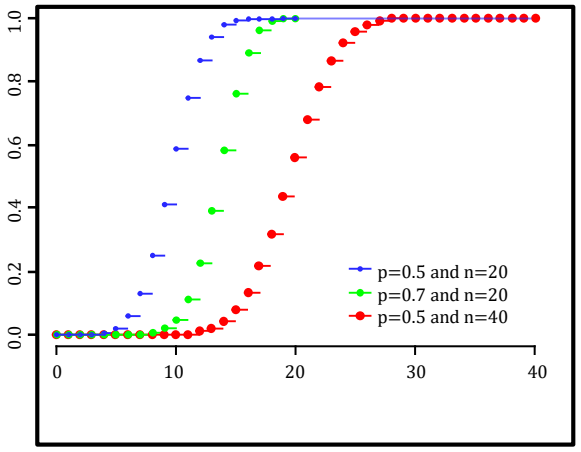
5) 지도학습 – 로지스틱 회귀 분석

로지스틱 회귀(Logistic Regression)

- 일반화 선형 모형(GLM)중 하나 이며, 종속변수가 범주형 자료인 경우 사용 가능한 모형
- 보통 이항(binomial) 로지스틱 회귀를 지칭하며, 서수(ordinal) 로지스틱, 다항(multinominal) 로지스틱 존재
- 종속변수는 2가지 범주를 가짐
  ※ 제품 구매 여부(구매/비구매), 사기 거래 여부(사기 거래/정상 거래) 등
- 모델을 거쳐 나온 종속 변수의 예측 값은 0에서 1 사이의 확률 값이며 이를 이진 값으로 변환해야 함
- 종속변수의 확률분포는 베르누이(Bernoulli) 분포를 따름

$$f_i(y) = P\{Y_i = y\} = P_i^y(1-P_i)^{1-y}, \qquad y = 0, 1$$





5) 지도학습 – 로지스틱 회귀 분석

로지스틱 회귀(Logistic Regression)

▶ 이항 로지스틱 회귀 모델에 test 데이터를 넣게 되면 데이터 포인트(data point) 당 1개의 확률 값이 산출됨

▶ 분류를 위해 산출된 확률 값을 문턱값(threshold)을 기준으로 이진값으로 변환

※ 문턱값은 경계값(cut-off value)라고도 함

▶ 문턱값은 기본적으로 0.5를 기준으로 하며 필요시 이를 조정하여 확률 값에 따른 이진(분류)값을 산출

threshold를 바꾸더라도 AUC는 변하지 않는다 (?)

문턱값이 0.5인 경우

p	y_hat
0.3	0
0.15	0
0.78	1
0.9	1

문턱값이 0.8인 경우

p	y_hat
0.3	0
0.15	0
0.78	0
0.9	1

5) 지도학습 – 로지스틱 회귀 분석

로지스틱 회귀모델의 수식

▶ 이항 로지스틱 모형은 종속 변수를 직접적으로 설명하는 것이 아님(정확한 예측 값 산출이 아님)

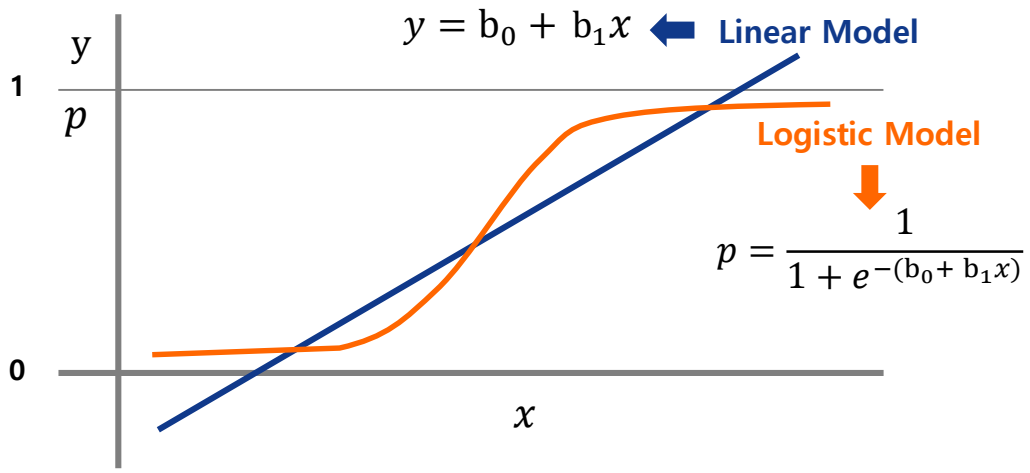
▶ 모형의 산출 값이 선형이라고 가정

$$y = \beta_0 + \sum \beta_i X_i \;\; i = 1, \ldots, n$$

※ 독립변수 X가 n개 있는 경우

▶ 위 모형(선형확률모형, linear probability model)의 단점을 보완하기 위하여 로짓 변환 실시

※ 로짓 변환(logit transformation): 승산(odds)에 로그를 취함



로지스틱 함수(logistic function)

$$y(t) = \frac{1}{1 + e^{-t}}$$

5) 지도학습 – 로지스틱 회귀 분석

로지스틱 회귀모델 관련 이론

승산(Odds)

▶ 집단 1에 속하는 확률에서 집단 0에 속하는 확률을 나눈 비율
▶ 축구 경기의 경우 이길 확률(P)을 질 확률(1-P)로 나눈 값

$$Odds = \frac{p}{1-p}$$

로짓(Logit)

▶ 승산(Odds)에 자연로그를 취한 것

$$logit = \log(Odds) = \log(\frac{p}{1-p})$$

5) 지도학습 – 로지스틱 회귀 분석

로지스틱 회귀모델 관련 이론

승산비(OR, Odds Ratio)

- 나머지 변수는 모두 고정시킨 상태에서 x_i를 1만큼 증가시 승산(Odds)의 변화 비율
- 승산비가 1보다 크면 독립변수의 값이 증가할수록 종속변수의 값이 1이 될 확률(사건 발생 확률)이 증가
- 승산비가 1보다 작으면 독립변수의 값이 증가할수록 종속변수의 값이 1이 될 확률(사건 발생 확률)이 감소
- 승산비가 1.5인 경우 종속변수의 값이 1이 될 확률이 약 1.5배 증가한다고 할 수 있다.
- 승산비가 1인 경우 계수가 0이라는 의미이기 때문에 해당 독립변수는 종속변수와 무관하다고 할 수 있다.
- 승산비 계산을 위해서는 np.exp() 함수 필요

$$\frac{odds(x_1,\ldots,x_i+1,\ldots x_n)}{odds(x_1,\ldots,x_i,\ldots x_n)} = \frac{e^{\beta_1+\beta_1 x_1,\ldots.+\beta_i(x_i+1)+\ldots+\beta_n x_n}}{e^{\beta_1+\beta_1 x_1,\ldots.+\beta_i x_i+\ldots+\beta_n x_n}} = e^{\beta_i}$$

※β_i: i번째 독립변수의 회귀계수

5) 지도학습 – 로지스틱 회귀 분석

로지스틱 회귀모델 관련 클래스

statsmodels - Logit()

- 로지스틱 회귀분석을 실시하는 statsmodels의 클래스
- endog, exog 인자에 각각 종속변수와 독립변수를 할당
- 산출 모델 객체의 params 어트리뷰트에 모델의 회귀계수 확인 가능
- 모델 객체의 .predict() 또는 .predict_proba() 메서드로 분류 결과 또는 예측 확률값을 생산

sklearn - LogisticRegression()

- 로지스틱 회귀분석을 실시하는 sklearn의 클래스
- fit_intercept, solver 인자로 절편 적합 여부 및 최적화 알고리즘 설정 가능
- random_state 인자에 자연수를 할당하여 결과 고정 가능
- fit() 메서드에 독립변수 및 종속변수 할당
- 산출 모델 객체의 coef_ 어트리뷰트에서 모델의 회귀계수 확인 가능
- 모델 객체의 .predict() 또는 .predict_proba() 메서드로 분류 결과 또는 예측 확률값을 생산

5) 지도학습 – 로지스틱 회귀 분석

관련 메서드 및 클래스(statsmodels > api)

메서드 및 클래스	설명
Logit()	로지스틱 회귀
.fit()	모델 학습하며 학습 데이터 입력
.summary()	회귀 분석 레포트 출력
.params	모델객체에서 회귀 계수 및 절편 추출

※ 최신 버전은 **from** statsmodels.discrete.discrete_model **import** Logit

관련 메서드 및 클래스(sklearn > linear_model)

메서드 및 클래스	설명
LogisticRegression()	로지스틱 회귀
.fit()	모델 학습하며 학습 데이터 입력
.coef_	모델객체에서 회귀 계수 추출

5) 지도학습 – 로지스틱 회귀 분석

모델링 예제 코드(statsmodels)

```
import pandas as pd
from statsmodels.api import Logit

df = pd.read_csv("logistic_regression_01.csv")
df_dum = pd.get_dummies(data = df, columns = ["rank"],
                        drop_first = True)

model = Logit(endog = df_dum["admit"],
              exog = df_dum.drop("admit", axis = 1),
              data = df_dum)

result = model.fit()
result.summary()
```

5) 지도학습 – 로지스틱 회귀 분석

모델링 예제 코드(sklearn)

```
import pandas as pd
from sklearn.linear_model import LogisticRegression

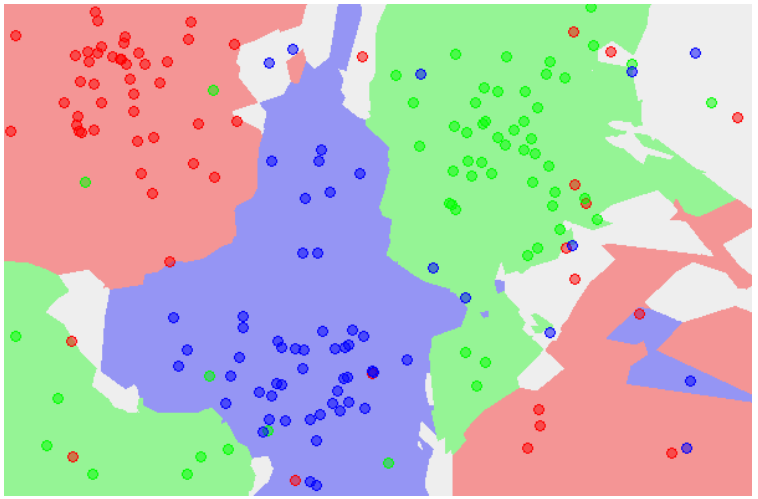
df = pd.read_csv("logistic_regression_01.csv")
df_dum = pd.get_dummies(data = df, columns = ["rank"],
                        drop_first = True)

model = LogisticRegression()
model.fit(X = df_dum.drop("admit", axis = 1),
          y = df_dum["admit"])
```

6) 지도학습 – k-NN

k-NN(k-Nearest Neighbor, k-최근접 이웃) 거리기반 알고리즘

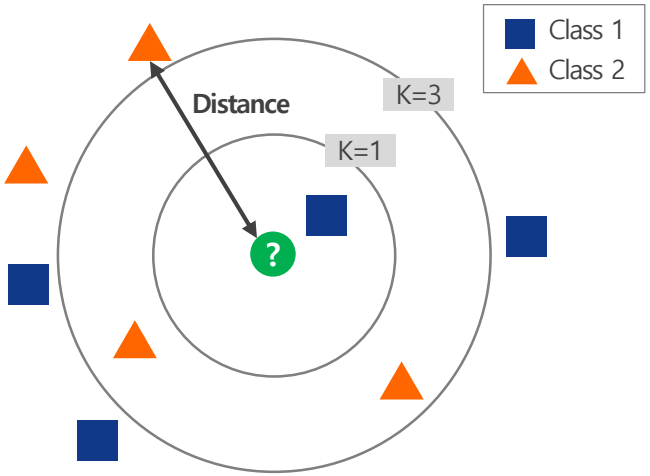
- 특정 데이터를 k개의 인접한 데이터 포인트를 기반으로 예측 하는 지도학습 알고리즘
- 인접 데이터 포인트는 독립변수를 활용하여 판별
- 종속변수에 따라 분류 모델과 회귀 모델로 나뉨
- k 값이 1에 가까우면 과적합이 되며, 값이 커질수록 과소적합이 되기에 적절한 k 값을 선택해야 한다.
- 거리기반 알고리즘이기 때문에 각 변수의 단위 및 정규화에 유의
- 근처 인접한 k개의 데이터만 고려하기 때문에 지역적 구조에 민감함
- 평가 데이터세트가 인입되기 전에 train data set를 사용한 모델 학습이 없음

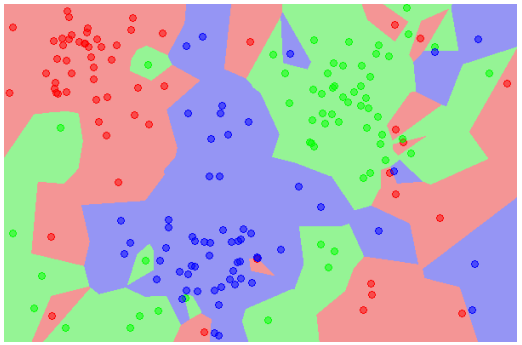


6) 지도학습 – k-NN

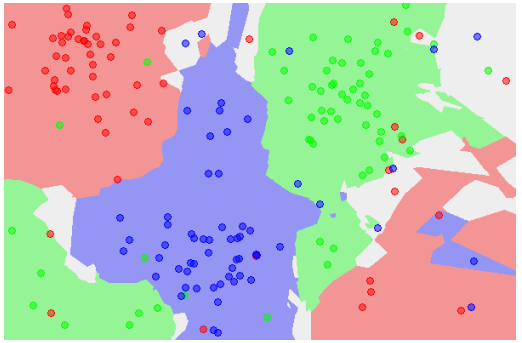
k-NN 분류(Classification)

- 새로운 값은 기존의 데이터를 기준으로 가장 가까운 k개의 최근접 값을 기준으로 분류됨
- 이진 분류시 k 값을 짝수로 지정하는 경우 그 분류가 제대로 되지 않을 수 있기에 홀수로 지정





k = 1



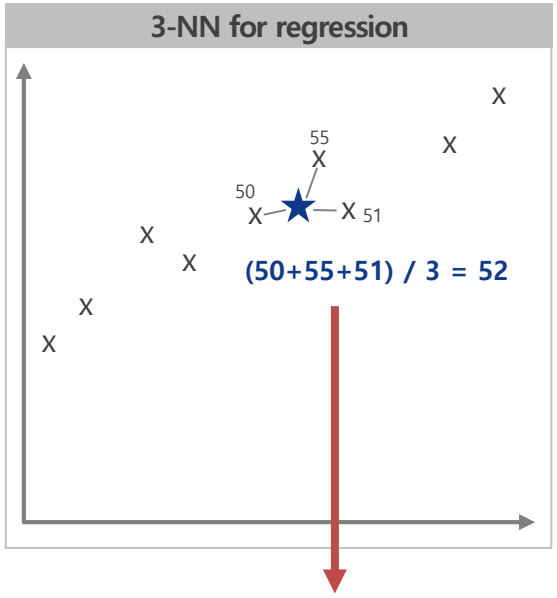
k = 5

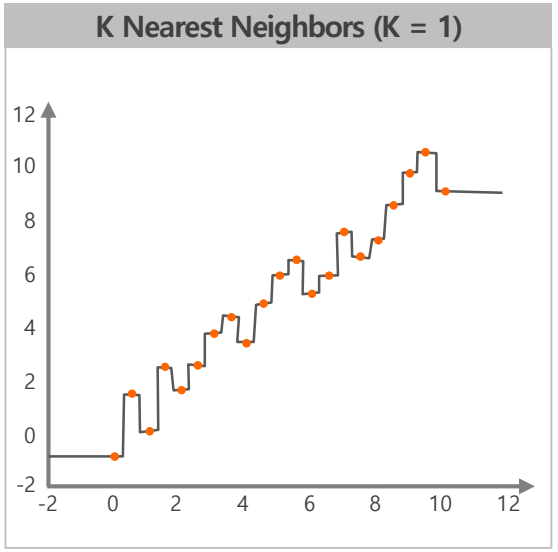
https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm

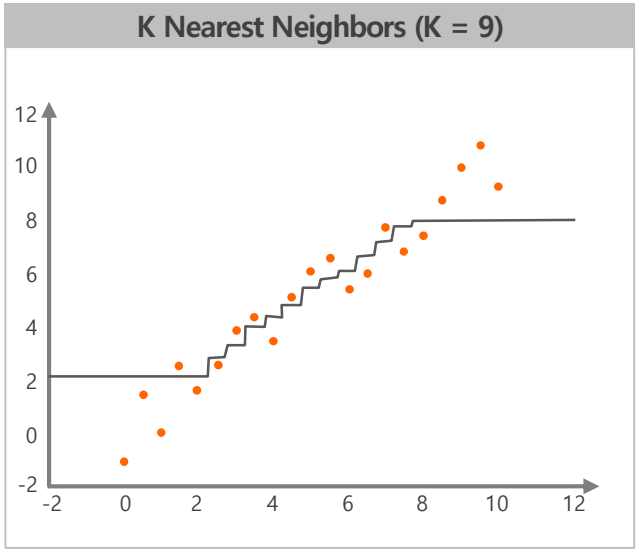
6) 지도학습 – k-NN

k-NN 회귀(Regression)

▶ 기본 개념은 분류모델과 같으며 k개의 인접한 자료의 (가중)평균으로 예측







A: 너네 저번에 시험 공부 20시간 정도 했다며? 시험 점수 얼마나 나왔어?
B: 난 50, C: 난 55, D: 난 51
A: ??? 나 이번에 20시간 했는데 그럼 나도 떨어지는거야???

6) 지도학습 – k-NN

관련 클래스

sklearn - KNeighborsClassifier()

- KNN 분류 모델을 학습하기 위한 sklearn의 클래스
- n_neighbors 인자에 학습시 고려할 이웃 데이터의 개수를 지정
- n_neighbors가 1에 가까울수록 과적합 되며 커질수록 과소적합 되는 경향 존재
- KNeighborsClassifier() 클래스의 fit() 메서드에 독립변수와 종속변수 할당
- 모델 객체의 .predict() 또는 .predict_proba() 메서드로 분류 결과 또는 예측 확률값을 생산

sklearn - KNeighborsRegressor()

- KNN 회귀 모델을 학습하기 위한 sklearn의 클래스
- n_neighbors 인자에 학습시 고려할 이웃 데이터의 개수를 지정
- n_neighbors가 1에 가까울수록 과적합 되며 커질수록 과소적합 되는 경향 존재
- KNeighborsClassifier() 클래스의 fit() 메서드에 독립변수와 종속변수 할당

6) 지도학습 – k-NN

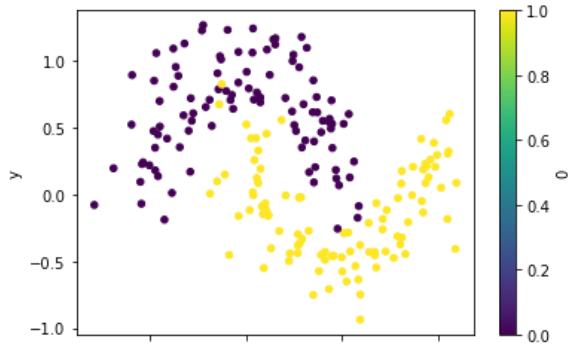
관련 클래스(sklearn > neighbors)

클래스	설명
KNeighborsClassifier()	k-NN 분류 모델
KNeighborsRegressor()	k-NN 회귀 모델

6) 지도학습 – k-NN

모델링 예제 코드(분류)

```
import pandas as pd
from sklearn.datasets import make_moons
X, Y = make_moons(n_samples = 200, noise = 0.2,
                  random_state = 123)
df_moon = pd.concat([pd.DataFrame(X, columns=["x", "y"]),
                     pd.Series(Y)], axis = 1)
df_moon.plot.scatter(x = "x", y = "y", c = 0,
                     colormap = "viridis")
```



6) 지도학습 – k-NN

모델링 예제 코드(분류)

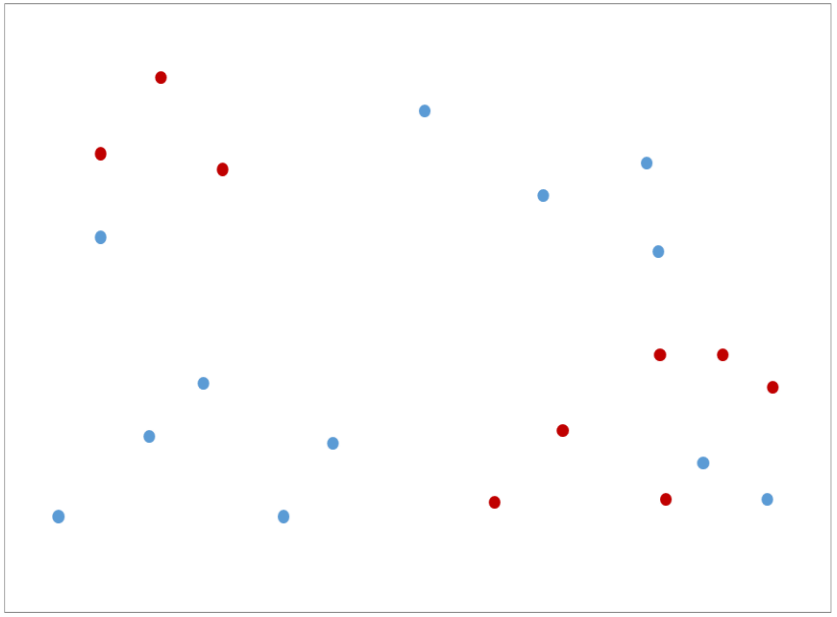
```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

X_tr, X_te, Y_tr, Y_te = train_test_split(X, Y,
                                          test_size = 0.3,
                                          random_state = 12)
model = KNeighborsClassifier(n_neighbors = 5)
model.fit(X = X_tr, y = Y_tr)
y_pred = model.predict(X_te)
accuracy_score(y_pred, Y_te)
```

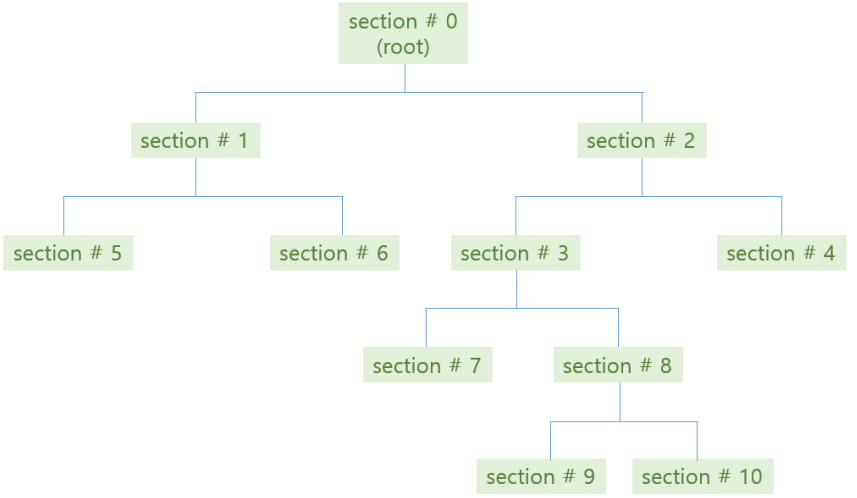
7) 지도학습 – 의사결정나무

의사결정나무(Decision Tree)

- 의사결정규칙(decision rule)을 도표화하여 종속변수를 예측 하는 방법
- 회귀 분석과 달리 각종 가정 불필요 하며 직관적(if ~ then 규칙)이고 해석이 비교적 쉬움
- 종속변수가 명목형인 경우 분류 나무(Classification Tree), 연속형인 경우 회귀 나무(Regression Tree) 사용
- 의사결정나무를 여러 개 합쳐서 만든 모델 중 대표적인 것이 Random Forest



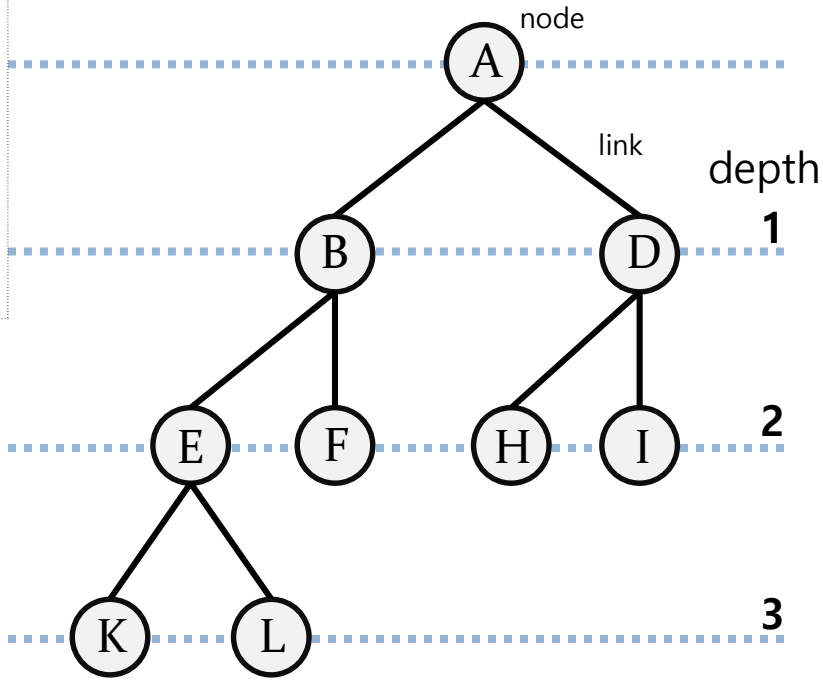
https://lovit.github.io/



7) 지도학습 – 의사결정나무

의사 결정 나무(Decision Tree) 용어 정리

- 노드(node): 데이터를 담고 있는 부분
- 차수(degree): 특정 노드가 가지고 있는 자식 노드의 수
- 레벨(level): 트리 구조 각 층의 번호
- 깊이(depth): 레벨 - 1
- 높이(height): 최상위 노드부터 맨 끝 노드 까지의 깊이
- 뿌리(root): 최상위 노드
- 잎(leaf)/단말(terminal): 차수가 0인 노드(마지막 끝단의 노드)
- 부모(parent): 서로 연결된 노드 중 레벨이 1 만큼 작은 노드
- 자식(child): 서로 연결된 노드 중 레벨이 1만큼 큰 노드
- 조상(ancestor): 서로 연결된 노드 중 레벨이 2 이상 작은 노드
- 자손(descentdant): 서로 연결된 노드 중 레벨이 2 이상 큰 노드



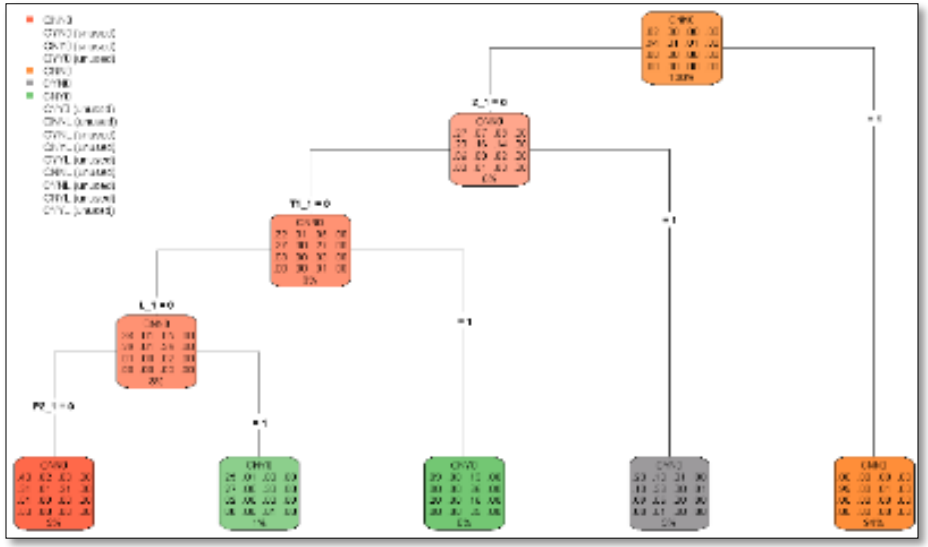
7) 지도학습 – 의사결정나무

분류 나무(Classification Tree)

- ▶ 종속변수가 명목형인 경우 사용하는 의사결정나무 모델
- ▶ 각 노드 분류 알고리즘은 이진 분류 시 지니 지수(Gini index) 기반의 CART 사용

※ CART: Classification And Regression Tree

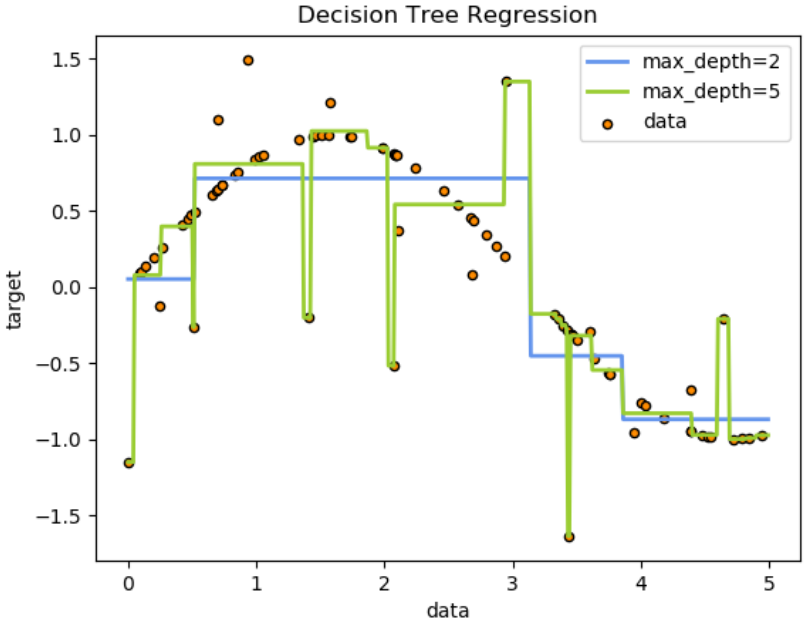
- ▶ 과적합 방지 및 모델 단순화를 위해 Depth, Impurity 등 관련 설정 활용
- ▶ 이진 분할은 지니 지수(CART)와 엔트로피 지수(C4.5, C5.0) 활용
- ▶ 다지분할은 카이제곱 통계량(CHAID) 활용



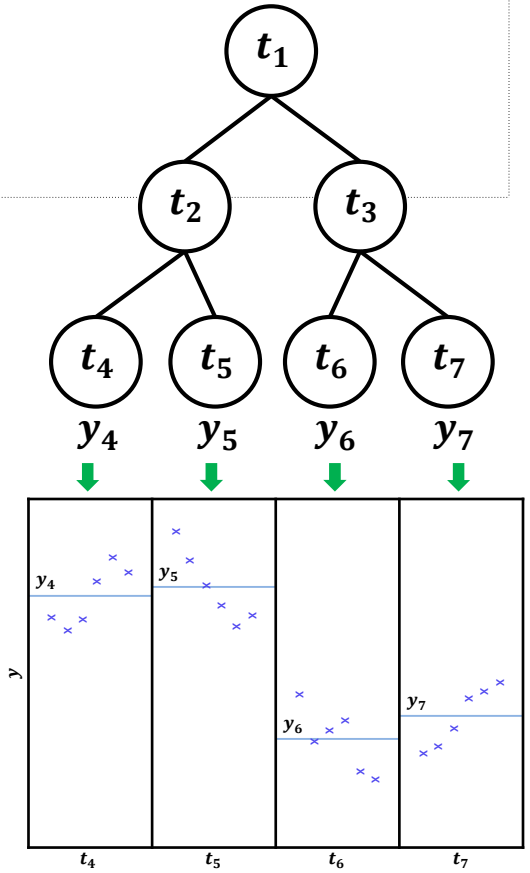
7) 지도학습 – 의사결정나무

회귀 나무(Regression Tree)

- 종속변수가 연속형인 경우 사용하는 의사결정나무 모델
- 이진분할(CART)에서는 분산 감소량을 기준으로 계산
- 다지분할(CHAID)에서는 ANOVA F-통계량 기준으로 계산
- 최적의 예측값 산출을 위해 패널티 함수를 사용하며 주로 오차제곱합(SSE) 사용



https://scikit-learn.org/



7) 지도학습 – 의사결정나무

노드의 분할과 나무의 성장

- ▶ 불순도(impurity): 특정 노드에 다양한 범주의 개체가 있는지 측정하는 기준. 엔트로피와 지니 지수로 판별
- ▶ 엔트로피(Entropy): 무질서도를 정량화 한 값으로 값이 높을 수록 해당 집단의 특징을 찾기 어려움
- ▶ 지니 지수(Gini index): 엔트로피 보다 계산이 빠르며 불순도가 높을수록 커지고 낮을수록 0에 가깝다.
- ▶ 가지치기(pruning): 과적합을 방지하기 위한 방법으로 오차와 규칙 기반 정확도를 기준으로 실시

엔트로피나 지니는 작을수록 좋고
특정 노드에 단일 범주만 존재하는 경우 0
범주간 비율이 동일한 경우 (1:1:1) 최대값

엔트로피

$$\mathrm{E}(t) = -\sum_{i=1}^{C} p_i \log_2 p_i \ , \ \ 0 \le E(t) \le 1 \, , \ \ p_i = p(i|t) = p(\text{특정 범주 개수}|\text{총 범주 개수})$$

(C: 분류 범주 개수, p_i: 특정 범주의 구성비)

지니 지수

$$\mathrm{G}(t) = 1 - \sum_{i=1}^{C} p_i^2 = 1 - \sum_{i=1}^{C} p(i|t)^2 \ , \ \ 0 \le G(t) \le 0.5$$

7) 지도학습 – 의사결정나무

노드의 분할과 나무의 성장

- 정보 이득(information gain): 분기 이전 부모 노드의 불순도와 분기 이후 자식 노드의 불순도 차이
- 정보 이득의 최대화는 엔트로피의 감소를 뜻하며 분류가 충분히 잘 된 것으로 판단
- 부모 노드의 불순도가 2이고 분기 이후 0.5로 줄었다면 정보 이득은 1.5

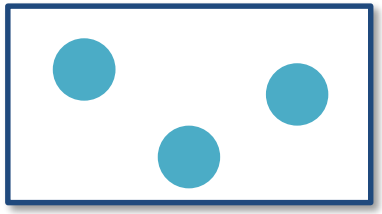
$$Information\ Gain = Entropy(N_P) - \sum_{i=1}^{n} w_i \times Entropy(N_{Ci})$$

N_p: 부모 노드
N_{Ci}: i 번째 자식 노드
w_i: i 번째 자식노드의 가중치
※ 노드 크기 비례

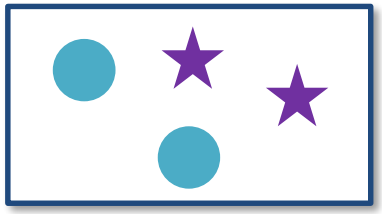
7) 지도학습 – 의사결정나무

Gini Index 계산

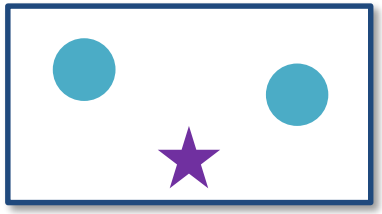
▶ 이진 분류의 경우 Gini는 단일 범주로 이루어진 경우 0, 범주별 구성비가 같은 경우 0.5



$$1-\left(\frac{3}{3}\right)^2-\left(\frac{0}{3}\right)^2=1-1-0=0$$



$$1-\left(\frac{2}{4}\right)^2-\left(\frac{2}{4}\right)^2=1-0.25-0.25=0.5$$

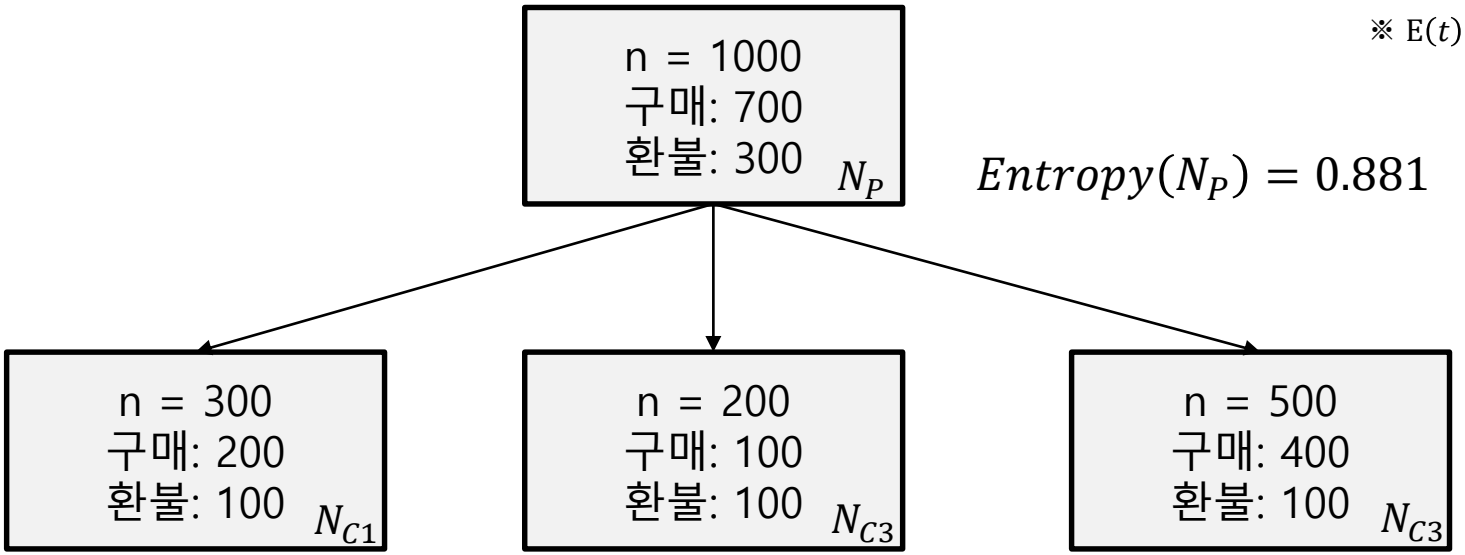


$$1-\left(\frac{2}{3}\right)^2-\left(\frac{1}{3}\right)^2=1-\frac{4}{9}-\frac{1}{9}=\frac{4}{9}$$

7) 지도학습 – 의사결정나무

Information Gain 계산

※ $\mathrm{E}(t) = -\sum_{i=1}^{C} p_i \log_2 p_i$



$Entropy(N_P) = 0.881$

$Entropy(N_{C1}) = 0.918$ $Entropy(N_{C2}) = 1$ $Entropy(N_{C3}) = 0.722$

$$IG = Entropy(N_P) - \sum_{i=1}^{n} w_i \times Entropy(N_{Ci})$$

$$= 0.881 - (0.3 \times 0.918 + 0.2 \times 1 + 0.5 \times 0.722) = 0.045$$

300 / 1000 200 / 1000 500 / 1000

7) 지도학습 – 의사결정나무

관련 함수 및 클래스(sklearn > tree)

함수 및 클래스	설명
DecisionTreeClassifier()	분류 나무
DecisionTreeRegressor()	회귀 나무
export_text()	모델 구조 출력(text)
plot_tree()	모델 구조 출력(plot)

관련 함수 및 메서드(matplotlib > pyplot)

함수 및 메서드	설명
figure()	그래프 크기 지정 가능
show()	그래프 출력

7) 지도학습 – 의사결정나무

모델링 예제 코드

```python
import pandas as pd
from sklearn import tree
from sklearn.model_selection import train_test_split

df = pd.read_csv("classification_data_01.csv")
X = df.drop("Class", axis = 1)
y = df["Class"]

X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size = 0.2,
                                          random_state=123)

clf = tree.DecisionTreeClassifier() # 모델 생성
clf.fit(X_tr, y_tr) # 학습
y_pred = clf.predict(X_te) # 추론(inference)
```

7) 지도학습 - 의사결정나무

모델링 예제 코드

```
1 from sklearn.metrics import confusion_matrix
2 confusion_matrix(y_te, y_pred)
```

```
array([[146,   1],
       [  1, 127]], dtype=int64)
```

```
1 from sklearn.metrics import accuracy_score
2 accuracy_score(y_true = y_te, y_pred = y_pred)
```

```
0.9927272727272727
```

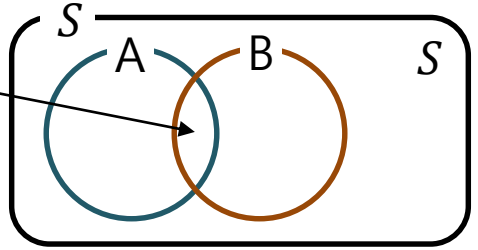
8) 지도학습 – 나이브 베이즈

나이브 베이즈 분류기(Naïve Bayes Classification)

- 특성들 사이의 독립을 가정하는 베이즈 정리를 적용한 확률 분류기의 일종
- 베이즈 정리인 조건부 확률이 핵심
- 사전 확률 및 추가 정보를 기반으로 사후 확률을 추론하는 통계적 방법인 베이즈 추정 기반 분류

조건부 확률

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$



S: 표본공간

8) 지도학습 – 나이브 베이즈

나이브 베이즈 분류기 연산 상세

- 새로운 문서(docu.)의 특정 카테고리(C_1) 분류
- $P(c_i)$: 사전확률(prior)
- $P(docu.|c_i)$: 우도(likelihood)
- $P(c_i|docu.)$: 사후확률(posterior)
- 각 카테고리별 사후확률을 비교하여 가장 큰 범주로 할당



	과학	문화	경제
P	0.86	0.23	0.45

문서(docu.)를 특정 클래스(c_1)로 분류하는 경우 사후확률 계산식

$$P(c_1|docu.) = \frac{P(c_1, docu.)}{P(docu.)} = \frac{\frac{p(c_1, docu.)}{P(c_1)} \cdot P(c_1)}{P(docu.)} = \frac{P(docu.|c_1)P(c_1)}{P(docu.)}$$

$$C_{MAP} = \underset{c = C}{argmax}\, P(c|docu.)$$

$$= \underset{c = C}{argmax} \frac{P(docu.|c)P(c)}{P(d)}$$

※ MAP = Maximum A Posteriori = most likely category
※ 분류 문제에서 $P(d)$로 나누는 계산은 중복이라 생략 가능

8) 지도학습 – 나이브 베이즈

나이브 베이즈 분류기 연산 예시 – 문서 분류

- 특정 카테고리(C_i)로의 문서 분류를 위해서 각 단어(w)의 우도($P(w_n|c_i)$)를 전부 곱함
- 각 단어의 등장은 독립(independent)이며 단어의 등장 순서는 무시된다.
- 문서 표현 방식인 Bag-of-Words와 비슷한 접근



특정 문서(docu.)에서 등장하는 단어(w)는 조건부 독립

$$P(w_1, w_2|c_i) = P(w_1|c_i) \cdot P(w_2|c_i)$$

특정 문서(docu.)가 특정 카테고리(c_k)일 확률

$$P(docu.|c_k) = \prod_i P(w_i|c_k) = P(w_1|c_k) \times P(w_2|c_k) \times \ \dots \times P(w_i|c_k) \ , \quad i, k \in \mathbb{N}$$

파이로 읽음. 원주율(π)의 대문자

※ $P(w_1|c_1)$: c_1(과학) 카테고리에서 w_1(초전도체) 단어가 등장할 확률

8) 지도학습 – 나이브 베이즈

나이브 베이즈 분류기 연산 예시 – 이메일 분류

▶ 텍스트 기반 스팸 메일/정상 메일 분류 예시
▶ 메일 내용: 안녕하세요 **이번 감사** 이벤트 **당첨 축하** 드립니다.
※ $P(spam) = P(email) = 0.5$ 라고 가정

이메일(email)을 스팸메일(spam)로 분류하는 경우 사후확률 계산식

$$P(spam|email) = \frac{P(spam, email)}{P(email)} = \frac{P(email|spam)P(spam)}{P(email)}$$

단어	P(단어|스팸O)	P(단어|스팸X)
축하	0.3	0.05
당첨	0.4	0.01
감사	0.1	0.6
이번	0.05	0.1

※ 기존 이메일(train set)으로 확보한 데이터

$$P(\text{스팸}O|email) = 6 \times 10^{-4} = 0.3 \times 0.4 \times 0.1 \times 0.05$$

$$P(\text{스팸}X|email) = 3 \times 10^{-5} = 0.05 \times 0.01 \times 0.6 \times 0.1$$

$$P(\text{스팸}O|email) > P(\text{스팸}X|email)$$

$$\therefore email \rightarrow spam!$$

8) 지도학습 – 나이브 베이즈

관련 메서드 및 클래스

sklearn - GaussianNB()

- 나이브베이즈 분류 모델을 위한 sklearn의 클래스
- 독립변수와 종속변수는 GaussianNB() 클래스의 메서드인 fit() 함수에 할당
- 모델 객체의 .predict() 또는 .predict_proba() 메서드로 분류 결과 또는 예측 확률값을 생산
- 이진 분류의 경우 출력된 예측 확률값의 두 번째 열이 1이 될 확률

sklearn - MultinomialNB()

- 나이브베이즈 분류 모델을 위한 sklearn의 클래스
- 독립변수와 종속변수는 MultinomialNB() 클래스의 메서드인 fit() 함수에 할당
- 모델 객체의 .predict() 또는 .predict_proba() 메서드로 분류 결과 또는 예측 확률값을 생산
- 다중 분류의 경우 .predict_proba() 메서드로 산출된 객체의 각 열은 종속변수 범주별 확률

8) 지도학습 – 나이브 베이즈

라이브러리 및 데이터 준비

```
1 import numpy as np
2 import pandas as pd
3 from sklearn.model_selection import train_test_split
4 from sklearn.naive_bayes import GaussianNB
```

```
1 df = pd.read_csv("classification_data_01.csv")
2 X = df.drop(columns = "Class")
3 y = df["Class"]
4
5 X_tr, X_te, y_tr, y_te = train_test_split(X, y,
6                                           train_size = 0.7,
7                                           random_state = 123)
8 len(X_tr), len(X_te)
```

```
(960, 412)
```

8) 지도학습 – 나이브 베이즈

예측 확률/분류값 산출

```
1 model_nb = GaussianNB()
2 model_nb.fit(X = X_tr, y = y_tr)
3 arr_pred = model_nb.predict_proba(X_te)
4 arr_pred[:3, ]
```

```
array([[0.7611068 , 0.2388932 ],
       [0.23308158, 0.76691842],
       [0.99746032, 0.00253968]])
```

```
1 pred_class = np.where(arr_pred[:, 1] > 0.5, 1, 0)
2 pred_class[:3]
```

```
array([0, 1, 0])
```

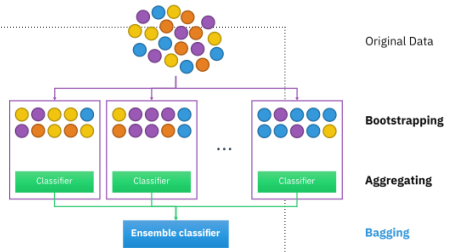
9) 지도학습 – 앙상블

앙상블(Ensemble) 모델링

▶ 2개 이상의 모델을 활용하여 단일 모델 대비 더 나은 성능의 모델을 만드는 것
※ 예) 다수의 약 분류기(Weak Classifier)를 결합하여 강 분류기(Strong Classifier)를 만듦
※ 예) 선형회귀 모델과 K-NN 회귀 모델을 결합

배깅(Bagging, Bootstrap Aggregating)

▶ 모델의 안정성과 정확도를 향상시키기 위한 기법
▶ 분산을 줄이고 과적합(overfitting)을 방지
▶ 각 모델을 생성하기 위해 사용하는 데이터는 부트스트랩(Bootstrap) 샘플 데이터
▶ 각 모델의 예측값을 취합(Aggregating)할 때 평균(회귀 모델) 또는 투표(분류 모델)를 활용



https://zetawiki.com/wiki/배깅

투표(Voting)

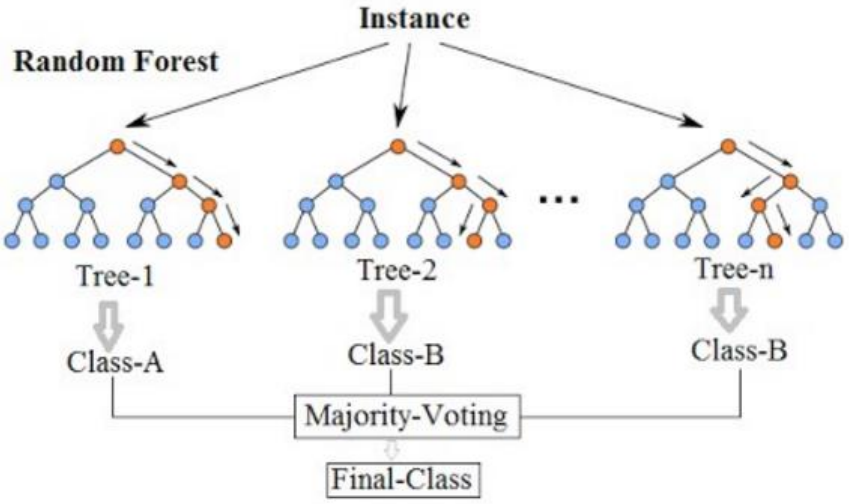
▶ 서로 다른 모델의 예측치를 취합하여 하나의 결과로 결정하는 방법
▶ 분류의 경우 최빈값을 기준으로 하는 Hard Voting, 확률이 가장 높은 값을 기준으로 하는 Soft Voting 중 선택

9) 지도학습 – 앙상블

랜덤포레스트(Random Forest)

- 대표적으로 많이 쓰이는 앙상블(ensemble) 기법 중 하나
- 주어진 데이터의 부트스트랩(bootstrap) 표본을 이용해 트리모델을 다수 구성하고 그 결과를 취합
- 의사결정나무를 기반으로 만들어진 모델이기 때문에 많은 설정값이 유사
- 의사결정나무와 같이 회귀 모델과 분류 모델이 있음
- 통계적 가정이 필요 없으나 선형 모델 대비 결과 해석이 어려움
- 트리 개수가 많을 경우 연산 시간이 오래 걸리고 RAM 소모가 큼





https://en.wikipedia.org/wiki/Random_forest

랜덤포레스트(Random Forest) – 변수 중요도

▶ 특정 (독립)변수의 중요도를 확인하고 이를 기반으로 인사이트를 얻거나 향후 모델링 작업에 참고 가능

※ 중요도가 매우 낮은 경우 모델에서 제외하기도 함

▶ 랜덤포레스트에서 가장 많이 사용되는 변수 중요도 확인 기법은 MDI(Mean Decrease Importance)

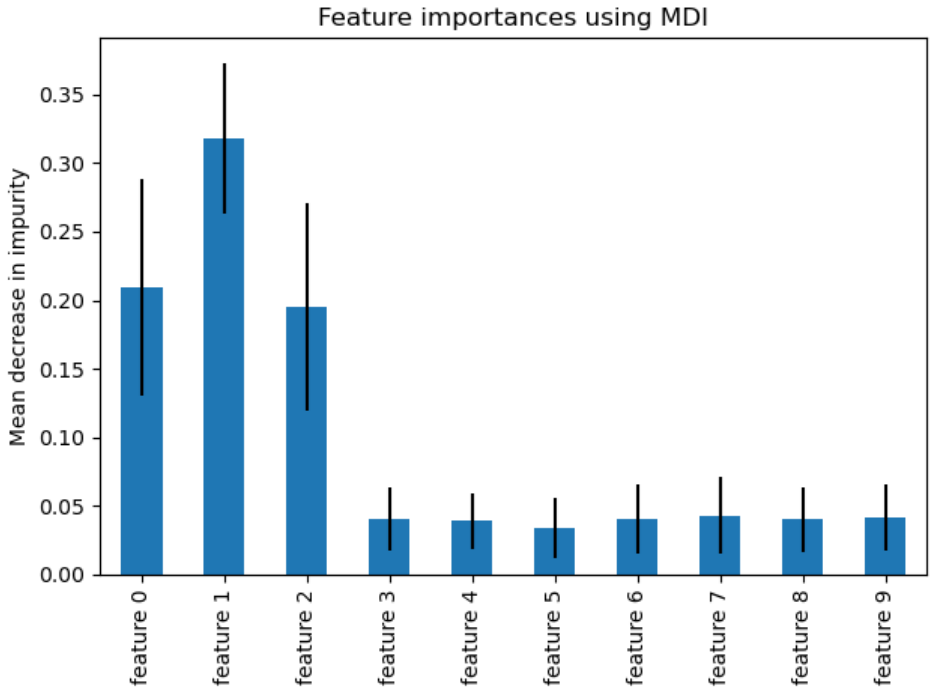
▶ Permutation Importance, Drop Column Importance 등 다른 번수 중요도 확인 기법 또한 사용 가능

※ Permutation Importance, Drop Column Importance 는 다른 지도학습에도 사용 가능

9) 지도학습 – 앙상블

변수 중요도 상세 - MDI

▶ MDI(Mean Decrease Importance): 노드 분할시 불순도 감소분의 평균을 활용



https://scikit-learn.org/stable/auto_examples/ensemble/plot_forest_importances.html

9) 지도학습 – 앙상블

변수 중요도 상세 – Permutation Importance

- Permutation Importance: test set의 특정 변수를 임의로 섞었을 때 기준 평가지표 변화량을 기준으로 중요도 산출
- 대부분의 일반 지도학습의 독립변수 중요도 평가 시 사용 가능
- 특정 독립변수의 데이터를 임의로 섞는다면 데이터 포인트간 관계가 끊어진다고 가정
- 알고리즘에 랜덤이 포함되기 때문에 랜덤을 고정하지 않는다면 수행 시 마다 결과가 다름
- 랜덤으로 데이터가 섞이지만 우연히 섞기 전과 데이터가 일치하거나 거의 비슷할 수 있음

	나이	경력	실적
0	52	24	45
1	27	1	0
2	34	6	12

→

	나이	경력	실적
0	52	1	45
1	27	24	0
2	34	6	12

https://datadoctorblog.com/2023/09/10/Py-ML-Evaluation-Model-Permutation-Importance/

9) 지도학습 – 앙상블

변수 중요도 상세 – Drop Column Importance

- ▶ Drop Column Importance: 특정 변수를 제외 후 평가지표 변화량을 기준으로 중요도 산출
- ▶ 대부분의 일반 지도학습의 독립변수 중요도 평가 시 사용 가능
- ▶ 동작 원리 및 결과 해석이 쉽고 명료
- ▶ 특정 독립변수를 제외 후 학습 및 평가를 실시하기에 변수 중요도 평가를 위한 연산량이 많은 편

Model	독립변수				RMSE	변화량	중요도
	A	B	C	D			
FM	O	O	O	O	13.232	-	-
RM1		O	O	O	21.342	8.11	0.427
RM2	O		O	O	14.345	1.113	0.059
RM3	O	O		O	16.657	3.425	0.180
RM4	O	O	O		19.569	6.337	0.334

※ FM(Full Model): 모든 독립변수가 들어간 모델, RM(Reduced Model): FM에서 일부 독립변수가 제거된 모델
https://datadoctorblog.com/2023/09/14/Py-ML-Evaluation-Model-Drop-Column-Importance/

9) 지도학습 – 앙상블

관련 메서드 및 클래스(sklearn > ensemble)

메서드 및 클래스	설명
RandomForestClassifier()	랜덤포레스트 분류 모델
RandomForestRegressor()	랜덤포레스트 회귀 모델
.fit()	모델 학습하며 학습 데이터 입력
.feature_importances_	RF 모델 객체에서 변수별 중요도(MDI) 산출

9) 지도학습 – 앙상블

라이브러리 및 데이터 준비

```
1 import numpy as np
2 import pandas as pd
3 from sklearn.model_selection import train_test_split
4 from sklearn.ensemble import RandomForestClassifier
```

```
1 df = pd.read_csv("classification_data_01.csv")
2 df_train, df_test = train_test_split(df,
3                                      train_size = 0.7,
4                                      random_state = 123)
5 len(df_train), len(df_test)
```

```
(960, 412)
```

9) 지도학습 – 앙상블

RandomForestClassfier() 예제

```
model_rf = RandomForestClassifier(n_estimators = 20, # tree 개수
                                  max_depth = 3, # 최대 가지 깊이
                                  random_state = 123)
model_rf.fit(X = df_train.drop(columns = "Class"),
             y = df_train["Class"])
pred = model_rf.predict(df_test.drop(columns = "Class"))
pred[:6]
```

```
array([0, 0, 0, 0, 1, 1], dtype=int64)
```

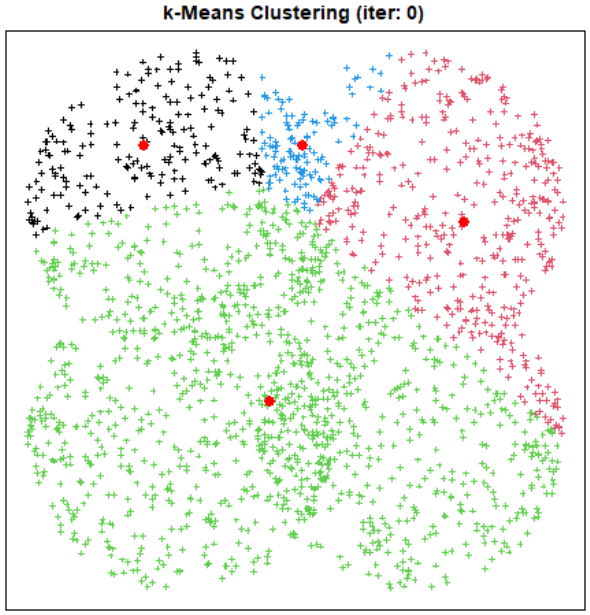
```
model_rf.feature_importances_ # MDI
```

```
array([0.66884266, 0.18973762, 0.10367387, 0.03774585])
```

10) 비지도학습 – k-means 군집분석

비계층적 군집분석: K-means Clustering

- ▶ 주어진 데이터를 k개의 군집으로 묶는 알고리즘
- ▶ 최초 k 값 선정이 어렵고 주관적으로 결정하며 경우에 따라 다른 분석기법을 활용하기도 함
- ▶ 평균을 기준으로 계산하기에 이상치에 민감
- ▶ 각 군집의 중심점(centroid)은 최초에 임의의 위치로 선정되며 평균을 활용하여 위치 조정



Q. k-means 군집분석을 실시함에 있어 데이터가 19개, 군집 개수는 3개, 반복 연산은 총 5회를 실시한다고 할 경우 수행하는 총 수치연산 횟수는
총 몇 번인가?"

1) 각 중심점(centroid)과 각 데이터간 거리계산
→□ n x k
2) 거리계산 결과를 기반으로 평균을 활용한 중심점 위치 재계산
→□ k
3) 1과 2의 과정을 반복
→□ (n x k + k) x iter.

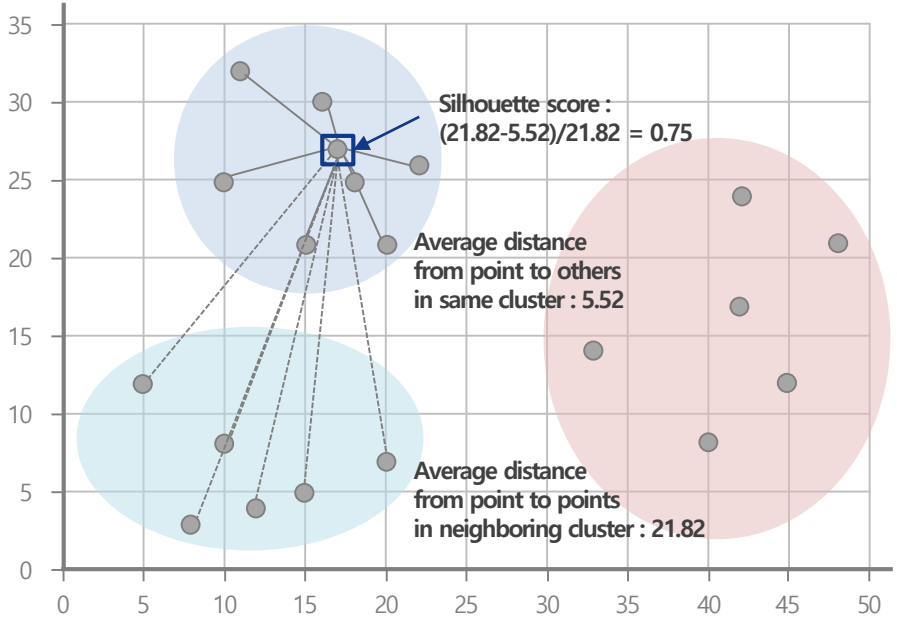
(n + 1) x k x iter. = (19 + 1) x 3 x 5 = 300

10) 비지도학습 – k-means 군집분석

군집 타당성 지표(Clustering Validity Index) - 실루엣 분석(Silhouette Analysis)

- ▶ 실루엣 분석에서 계산하는 점수가 실루엣 점수
- ▶ 자신의 군집의 특정원소와 각 원소 간의 거리 평균과 타 군집 원소 간의 거리 평균을 기반으로 산출
- ▶ 실루엣 점수 계산시 계산량이 많아($O(n^2)$) 필요시 표본추출 후 계산
- ▶ 정규화를 위해 최대값을 나누어 주며 값이 클 수록 좋고 최대값은 1이다.

※ sklearn에서 산출하는 경우 최소값 0, 최대값 1



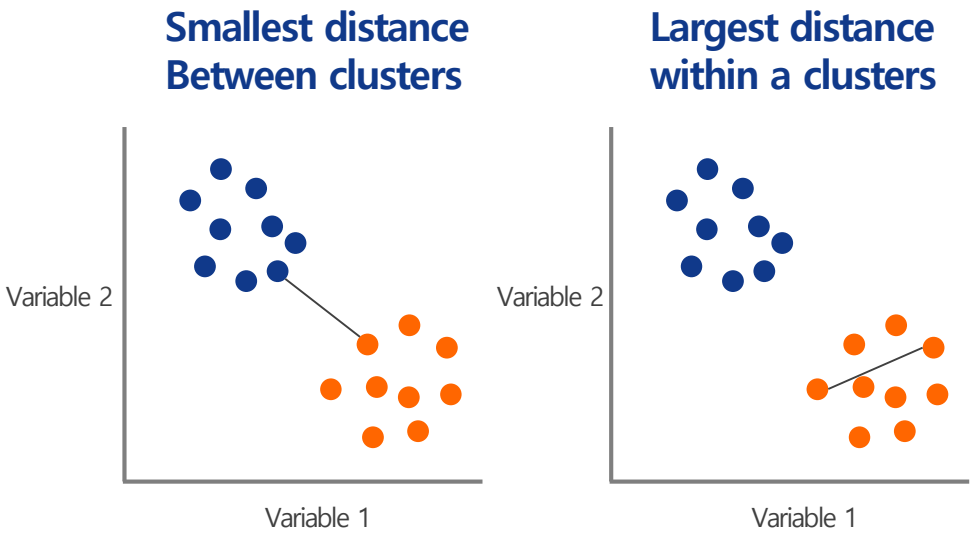
$$s(i) = \frac{b(i) - a(i)}{\max(a(i),\ b(i))}$$

$a(i)$: i번째 개체와 같은 군집에 속한 요소간 거리 평균

$b(i)$: i번째 개체와 다른 군집에 속한 요소간 거리 최소

군집 타당성 지표(Clustering Validity Index) - Dunn Index

- 군집 간 거리의 최소값을 분자, 군집 내 요소 간 거리의 최대값을 분모로 하는 지표
- 값이 클수록 좋으며 최소값은 0이다(최대값은 무한대).



$$I(C) = \frac{\min\limits_{i \neq j}\{d_c(C_i, C_j)\}}{\max\limits_{1 \leq l \leq k}\{\Delta(C_l)\}}$$

10) 비지도학습 – k-means 군집분석

관련 메서드 및 클래스(sklearn > cluster)

메서드 및 클래스	설명
KMeans()	k-means 군집분석
.fit()	모델 학습하며 학습 데이터 입력
.cluster_centers_	각 군집의 중심점 출력
☆ .labels_	각 데이터가 속하는 군집 번호 출력
.inertia_	inertia(WCSS, Within Cluster Sum of Squares) 출력

10) 비지도학습 – k-means 군집분석

관련 함수 및 메서드(sklearn > metrics)

함수 및 메서드	설명
silhouette_score()	Silhouette score 계산

관련 메서드 및 클래스(validclust)

메서드 및 클래스	설명
ValidClust()	indices 인자에 "dunn"을 넣어 Dunn Index 계산
.fit_predict()	ValidClust()로 생성된 객체 기반 인덱스 계산

10) 비지도학습 – k-means 군집분석

모델링 예제 코드

```
1 import pandas as pd
2 from sklearn.cluster import KMeans
3 df = pd.read_csv("iris.csv")
4 X = df.loc[:, :"PetalWidth"]
5 model = KMeans(n_clusters = 3, random_state = 123)
6 model.fit(X)
7 df_centroids = pd.DataFrame(model.cluster_centers_,
8                              columns = X.columns)
9 df_centroids
```

	SepalLength	SepalWidth	PetalLength	PetalWidth
0	6.850000	3.073684	5.742105	2.071053
1	5.006000	3.428000	1.462000	0.246000
2	5.901613	2.748387	4.393548	1.433871

첫 번째 군집은 꽃받침의 수치와 꽃잎의 수치가 전체적으로 크기 때문에 큰 꽃의 데이터가 모여 있는 것이라고 할 수 있음.
두 번째 군집은 꽃받침의 수치와 꽃잎의 수치가 전체적으로 작기 때문에 큰 꽃의 데이터가 모여 있는 것이라고 할 수 있음.

10) 비지도학습 – k-means 군집분석

모델링 예제 코드

```
1 from sklearn.metrics import silhouette_score
2 silhouette_score(X = X,
3                  labels = model.labels_,
4                  random_state = 123)
```

```
0.5528190123564101
```

sample_size 인자에 값을 할당할 때만
random_state 인자에 값 지정이 의미가 있음
즉, 이 경우는 의미 없음

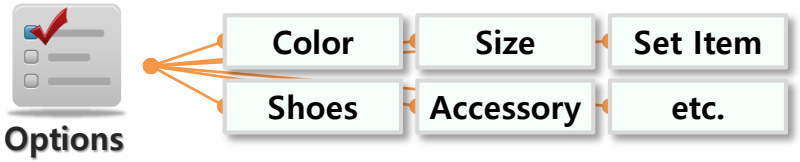
11) 특성 공학

특성 공학(Feature Engineering)

- 변수 선별, 기존 변수 조합 등 주로 모델의 성능을 올리기 위해서 주로 실시
- 모델을 간결하게 하거나 모델의 해석을 용이하게 하기도 함
- 도메인 지식과 데이터의 특성을 잘 이해하여 종속변수와 관련이 깊은 신규 변수 생성이 중요



fruit, red,
round shaped,
price, taste …



속성 부분집합 선택법(Feature Subset Selection)

- **Embedded approaches**: 알고리즘 내부에서 결정하는 것으로 대표적으로 의사결정나무 알고리즘에서 사용
- **Filter approaches**: 모델링 이전에 여러 지표(상관계수 등)를 기반으로 필요한 데이터만 걸러내는 것
- **Wrapper approaches**: 특정 지표를 기준으로 해당 지표가 최적값(목표값)이 될 때 까지 탐색하는 방법

※ 선형회귀의 backward elimination, forward/stepwise selection

12) 필기 예상 문제

Q01. k-NN Regression에 대한 특징으로 알맞지 않은 것은?

① KNN 알고리즘은 지역적 구조에 민감하다

② k가 작으면 과대적합(overfitting)문제가 발생한다

③ 이상치에 민감하다

④ TEST 데이터가 들어오기 전에 모델이 학습한다

12) 필기 예상 문제

Q02. 의사결정나무 기법의 특성을 설명한 것 중 옳지 않은 것은?

① 이해하기 쉬운 If~then~ 과 같은 형식으로 구성된다

② 시각화를 통하여 표현됨으로 이해하기 쉽다

③ 통계적 가정이 필요하다

④ 정보이득 개념을 활용하여 모델을 생성한다

12) 필기 예상 문제

Q03. 다음 K-means 군집 기법에 대한 설명으로 잘못된 것은?

① n개의 데이터와 k개의 중심점이 주어졌을 때, 각 그룹 내의 데이터와 중심점 간의 비용을 최대화하는 방향으로 계속 업데이트하여 군집화를 수행하는 기법이다

② 중심점의 수 이자 군집의 수인 k 값을 사전에 제시하고, k 개의 중심점과 개별 데이터의 거리를 측정하여 가장 가까운 중심점에 속한 것으로 한다

③ 할당된 데이터들의 평균값으로 새로운 중심점을 업데이트 하는데, 이 때 평균값을 사용하기 때문에 K-means라 불린다

④ 중심점 업데이트 시에 이상치에 영향을 받을 수 있고, 항상 최적 결과를 보장하는 것은 아니다

12) 필기 예상 문제

Q04. 다음의 머신러닝 지도학습 기법 중 그 성격이 다른 하나는?

① Logistic Regression

② Classification Tree

③ KNN Classifier

④ Linear Regression

12) 필기 예상 문제

Q05. 3차원 공간에 있는 (-1,0,3) 과 (4,1,-3) 의 유클리디안 거리의 계산으로 올바른 것은?

① 4

② 0

③ $\sqrt{37}$

④ $\sqrt{62}$

12) 필기 예상 문제

Q06. 의사결정나무의 분류나무를 사용할 경우 노드의 불순도를 평가하기 위해 Gini Index를 활용할 수 있다. 여기서 종속변수가 A와 B로 이루어진 자료를 학습하여 이진 분류를 하고자 한다. 이 때 노드의 각 클래스가 A: 2, B: 6 일 때 계산한 Gini Index로 옳은 것은?

① 0.125

② 0.25

③ 0.375

④ 0.5

12) 필기 예상 문제

Q07. 다음 중 결정계수 관련 내용으로 옳지 않은 것은?

① 단순 선형 회귀분석의 결정계수는 독립변수와 종속변수의 상관계수의 제곱과 같다

② 조정된 결정계수는 학습에 사용된 자료의 변수의 개수와 데이터의 개수에 영향을 받는다

③ 결정계수가 높을 경우 모델의 설명력이 높은 것이라 평가한다

④ 결정계수는 -1에서 1사이의 값을 가진다

이건 상관계수

12) 필기 예상 문제

Q08. 다음 중 다중 선형 회귀분석의 다중공선성 문제와 관련된 내용으로 가장 옳지 않은 것은?

① 다중공선성 문제 존재 여부는 분산팽창계수(VIF)가 지정한 임계값 초과 여부를 기준으로 확인 할 수 있다

② 다중공선성 문제가 있는 경우 독립변수의 회귀 계수의 신뢰구간이 넓어진다

③ 종속변수와 독립변수간 상관계수가 높은 경우 다중공선성 문제가 발생할 확률이 높다

④ 예측을 주 목적으로 하는 모델의 경우 예측 성능이 충분히 좋다면 다중공선성 문제를 무시할 수 있다

12) 필기 예상 문제

Q09. 다음 중 군집분석 관련 내용으로 가장 옳지 않은 것은?

① 군집분석을 활용하여 결측치 처리를 할 수 있다

② 군집분석은 데이터가 커질수록 연산 비용이 줄어든다

③ 군집의 해석은 각 군집의 centroid를 기준으로 하며 주관적인 해석이 가능하다

④ 군집 결과의 평가는 각 군집간 원소의 밀집도를 활용할 수 있다

12) 필기 예상 문제

Q10. 다음 중 k-means 군집분석의 내용으로 옳지 않은 것은?

① k는 2 이상의 자연수로 값이 크다고 반드시 좋은 것은 아니다

② 양질의 결과 산출을 위해서 입력 자료의 정규화가 권장된다

③ 군집의 평가로 silhouette score를 활용할 수 있다

④ 각 군집의 최적 centroid를 찾기 위해서 ~~최소 200회~~ 이상의 반복 연산이 요구된다

12) 필기 예상 문제

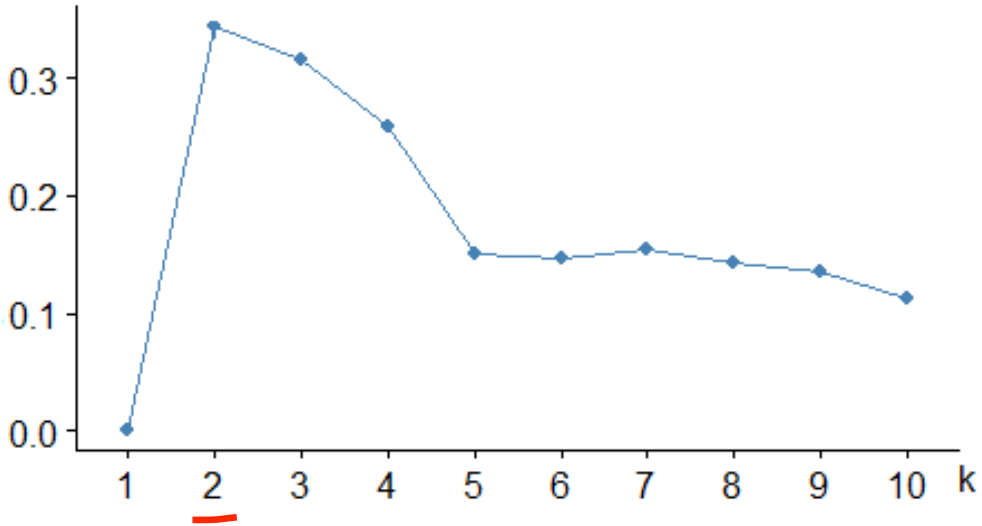
Q11. 주어진 그래프는 군집방법을 이용하여 구한, 군집의 개수(x축)에 따른 실루엣 점수(y축) 그래프이다. 최적이라고 판단되는 군집의 개수 K는 무엇인가?

① 2

② 3

③ 4

④ 5



12) 필기 예상 문제

Q12. 아래 데이터를 사용하여 분석을 수행할 때, 독립변수, 종속변수, 학습모델에 대한 설명이 적절하지 않은 것을 고르시오.

매장위치	브랜드 명	매장크기	매출
서울	A	100	2350
부산	B	200	1590
부산	A	250	2100
서울	B	400	2530
서울	A	340	2045

① k-NN 분류: 독립변수로 매출을 사용하여 브랜드명을 예측

② 선형회귀: 독립변수로 매출을 사용하여 매장크기를 예측

③ 회귀나무: 독립변수로 매장크기, 브랜드명, 매장위치를 사용하여 매출이 2,000 이상인지 여부를 예측

④ 로지스틱 회귀 : 독립변수로 매장크기, 매장위치를 사용하여 브랜드명을 예측

12) 필기 예상 문제

Q13. Decision Tree의 Feature 중요도는 Tree 상단에 나오는 순서로만 결정된다.

① O

② X

12) 필기 예상 문제

Q14. Linear Regression의 주요 가정 사항과 가정사항 만족 여부를 확인하는 방법을 연결한 것 중 적절하지 않은 것은?

① 선형성 - 산점도

② 정규성 - Q-Q Plot

③ 등분산성 – 잔차그래프

④ 독립성 - 라인그래프

12) 필기 예상 문제

Q15. 주어진 데이터에서 "참가여부"는 목표(Target) 변수이고, "자외선","온도","습도“, “바람”은 입력(input)변수들이다. 이 데이터를 이용하여 의사결정 나무의 분류나무 알고리즘으로 노드를 분리하려 한다. 어떤 입력변수를 기준으로 분할했을 때 자식노드의 Gini 값의 합이 가장 낮은가?

① 자외선

② 온도

③ 습도

④ 바람 ✓

자외선	온도	습도	바람	참가여부
강함	적당	보통	약함	X
강함	적당	낮음	약함	X
약함	적당	보통	약함	X
약함	적당	보통	강함	O
약함	추움	낮음	강함	O

12) 필기 예상 문제

Q16. ROC curve는 True Positive Rate를 x축에, False Positive Rate를 y축에 표시한 그래프로서 전체 면적 대비 곡선의 아래쪽 면적의 크기로 분류기의 성능을 평가할 수 있다

① O

② X

12) 필기 예상 문제

Q17. 나이브 베이즈 기법에 대한 특징으로 적절하지 않은 것은?

① 학습 과정이 단순하여 대규모 데이터셋에 적용하기 용이하다

② 분류 결과를 확률 형태(Posterior Probability)로 해석할 수 있다

③ 의사결정나무보다 높은 정확도를 보장한다.

④ 분류 문제뿐 아니라, 이상 탐지와 같은 영역에도 활용될 수 있다



04

실기 OT



1) 교육 개요

교육내용



Python 데이터 핸들링

01 데이터프레임 기초와 필터링
02 요약
03 파생변수 생성
04 텍스트 데이터 처리
05 시간 데이터 처리
06 Pivoting
07 데이터 병합
08 고급 데이터 핸들링



실전 데이터 분석 문제

Set 01 시중 TV 제품별 분석
Set 02 갤럭시 사용자 데이터 분석
Set 03 시중 스마트폰 상세 정보
Set 04 디지털프라자 매출 데이터
Set 05 신용카드 고객정보 분석
Set 06 교육 수강자 분석

2) 필수 이론 정리

실기 문제 공략을 위한 분야별 필수 이론

- ▶ 데이터 전처리: 필터링, Pivoting, 병합, 텍스트 핸들링, 시간 데이터 핸들링, 정규화, 결측치 처리
- ▶ 통계: 기술통계량 산출, 이상치 처리, 표본 추출, 상관분석, seed(random state) 설정
- ▶ 머신러닝: Holdout test, 회귀/분류 모델 평가지표, 기타 모델 평가지표, seed(random state) 설정

3) 실기 문제 유형

전처리

- 필터링 결과를 기반으로 계산하는 특정 값의 빈도 또는 비율
- 제시된 기준으로 실시하는 이상치 필터링과 필터링된 결과를 기준으로 계산하는 기술통계량
- 상기 두 조건에서 텍스트 처리/시간 데이터 처리/데이터 병합이 추가된 유형

통계

- 통계분석을 통해 산출가능한 기술통계량 또는 상관계수
- 상기 통계분석 실시를 위한 전처리 작업이 추가된 유형

3) 실기 문제 유형

머신러닝 - 공통

- 함수/메서드/클래스 등 별도 옵션 조정 메서드에 대한 지시사항이 없으면 기본값 사용
- 모델 학습 전데이터의 train/test 분할, 정규화는 언급이 없으면 실시하지 않음

머신러닝 - 지도학습

- Holdout test를 활용한 지도학습 모델링과 결과 평가
- 모델링 이전 정규화 또는 데이터 전처리가 가미된 유형
- 학습 모델 기반 별도의 평가 데이터를 활용한 예측값 생산과 평가
- 모델의 파라미터 튜닝 또는 추가에 따른 성능변화 관찰
- 이종 알고리즘으로 생성된 모델간 성능 비교

머신러닝 - 비지도학습

- 군집분석 결과 중 특정 군집의 특성 파악
- 특정 데이터와 가장 가까운 군집 확인
- 군집분석 결과를 활용한 실루엣 분석



05

데이터 핸들링



1) 데이터프레임 기초와 필터링

인덱서의 사용

- Pandas 객체의 보다 빠른 연산과 가독성을 위해 인덱서 사용 권장
- .iloc[] 인덱서는 내부에 정수만 사용 가능
- 필터링을 위해서는 .loc[] 인덱서 사용
- 인덱서는 주로 DataFrame 객체에 사용하며 Series는 드물게 사용
- DataFrame 객체는 2차원 객체에기 때문에 인덱서를 사용하면 대괄호 사이에 쉼표를 쓰는 것을 권장
- .at[] 와 .iat[] 는 .loc[] 와 .iloc[] 로 대체 가능

DataFrame.at	Access a single value for a row/column label pair.
DataFrame.iat	Access a single value for a row/column pair by integer position.
DataFrame.loc	Access a group of rows and columns by label(s) or a boolean array.
DataFrame.iloc	Purely integer-location based indexing for selection by position.

```
df.iloc[ row , column ]
df.loc[ row , column ]
```

1) 데이터프레임 기초와 필터링

DataFrame 색인

- ▶ 대괄호를 사용하여 내부 원소에 접근 가능하나 인덱서 사용 권장
- ▶ 대괄호 내부 쉼표를 사용하여 row와 column을 동시에 색인하려고 하는 경우 쉼표 앞에 row 관련 내용 입력
- ▶ 인덱서 사용시 모든 row를 지정할 경우 콜론을 사용
- ▶ 마침표 뒤에 별도의 변수명을 선언하는 경우 어트리뷰트와 충돌이 생길 수 있어 사용 지양

1) 데이터프레임 기초와 필터링

DataFrame 색인

```
df_s = pd.DataFrame(dict(v1 = [100, 200, 300],
                         v2 = [400, 500, 600],
                         shape = ["A", "B", "C"]))
```

```
df_s.iloc[:2, ]
df_s.loc[:2, ]
df_s.v1
df_s.shape # row, column
df_s["shape"]
df_s.iloc[:, :-1]
df_s.loc[:, "v2":]
```

1) 데이터프레임 기초와 필터링

DataFrame 필터링

```
df_s.loc[df_s["v1"] == 200, ]
df_s.loc[df_s["v1"] != 200, ]
df_s["v1"] == 200
~(df_s["v1"] == 200)
df_s.loc[~(df_s["v1"] == 200), ]
df_s.loc[(df_s["v1"] == 200) & (df_s["v2"] == 600), ]
df_s.loc[(df_s["v1"] == 200) | (df_s["v2"] == 600), ]
condi_1 = df_s["v1"] == 200
condi_2 = df_s["v2"] == 500
df_s.loc[condi_1 & condi_2, ]
df_s.loc[(df_s["shape"] == "A") | (df_s["shape"] == "C"), ]
df_s.loc[df_s["shape"].isin(["A", "C"]), ]
df_s.loc[~df_s["shape"].isin(["A", "C"]), ]
```

1) 데이터프레임 기초와 필터링

DataFrame의 변수명 확인 및 변경

▶ 특정 변수명을 바꾸기 위해서는 .rename() 메서드와 Dictionary 객체 사용
▶ .rename() 메서드를 사용하지 않을 경우 전체 변수명을 list 객체로 할당해서 바꿔야 함

```
1 df.columns
2 df.columns[1]
3 df.columns = ["xx", "yy"]
4 df.columns
```

```
1 df = df.rename(columns = {"xx": "obs"})
2 df.rename(columns = {"xx": "obs"}, inplace = True)
```



사용 지양

1) 데이터프레임 기초와 필터링

Pandas 객체 필터링

- Series 객체의 경우 별도의 인덱서 없이 대괄호 기반의 벡터연산으로 가능
- DataFrame 객체의 경우 .iloc[] 또는 .loc[] 인덱서 기반의 필터링 권장
- 보통 row 부분에 특정 인덱스(숫자 또는 문자)가 명시되도록 하거나 논리값(Boolean)을 할당
- 두 개 이상의 조건이 필요한 경우 각 조건을 소괄호로 감싸고 논리 연산자로 조건을 이어주어야 함
- Series객체의 경우 복수의 or 조건 연산보다 .isin() 메서드가 유용

DataFrame.loc	Access a group of rows and columns by label(s) or a boolean array.
DataFrame.iloc	Purely integer-location based indexing for selection by position.

```
df.iloc[ row , column ]
df.loc[ row , column ]
```

1) 데이터프레임 기초와 필터링

필터링 예제

```
1 df = pd.read_csv("krx_202105_utf8.csv")
2 df.head(2)
```

```
1 df_sub = df.loc[df["지수명"] == "KRX 300", ]
2 df_sub
```

	지수명	종가	대비	등락률	시가	고가
0	KRX 300	1901.05	-11.63	-0.61	1913.15	1929.94
29	KRX 300	1916.40	15.35	0.81	1903.57	1916.40

1) 데이터프레임 기초와 필터링

필터링 예제

```
1 df.loc[df["종가"] == df["종가"].max(), ["지수명", "종가", "날짜"]]
```

	지수명	종가	날짜
117	KTOP 30	11869.29	20210510

```
1 df["종가"].idxmax() # 최댓값의 index
2 df.loc[df["종가"].idxmax(), ["지수명", "종가", "날짜"]]
3 df.loc[[df["종가"].idxmax()], ["지수명", "종가", "날짜"]]
```

1) 데이터프레임 기초와 필터링

결측치 처리

```
1 df = pd.read_csv("iris_missing.csv")
2 df_sub = df.head()
3 df_sub
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	NaN	NaN	0.2	setosa
1	4.9	3.0	1.4		
2	4.7	3.2	1.3		
3	4.6	3.1	1.5		
4	5.0	3.6	1.4		

```
1 df_sub.info() # 특정 버전의 경우 에러가 날 수 있음
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 5 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   Sepal.Length  5 non-null      float64
 1   Sepal.Width   4 non-null      float64
 2   Petal.Length  4 non-null      float64
 3   Petal.Width   5 non-null      float64
 4   Species       5 non-null      object
dtypes: float64(4), object(1)
memory usage: 332.0+ bytes
```

1) 데이터프레임 기초와 필터링

pandas - isna(), isnull()

- 결측치 원소를 True, 관측치를 False로 반환하는 메서드
- 반대의 기능을 하는 메서드는 notna() 와 notnull()

pandas - fillna()

- 결측치를 채워 넣기 위한 메서드
- value 인자에 결측치를 채워 넣을 값을 입력하며 딕셔너리 사용 가능
- method에 'bfill'은 뒤의 값을, 'ffill'은 앞의 값을 참고하여 결측 처리

pandas - dropna()

- 결측치가 있는 row 또는 column을 제거하기 위한 메서드
- how 인자에 'any'는 결측치가 하나라도 있는 경우, 'all'은 전체가 결측인 경우 제거

1) 데이터프레임 기초와 필터링

결측치 확인/처리

```
df_sub.count() # 관측치 개수 확인
df_sub.isna()
df_sub.isna().sum() # ⭐
df_sub.isna().sum(axis = 1)
```

```
df_sub1 = df_sub.loc[df_sub["Sepal.Width"].isna(), ]
df_sub1
```

```
df_sub2 = df_sub.loc[df_sub["Sepal.Width"].notna(), ]
df_sub2
```

```
df_sub3 = df_sub.dropna()
df_sub3
```

1) 데이터프레임 기초와 필터링

결측치 확인/처리

```
df_sub.loc[:, "Sepal.Width"] = df_sub["Sepal.Width"].fillna(-999)
df_sub["Petal.Length"] = df_sub["Petal.Length"].fillna(df_sub["Petal.Length"].mean())
df_sub # 여기서 발생하는 빨간 메세지는 에러가 아닌 경고. (결과는 올바르게 나옴.)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	5.1	-999.0	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

1) 데이터프레임 기초와 필터링

색인(index)

▶ .reset_index(): 색인 초기화. 필터링 이후나 .groupby() 메서드를 활용한 연산 이후에 유용
▶ .set_index(): 특정 변수를 색인으로 설정. 그래프 구현 또는 join 연산에 활용

속성 확인 및 변환

▶ Series 객체는 .dtype 메서드, DataFrame 객체는 .dtypes 어트리뷰트로 데이터 속성 확인 가능
▶ .astype() 메서드를 사용해서 데이터 강제 형변환 가능
※ 문자: "str", 정수: "int", 실수: "float"

```
1 # df_sub["Sepal.Length"] + "cm"
2 df_sub["Sepal.Length"].astype("str") + "cm"
```

```
0    5.1cm
1    4.9cm
2    4.7cm
3    4.6cm
4    5.0cm
Name: Sepal.Length, dtype: object
```

1) 데이터프레임 기초와 필터링

Pandas를 활용한 데이터 정렬

▶ 정렬은 index기준과 각 변수의 값을 기준으로 하는 방법이 있음
▶ 각 메서드의 axis 인자를 설정하여 row 또는 column 기준으로 정렬 가능
▶ 각 메서드의 ascending 인자를 설정하여 내림차순 또는 오름차순 정렬 가능
▶ 실기 문제에서 정렬 관련 지시사항이 없으면 임의로 정렬된 객체를 분석에 절대 사용하지 말 것
※ 특정 알고리즘(보통 임의 확률과정이 포함된)은 입력되는 객체의 행 순서가 변경되면 결과가 달라짐

메서드	설명
.sort_index()	index 기준 정렬 시 사용
.sort_values()	특정 변수 기준 정렬 시 사용

```
df = pd.DataFrame([["A", 3], ["C", 1], ["B", 2]],
                  columns = ["class", "value"])
df.sort_values(by = "class")
df.sort_values(by = "class", ascending = False)
```

2) 요약

원소 개수 확인

- 단일 변수 또는 2변수 이상의 원소 또는 조합 개수 확인
- .unique(), .value_conuts(), pd.crosstab() 메서드 및 함수로 다양한 정보 확인 가능
- .nunique() 는 len() 함수와 .unique() 메서드를 합친 기능의 메서드로 매우 유용한 메서드
- .value_counts() 메서드 와 pd.crosstab() 함수의 경우 normalize 인자를 활용한 비율 계산 가능

```
1 df = pd.read_csv("bike.csv")
2 df["season"].unique()
3 df["season"].drop_duplicates()
4 df["season"].value_counts()
5 df["season"].value_counts(normalize = True)
6 df[["season", "holiday"]].drop_duplicates()
7 pd.crosstab(df["season"], df["holiday"])
```

2) 요약

.groupby()

- ▶ .agg() 메서드는 종합하다는 뜻의 aggregate 단어에서 첫 세 글자를 딴 것
- ▶ .agg() 메서드에 2개 이상의 요약 함수(sum, mean 등)을 사용하여 손쉽게 처리 가능
- ▶ .groupby() 메서드는 .agg() 등 데이터를 요약하는 메서드 직전에 사용
- ▶ 2개 이상의 변수를 기준으로 자료를 요약하는 경우 .agg() 메서드와 같이 리스트로 그 변수명을 묶어준다.

```
df.groupby("col_1")["col_2"].mean()
```

기준 변수 / 대상 변수 / 연산 규칙

https://datadoctorblog.com/2023/04/28/Py-Basic-Pandas-Groupby

```
1 df = pd.read_csv("diamonds.csv")
2 df.loc[:, "price"].agg(["mean"])
3 df.loc[:, "price"].agg(["max", "mean"])
4 df.groupby("cut")["price"].agg(["max", "min"])
5 df.groupby(["cut", "color"])["price"].agg(["max", "min"])
```

3) 파생변수 생성

다양한 변수 생성법

▶ 단순 조작: 정규화, 범주화 등 자기 자신만을 사용하여 생성

▶ 복수 변수 통합: 2개 이상의 변수를 산술연산 또는 특정 공식 기반으로 합쳐 새로운 변수를 만듦

※ 출근 소요시간 + 퇴근 소요시간 = 통근 시간

▶ 요약: 1:n 관계의 데이터의 경우 해당 데이터를 요약하며 대표값을 생성

※ 구매 데이터를 기반으로 고객의 월평균 구매금액 산출

4) 텍스트 데이터 처리

Pandas 기반의 텍스트 데이터 처리

▶ Pandas Series 객체의 .str 접근자(Accessor)에 텍스트 처리 메서드 내장
▶ 텍스트 처리 관련 함수 또는 메서드 사용시 자료 속성에 주의
※ 문자형이 아닐 시 .astype("str") 사용 권장

.str 접근자의 핵심 메서드

메서드	설명
.replace()	문자를 치환하며 regex인자에 True를 할당할 경우 정규표현식 사용 가능
.contains()	특정 문자 패턴을 만족하는 경우 True, 그렇지 않은 경우 False 반환
.split()	문자를 특정 문자 기준으로 분할하며 expand인자가 유용함
.len()	문자열의 길이 반환

4) 텍스트 데이터 처리

.str 접근자의 기타 메서드

메서드	설명
.str[0]	첫 번째 문자 추출
.str.get(-1)	마지막 문자 추출
✸ .slice()	지정된 범위의 문자 추출
✸ .extract()	조건(pat)에 맞는 텍스트를 추출하며 group을 지정해야 함
.lower()	영문 대문자를 영문 소문자로 치환
.zfill()	지정한 길이보다 문자열의 길이가 짧을 경우 앞에 숫자 0을 채워줌

4) 텍스트 데이터 처리

텍스트 데이터 처리 실습

```
df_tx = pd.DataFrame(dict(v1 = [100, 200, 300],
                          v2 = ["abc", "aaa", "ccc"],
                          v3 = [123, "1234-5678", "010-1234-5678"]))
df_tx
```

	v1	v2	v3
0	100	abc	123
1	200	aaa	1234-5678
2	300	ccc	010-1234-5678

4) 텍스트 데이터 처리

텍스트 데이터 처리 실습

```
df_tx["v2"].replace("a", "🔥")
df_tx["v2"].replace("aaa", "🔥")
df_tx["v2"].replace({"aaa": "🔥", "ccc": "💙"})
df_tx["v2"].str.replace("a", "🔥")
df_tx["v2"].str.replace("aaa", "🔥")
df_tx["v2"].str.contains("a")
~df_tx["v2"].str.contains("a")
```

```
df_tx.loc[ df_tx["v2"].str.contains("a"), ]
df_tx.loc[~df_tx["v2"].str.contains("a"), ]
```

4) 텍스트 데이터 처리

텍스트 데이터 처리 실습

```
df_tx["v3"].str.split("-")
```

```
0                  NaN
1          [1234, 5678]
2    [010, 1234, 5678]
Name: v3, dtype: object
```

```
df_tx["v4"] = df_tx["v3"].astype("str")
df_tx["v4"][0]
df_tx["v4"].str.split("-")
df_tx["v4"].str.split("-").explode()

df_tx_v4 = df_tx["v4"].str.split("-", expand = True)
df_tx_v4_2 = df_tx_v4.add_prefix("v4_") # .add_suffix() 도 있음
df_tx_v4_3 = df_tx_v4_2.fillna("🥗")
df_tx_v4_3
```

5) 시간 데이터 처리

Pandas 기반의 시간 데이터 처리

- ▶ datetime 라이브러리의 기능을 Pandas Series 객체에서 지원
- ▶ 문자 또는 숫자 원소는 Pandas의 to_datetime() 함수로 속성 변환 가능
- ▶ to_datetime() 함수의 format 인자를 활용할 경우 다양한 표현의 텍스트를 시간으로 변환 가능
- ▶ to_datetime() 함수의 origin 및 unit에 날짜 계산 기준 및 단위 지정 가능
- ▶ Pandas Series 객체의 .dt 엑세서(Accessor)에 시간 데이터 어트리뷰트 정보 내장
- ▶ .dt 엑세서에는 .year, .month, .hour 등 다양한 어트리뷰트를 사용하여 년, 월, 시각 등 정보 추출 가능

5) 시간 데이터 처리

Pandas 기반의 시간 데이터 처리

```
ser_t1 = pd.Series(["2077-12-18", "2077-12-19", "2077-12-20"])
ser_t2 = pd.Series(["2077년 12월 18일", "2077년 12월 19일", "2077년 12월 20일"])
ser_t3 = pd.Series([20241218, 20241219, 20241220])
ser_t4 = pd.Series([1234, 2345, 3456])
```

```
pd.to_datetime(ser_t1)
pd.to_datetime(ser_t2) # 에러!!
pd.to_datetime(ser_t2, format = "%Y년 %m월 %d일")
pd.to_datetime(ser_t3)
pd.to_datetime(ser_t3.astype("str"))
pd.to_datetime(ser_t4)
pd.to_datetime(ser_t4, origin = "2070-01-01", unit = "m")
```

5) 시간 데이터 처리

Pandas 기반의 시간 데이터 처리

```
df_dt2["datetime"] = pd.to_datetime(df_dt2["datetime"])
df_dt2["date"  ] = df_dt2["datetime"].dt.date
df_dt2["yyyymm"] = df_dt2["datetime"].dt.strftime("%Y-%m") # 기출🎯
df_dt2["year"  ] = df_dt2["datetime"].dt.year
df_dt2["month" ] = df_dt2["datetime"].dt.month
df_dt2["wday"  ] = df_dt2["datetime"].dt.weekday # 토: 5, 일: 6
df_dt2["wend"  ] = np.where(df_dt2["wday"] >= 5, 1, 0) # 주말 1, 주중 0
df_dt2["hour"  ] = df_dt2["datetime"].dt.hour
df_dt2["dt_s9h"] = df_dt2["datetime"] + pd.to_timedelta(9, unit = "h")
```

5) 시간 데이터 처리

Pandas 기반의 시간 데이터 처리

```
df_dt = pd.DataFrame(dict(date = ["2077-08-01", "2077-08-02", "2077-08-03"]))
df_dt["origin"] = "2077-01-01"
df_dt["date"  ] = pd.to_datetime(df_dt["date"])
df_dt["origin"] = pd.to_datetime(df_dt["origin"])
df_dt["diff"  ] = df_dt["date"] - df_dt["origin"]
df_dt["diff_d"] = df_dt["diff"].dt.days
df_dt
```

	date	origin	diff	diff_d
0	2077-08-01	2077-01-01	212 days	212
1	2077-08-02	2077-01-01	213 days	213
2	2077-08-03	2077-01-01	214 days	214

5) 시간 데이터 처리

Pandas - to_datetime()

- 문자형 데이터를 시간 데이터로 바꿔주는 함수
- YYYY-mm-dd HH:MM:SS 의 표준 형식 입력의 경우 바로 변환
- format 인자를 활용하여 다양한 형식을 표준 시간 데이터로 변환 가능
- origin 인자에 일자 지정 시 해당일 기준 경과일 계산 가능

Pandas - weekday

- 시간데이터에서 요일 정보를 담고 있는 어트리뷰트(attribute)
- 월요일이 0이고 일요일이 6으로 반환
- 유사 어트리뷰트로 year, month, hour 등 다양함

5) 시간 데이터 처리

lead - lag

Q. "v"변수에 결측이 존재하는 경우 해당 결측값의 직전값과 직후값 하나씩 선택하여 두 값의 평균을 산출하고 그 값으로 결측을 대치하시오.

※ 단, 연속된 결측치는 없음

```
df_t = pd.DataFrame(dict(date = pd.date_range("2024-01-01", "2024-01-07"),
                         v = [100, 200, 300, np.nan, 500, 600, 700]))
df_t["v_s1"] = df_t["v"].shift(1)
df_t["v_s2"] = df_t["v"].shift(2)
df_t["v_sn1"] = df_t["v"].shift(-1)
df_t["v_fill_1"] = np.where(df_t["v"].isna(),
                            (df_t["v_s1"] + df_t["v_sn1"]) / 2,
                            df_t["v"])
df_t["v_fill_2"] = df_t["v"].interpolate() # 보간법(기본 동작은 선형 보간)
```

6) Pivoting

Pandas - melt()

- wide form의 데이터프레임을 long form으로 자료구조를 변환하는 메서드
- id_vars 인자에 기준이 되는 변수를 지정하여 처리
- 통계 또는 머신러닝 실시 전에 데이터 구조를 맞추기 위해서 주로 활용

Pandas - pivot()

- long form의 데이터프레임을 wide form으로 자료구조를 변환하는 메서드
- index/columns/values 인자에 각각 대상 변수를 지정하여 출력 데이터 구조 결정
- 데이터를 요약하거나 군집분석 실시 전 데이터 전처리에 주로 활용
- .pivot() 는 .pivot_table() 로 대체 가능

  ※ 옛날 Pandas 버전의 .pivot() 은 다중 인덱스를 지원하지 않음

7) 데이터 병합

단순 병합 – pd.concat()

▶ Pandas 라이브러리의 concat() 함수로 데이터프레임 이어 붙이기
▶ axis 인자로 이어 붙이는 방향 설정 가능(0: row, 1: column)
▶ 함수 사용시 각 객체의 index로 인한 오동작 주의

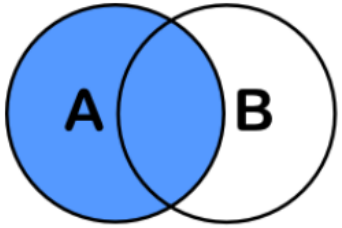
```
df_bike = pd.read_csv("bike.csv")
df_b1 = df_bike.iloc[:4, 4:7]
df_b2 = df_bike.iloc[1:5, 5:8]
```

```
pd.concat([df_b1, df_b2])
pd.concat([df_b1, df_b2], axis = 1)
pd.concat([df_b1, df_b2.reset_index(drop = True).add_suffix("_y")], axis = 1)
```

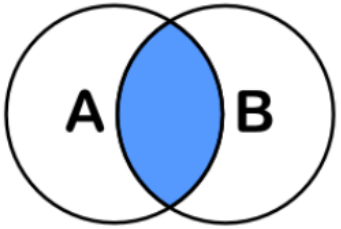
7) 데이터 병합

Join 연산

- Left Join



- Inner Join



관련 함수 및 메서드

함수 및 메서드	설명
merge()	변수를 기준으로 데이터 병합
join()	인덱스를 기준으로 데이터 병합

8) 고급 데이터 핸들링

lambda 함수

- 사용자 정의 함수 대신 사용가능한 일회성 함수
- 별도의 함수명을 지정하지 않고 사용하고자 하는 경우 유용
- lambda 함수의 x 인자에는 기본적으로 Series 객체가 인입됨
- 간단한 로직을 구현할 때 사용되며 좀 더 복잡한 로직 구현이 필요한 경우 사용자 정의 함수로 대체 가능
- crosstab(), .pivot_table(), .agg(), apply() 에 주로 사용

```
1 df_bike = pd.read_csv("bike.csv")
2 df_bike.groupby("season")["count"].agg(lambda x: round(x.mean()))
```

season 별로 쪼개진 “count”의 원소가 Series 객체로 lambda 에 인입됨

8) 고급 데이터 핸들링

정규표현식(Regular Expression)

- ▶ 특정한 규칙을 가진 문자열의 집합을 표현하는 데 사용하는 형식 언어
- ▶ 정규 표현식은 많은 텍스트 편집기와 프로그래밍 언어에서 문자열의 검색과 치환을 위해 지원하고 있음
- ▶ Pandas Series 객체의 .str accessor의 각종 메서드에서 정규표현식을 지원
- ▶ 시험범위는 아니나 숙지할 경우 보다 수월한 문제 풀이 가능

정규표현식(regular expression) 주요 문법

문법	설명
{n}	직전 문자를 n번 반복
✸ ab{4}	a 다음에 b가 위치하며 b가 4번 반복됨(abbbb)
{n,}	직전 문자가 n번 이상 반복
✸ {n,m}	직전 문자가 n번 이상 m번 이하 반복
ab(0|1)	ab0 또는 ab1
₩t	탭(tab)

8) 고급 데이터 핸들링

정규표현식(regular expression) 주요 문법

문법	설명
^	시작
$	끝
.	모든 문자열
₩.	마침표
[0-9]	숫자
[a-z]	모든 영문 소문자
[A-Z]	모든 영문 대문자
[a-zA-Z]	모든 영문자
[ㄱ-ㅎ]	한글 초성
[가-힣]	한글 완성형
[^0-9]	숫자가 아닌 모든 문자
ab|cd	ab 또는 cd
<.*?>	<로 시작하고 >로 끝나는 모든 패턴(<>, <a>, 등)



실기 대비

실전 문제풀이
set 1



1) 데이터 및 시나리오

시중 TV 제품별 분석

▶ 시중 판매 중인 TV정보를 온라인 쇼핑몰 웹페이지에서 크롤링 하여 분석을 하고자 한다. 해당 데이터를 기반으로 각 TV의 제원은 어떠 한지 제원에 따른 평가는 어떠 한지 알아보고 향후 신제품 출시에 참고하고자 한다. 단, 데이터가 수집되는 과정에서 실수가 있어 특정 열에 올바른 정보가 기입되어 있지 않은 경우가 있으니 분석에 주의하도록 한다.

데이터 개요



set_01_data.csv : 666 rows, 11 columns, UTF-8

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
Id	string	상품 고유 식별자
Stars	float	평가 평균 점수
Ratings	int	평가 수
Reviews	int	후기 수
current_price	int	현재 가격
MRP	int	공장 출고가
channel	string	프리미엄 채널 서비스 제공 목록
Operating_system	string	운영체제
Picture_quality	string	해상도
Speaker	string	스피커
Frequency	string	주사율

2) 문제

필요 라이브러리 함수 및 클래스 목록

목록
from sklearn.cluster **import** KMeans
from sklearn.ensemble **import** RandomForestRegressor

2) 문제

**Q01. 주사율(Frequency)은 TV 제원 중 가격에 큰 영향을 미치는 제원이다.
그런데 데이터 수집 중 실수가 발생하여 주사율(Frequency) 값 중 일부가 해상도(Picture_quality), 스피커(Speaker) 변수에 잘못 입력된 것이 발견되었다. 세 변수에 흩어져 있는 주사율 데이터를 취합하여 전체 TV 중에서 주사율이 60Hz인 TV는 총 몇 대 인가?**

※ 주사율은 2~3자리 숫자 뒤에 한 칸 띄어쓰기 후 "Hz"로 표기되어 있다. (ex. '60 Hz')

※ 세 변수 모두 주사율 정보가 없을 경우 결측치로 간주하고 이를 분석에서 제외하시오.

※ 결과는 정수로 산출하시오.

(정답 예시: 12)

2) 문제

Q02. TV의 해상도는 다양하지만 그 중 4K제품에 대해서 조사해보고자 한다. 신규 제품 개발 방향을 설정하기 위해 시장에 출시된 다양한 4K 제품군을 군집분석을 사용하여 군집을 확인해보고 이를 기반으로 향후에 정성분석을 실시하고자 한다. 4K 제품의 데이터 중 수치형 변수 5개를 대상으로 k-means 군집분석 알고리즘을 적용해보고 3개 군집으로 나눴을 때 군집 크기가 가장 큰 군집에 해당하는 상품 수를 확인하시오.

※ 4K 제품군은 "4K"로 화면 해상도 관련 변수에서 찾아낼 수 있다.
※ 화면 해상도 정보는 "Operating_system", "channel", "Picture_quality" 변수에 흩어져 있다.
※ 분석 대상인 4K 제품군 중 "Stars", "Ratings", "Reviews" 변수의 값이 하나라도 0인 데이터는 제외 후 분석하시오.
※ seed는 123으로 지정하시오.
※ 결과는 정수로 산출하시오.
(정답 예시: 12)

2) 문제

Q03. 좋은 평가를 받는 제품의 조건을 알아보고자 한다. 이를 위해 기존 변수와 더불어 여러 파생변수를 생성 후 해당 변수를 독립변수로 하고 평가 평균 점수(Stars)를 종속변수로 하여 Random Forest 분석을 통해 좋은 평가를 받는 제품의 조건을 알아보고자 한다. 아래 절차를 수행하여 변수 중요도를 확인하고, 그 값 중 가장 큰 값을 가진 변수명을 확인하시오.

<독립변수>
1) 후기 작성 비율: 후기 수(Reviews)/평가 수(Ratings)
2) 공장 출고가(MRP)
3) 할인율: 현재 판매가(current_price)/공장 출고가(MRP)
4) Netflix 제공 여부: 제공(1), 미제공(0)
5) Prime Video 제공 여부: 제공(1), 미제공(0)
6) 고해상도 여부: 4K 또는 8K(1), 나머지 0

<종속변수>
- 평가 평균 점수(Stars)

※ channel 변수에 해상도('Pixel' 문자 참조) 또는 운영체제 정보('Oper' 문자 참조)가 있는 TV는 분석에서 제외하시오.
※ Netflix와 Prime Video 제공여부 변수는 각각 channel 변수를 기반으로 생성하시오.
※ 독립변수를 생성하면서 결측치가 생성되는 경우 해당 행을 모두 제거하시오.
※ 학습 대상이 되는 행 개수는 200이다.
※ 머신러닝 모델 학습 시 독립변수의 순서는 제시된 번호 순서대로 왼쪽에서 오른쪽으로 배치하시오.
※ 고해상도 여부 변수 생성은 해상도(Picture_quality) 변수만 사용하여 생성하시오.
※ seed는 123으로 지정하시오.
(정답 예시: 고해상도여부 - 띄어쓰지 않고 문제에서 제시된 독립변수 명을 기입)



실기 대비

실전 문제풀이
set 2



1) 데이터 및 시나리오

갤럭시 사용자 데이터 분석

▶ 디지털 기기 취급 전문업체 DigiSales는 오프라인 매장에서 갤럭시 제품군을 구매한 이력이 있는 사람들의 단말기 이용 행태를 분석하기 위해 통신사 MT로 부터 익명화 처리된 고객 정보를 일부 구매하였다.
해당 데이터에서 인사이트를 뽑기 위해 다양한 분석을 해보고자 한다.

데이터 개요



set_02_data.csv : 6465 rows, 21 columns, UTF-8

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
customerID	string	고객 식별자
gender	string	성별
SeniorCitizen	int	시니어 여부(1: 시니어, 0: 시니어 아님)
Partner	string	배우자 존재 여부(Yes: 있음, No: 없음)
Dependents	string	부양가족(Yes: 있음, No: 없음)
tenure	int	현 직장 근속 월수
PhoneService	string	단말 서비스 사용 여부(Yes: 사용 중, No: 해지)
MultipleLines	string	다중 회선 개통 여부(Yes: 사용 중, No: 미사용)
InternetService	string	인터넷 사용(DSL: 저속 서비스, Fiber optic: 고속 서비스, No: 안함)
OnlineSecurity	string	온라인 보안 서비스(Yes: 사용 중, No: 미사용)
OnlineBackup	string	온라인 백업 서비스(Yes: 사용 중, No: 미사용)

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
DeviceProtection	string	기기 보호 서비스(Yes: 사용 중, No: 미사용)
TechSupport	string	기술 지원 서비스(Yes: 사용 중, No: 미사용)
StreamingTV	string	스트리밍 지원 TV(Yes: 사용 중, No: 미사용)
StreamingMovies	string	영화 스트리밍 서비스(Yes: 사용 중, No: 미사용)
Contract	string	계약 갱신 주기
PaperlessBilling	string	온라인 명세서 발급 서비스(Yes: 사용 중, No: 미사용)
PaymentMethod	string	납부 방법
MonthlyCharges	float	월별 청구 금액
TotalCharges	float	누적 청구 금액
Churn	string	이탈 여부(Yes: 이탈, No: 잔존)

2) 문제

필요 라이브러리 함수 및 클래스 목록

목록
from sklearn.linear_model **import** LogisticRegression
from sklearn.metrics **import** f1_score

2) 문제

Q01. 부가 서비스를 많이 사용할수록 제품 또는 브랜드에 고관여 되어있다는 가설을 세우고 분석을 하고자 한다. 이에 앞서 시니어가 아닌 남성 고객을 대상으로 고객별 부가서비스 사용 현황 통계를 산출하고자 한다. 부가 서비스를 1개 사용하는 사람은 부가 서비스를 6개 사용하는 사람보다 몇 배나 많은지 계산하시오.

※ 부가서비스 대상 변수: OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies
※ 부가서비스 변수의 범주가 "Yes"인 경우 해당 부가서비스를 이용하는 것으로 한다.
※ 부가서비스 변수에 "Yes" 또는 "No"가 아닌 다른 범주가 있는 경우 해당 행은 제거 후 분석하시오.
※ 첫 번째 고객(6682-VCIXC)의 경우 부가서비스를 4개 이용 중이다.
※ 정답은 소수점 둘째자리 아래로 버림하고 소수점 둘째 자리까지 산출하시오.
(정답 예시: 1.23)

2) 문제

Q02. 고객의 가입 기간과 현 직장 근속 월수(tenure), 월별 청구 금액(MonthlyCharges)간 관계를 알아보고자 한다. 먼저 납부 방식을 자동이체 또는 자동결제로 처리하는 고객과 그렇지 않은 고객을 따로 분석하고 해당 고객군의 특성을 향후에 분석해보고자 한다. 그래서 각 고객군 별로 "고객 가입 기간"과 같이 살펴볼 변수인 "근속 월수", "월별 청구 금액" 변수를 피어슨 상관분석을 실시해보자. 납부 방식을 자동이체 또는 자동결제로 처리하는 고객을 대상으로 산출한 피어슨 상관계수 중 최댓값을 A, 납부 방식을 자동이체 또는 자동결제로 처리하지 않는 고객을 대상으로 산출한 피어슨 상관계수 중 최댓값을 B라고 할 때, A-B 를 구하시오.

※ "고객 가입 기간"은 총 청구금액(TotalCharges)을 월별 청구금액(MonthlyCharges)으로 나눈 값의 몫으로 한다.

※ 본 문제 풀이에 계약 갱신 주기(Contract)는 관련없음.

※ 납부를 자동이체 또는 자동결제로 처리하는 고객은 "PaymentMethod"변수의 값에 "automatic"이 포함되어 있다.

※ 정답은 절댓값을 반올림하여 소수점 넷째 자리까지 산출하시오.

(정답 예시: 0.123)

2) 문제

Q03. 고객 이탈여부(Churn)를 종속변수로 하는 모델을 만들어보고자 한다.
데이터 분할 후 정규화를 실시하여 로지스틱 회귀분석을 실시하고 해당 모델을 기준점 삼아 모델을 개선하고자 한다.
주어진 독립변수를 활용하여 F1-score로 모델을 평가하시오.

<독립변수>

1) 시니어 여부
2) 파트너 존재 여부
3) 부양가족 존재 여부
4) 현 직장 근속 개월 수
5) 월별 청구 금액
6) 누적 청구 금액
7) 온라인 보안 서비스
8) 온라인 백업 서비스
9) 기기 보호 서비스
10) 기술 지원 서비스
11) 영화 스트리밍 서비스
12) 온라인 명세서 발급 서비스

<종속변수>

- 고객 이탈여부

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} \qquad Precision = \frac{TP}{TP + FP} \qquad Recall = \frac{TP}{TP + FN}$$

※ 범주형 변수의 범주가 "Yes"인 경우 1로, "No"인 경우 0으로 치환하고, 나머지 범주는 -1로 치환하시오.
※ 고객 식별자(customerID)에 있는 숫자가 4의 배수가 아닌 고객 데이터를 학습 데이터, 나머지를 평가 데이터로 하시오.
※ 정규화는 Min-Max 정규화를 실시하며 모든 수치형 독립변수를 대상으로 하시오.
※ 평가 데이터 세트는 학습 데이터 세트 기반으로 정규화 하시오.
※ 머신러닝 모델 학습 시 독립변수의 순서는 제시된 번호 순서대로 왼쪽에서 오른쪽으로 배치하시오.
※ seed는 123으로 고정하시오.
※ 정답은 반올림하여 소수점 둘째 자리까지 산출하시오.
(정답 예시: 0.12)



실기 대비

실전 문제풀이
set 3



1) 데이터 및 시나리오

시중 스마트폰 상세 정보

▶ 갓 입사한 신입사원 김모씨는 기획 부서에 배치되었다. 첫 프로젝트로 신규 스마트폰 스팩 기획 업무를 보조하게 되었다. 장고 끝에 김씨는 온라인 디지털 마켓 사이트 "디판다요"에서 판매중인 스마트폰 데이터를 수집하여 이를 분석하고 향후 프로젝트의 백데이터로 활용하기로 결심하였다.

데이터 개요

set_03_data.csv : 430 rows, 11 columns, UTF-8

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
screen_size	string	화면 크기
ROM	int	저장 공간 용량
RAM	int	RAM 용량
n_rear_cam	int	후면 카메라 개수
n_front_cam	int	전면 카메라 개수
battery_c	int	배터리 용량
ratings	float	평가 점수 평균
n_ratings	int	평가 개수
sales_p	int	판매가격
discount_p	float	할인율
sales_idx	float	판매 지수

2) 문제

필요 라이브러리 함수 및 클래스 목록

목록
from sklearn.cluster **import** KMeans
from sklearn.neighbors **import** KNeighborsRegressor

2) 문제

Q01. 스마트폰의 경우 많은 제품이 출시되지만 정작 주목받는 제품은 극히 적다고 한다. 판매지수(sales_idx)를 기준으로 이상치라고 판단되는 제품을 주목받는 제품이라고 판단하고 해당 제품들의 성능지표를 산출하시오.
산출된 성능지표의 평균은 얼마인가?

<성능지표 계산식>

$$\text{성능지표} = \frac{ROM}{32} + \frac{RAM}{2} + \text{카메라 개수} + \frac{\text{배터리 용량}(battery_c)}{1000}$$

※ 카메라 개수: 후면 카메라 개수(n_rear_cam) + 전면 카메라 개수(n_front_cam)
※ 이상치는 평균을 기준으로 2 표준편차보다 큰 값으로 정의한다.
※ 결과는 반올림하여 소수점 둘째 자리까지 산출하시오.
(정답 예시: 0.12)

2) 문제

Q02. 스마트폰 제품을 군집화 하여 살펴보고자 한다. k-means 군집분석 알고리즘으로 군집분석을 실시했을 때 군집 개수를 3개로 하여 분석하는 것이 좋을지 4개로 분석하는 것이 좋을지 관계자간 의견이 분분하다. 그래서 보다 합리적인 의사결정을 위해 4개 군집으로 수행한 결과를 추가로 살펴보기로 하였다. 화면 크기(screen_size)를 제외한 모든 변수를 k-means 알고리즘을 사용하여 4개 군집으로 나누고, 군집 중 배터리 용량(battery_c)이 가장 큰 군집의 중심점(centroid)과 유클리드 거리 기준으로 가장 가까운 군집의 중심점 거리를 산출하시오.

※ 군집분석을 수행하는 데이터와 중심점 계산 데이터는 모두 표준화(standardized)된 데이터를 사용하시오.

※ seed는 123으로 지정하시오.

※ 결과는 반올림하여 소수점 둘째 자리까지 산출하시오.

(정답 예시: 0.12)

2) 문제

Q03. 판매 지수(sales_idx)를 예측하기 위해 k-NN 머신러닝 모델을 활용하고자 한다. 최적의 이웃 개수(k)를 선정하기 위해 k를 3부터 11까지 증가시키면서 RMSE(Root Mean Squared Error)를 기준으로 그 결과를 보고자 한다. 우선 다음의 지시사항에 따라 최적의 k를 확인하시오.

단계1) 명목형 변수인 화면 크기(screen_size)를 One Hot Encoding을 실시하여 더미변수 생성
단계2) Scikit Learn라이브러리의 train_test_split() 클래스로 학습 데이터와 평가 데이터 분할
단계3) 단계2의 데이터를 Min-Max 정규화 실시
단계4) 단계3의 데이터를 사용하여 k값을 변화시키며 k-NN 분석을 실시하고 최적의 k 탐색
단계5) 단계4에서 확보한 최적의 k 기반으로 산출한 모델을 “model_best”로 지칭

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

※ 학습 및 평가 데이터 세트 분할비는 8:2으로 하시오.
※ 정규화 시 평가 데이터 세트는 학습 데이터 세트 기반으로 정규화 하시오.
※ k-NN 모델에 들어가는 종속변수는 판매지수(sales_idx)이며 나머지 모든 변수(더미변수 포함)가 독립변수이다.
※ k-NN 모델 학습 시 입력하는 독립변수의 순서는 최초 데이터의 순서를 따르되 더미변수는 가장 오른쪽에 위치 시키시오.
※ One Hot Encoding으로 생성된 더미변수는 각 변수의 명을 사전 기준(A->Z, a-z)으로 왼쪽에서 오른쪽으로 배치하시오.
※ seed는 123으로 고정하시오.
※ 최근접 이웃은 3, 5, 7, 9, 11개를 사용하시오.

2) 문제

Q03. 앞에서 생성한 "model_best"를 활용하고자 한다. 마침 저번달에 신규 출시된 경쟁사의 스마트폰 데이터를 확보하였고, "model_best"를 사용하여 해당 스마트폰의 판매지수를 예측해보고자 한다.
다음의 지시사항과 데이터를 기반으로 신규 출시된 경쟁사의 스마트폰 판매지수 예측값을 산출하시오.

단계6) 확보한 데이터는 기존 원핫인코딩 규칙을 기반으로 더미변수 생성
단계7) 기존 정규화 규칙을 기반으로 주어진 데이터를 정규화
단계8) "model_best"에 단계7 에서 산출한 데이터 세트를 입력하고 그 예측값을 산출
단계9) 단계8 에서 산출한 예측값을 기존 정규화 규칙을 기반으로 역변환

<확보 데이터>

ROM: 256	n_front_cam: 1	n_ratings: 25000	screen_size: Large
RAM: 6	battery_c: 4000	sales_p: 85000	
n_rear_cam: 4	ratings: 4.3	discount_p: 0.05	

※ 단계8 수행 시 독립변수의 순서는 기존 모델인 "model_best"와 일치 시키시오.
※ 정답은 반올림하여 소수 둘째 자리까지 산출하시오.
(정답 예시: 0.12)



실기 대비

실전 문제풀이
set 4



1) 데이터 및 시나리오

디지털프라자 매출 데이터

▶ 디지털프라자 A지점에서 최근 연휴 직전에 재고 처리와 매출 신장을 위해 대대적인 할인 행사를 하였다. 하루만 반짝 진행한 행사에서 예상보다 많은 5880명이 방문했고 이번에 발생한 매출데이터를 취합하여 향후 발송할 판촉물에 들어갈 컨텐츠를 기획하고자 한다. 취합한 데이터는 다음과 같고 한 개의 행이 물품 1개 구매 내역이다.

데이터 개요



set_04_data.csv : 200000 rows, 11 columns, UTF-8

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
user	int	고객 식별자
prod	string	상품 식별자
gender	string	고객의 성별
age_group	string	고객의 연령대
job	int	고객의 직업 구분
City	string	고객의 거주지
Marital	int	결혼 여부(1: 결혼)
prod_cat1	int	상품 카테고리(대)
prod_cat2	int	상품 카테고리(중)
prod_cat3	int	상품 카테고리(소)
purchase	int	결제 금액

2) 문제

필요 라이브러리 함수 및 클래스 목록

목록
from sklearn.cluster **import** KMeans
from sklearn.metrics **import** silhouette_score

2) 문제

Q01. 직업(job)번호가 20인 남성의 데이터를 사용하여 제품 구매 확률을 계산하고자 한다. 대 카테고리(prod_cat1)가 5인 제품의 구매 확률은 얼마인가?

※ 각 행은 제품 1개의 구매 데이터이며 각 행을 기준으로 문제를 풀이 하시오.
※ 분석에서 거주지(city)가 2개 이상이 기록된 고객의 데이터는 제외한다.
※ 고객 식별자(user)가 1665인 고객은 거주지가 "B"와 "D"로 총 2개이다.
※ 정답은 반올림하여 소수 셋째 자리까지 산출하시오.
(정답 예시: 0.123)

2) 문제

Q02. 결혼 여부(marital)에 따라 구매하는 물품의 종류가 많이 차이 나는지 확인하고자 한다. 비교적 신혼부부가 많은 26-35세 그룹을 대상으로 각 고객의 구매물품 데이터에서 고유 카테고리 수를 산출하고 결혼여부별로 그 평균값의 차이를 산출하시오.

※ 구매 물품의 카테고리 개수 산출에는 prod_cat1, prod_cat2, prod_cat3 변수를 사용한다.

※ 물품 카테고리 관련 변수로 카테고리 ID 변수를 신규 생성하여 처리하는 것을 권장하며 예시는 다음과 같다.

prod_cat1	prod_cat2	prod_cat3	prod_cat
12	0	0	12-0-0
16	0	0	16-0-0

※ 고객 식별자가 1인 고객은 총 12개 물품을 구매하였고 해당 물품의 고유한 카테고리 수는 9이다.

※ 정답은 절대값을 반올림하여 소수점 둘째 자리까지 산출하시오.

(정답 예시: 0.12)

2) 문제

Q03. 고객별로 데이터를 취합하고 이를 군집화 하여 각 군집별로 마케팅 전략을 수립하고자 한다. 다음에 제시된 변수와 지시사항을 참고하여 k-means 군집분석을 실시하고 7개 군집으로 분석했을 때 Silhouette score 를 산출하시오.

단계1) 거주지(city)가 2개 이상이 기록된 고객 데이터는 제외
단계2) 단계1의 데이터에서 user, gender, age_group, job, city, marital 순으로 변수를 뽑아 고객 고유정보 산출
단계3) 고객별로 “구매 상품 종류수”와 “구매 금액 총액” 변수를 산출
단계4) 단계2의 데이터와 단계3의 데이터를 병합
단계5) 단계4의 데이터를 기반으로 “gender”와 “age_group” 변수 원소를 치환
단계6) 단계5의 데이터의 범주형 변수(job, city)에 대해 One Hot Encoding을 실시하여 더미변수 확보 및 병합
단계7) 단계6의 데이터 전체에 대해 Min-Max 정규화 실시
단계8) 단계7의 데이터를 사용하여 k-means 군집분석 실시

※ 고객 식별자(user)가 1665인 고객은 거주지가 "B"와 "D"로 총 2개이다.
※ “구매 상품 종류수” 변수는 "prod" 변수를, “구매 금액 총액” 변수는 “purchase”를 사용하여 생성하시오.
※ 성별 변수는 "gender" 변수에서 "M"을 1, "F"를 0으로 변환하여 사용하시오.
※ 나이는 "age_group" 변수에서 나이가 가장 적은 그룹을 0, 가장 나이가 많은 그룹은 6으로 총 7개 원소를 등간격의 정수로 치환하시오.
※ One Hot Encoding으로 생성된 더미변수는 각 변수의 명을 사전 기준(A->Z, a-z)으로 왼쪽에서 오른쪽으로 배치하시오.
※ 군집 분석에 사용되는 변수는 총 30개로 고객 식별자(user)는 포함되지 않는다.
※ seed는 123으로 지정하시오.
※ 결과는 반올림하여 소수점 둘째 자리까지 출력하시오.(정답 예시: 0.12)



실기 대비

실전 문제풀이
set 5



1) 데이터 및 시나리오

신용카드 고객정보 분석

▶ 삼성전자의 고객 마케팅에 활용하기 위하여 삼성 카드 측에서 비식별화된 고객 데이터를 협조 받아 통합 분석을 하기 위한 선제 분석을 하고자 한다.

※ 분석 수행 전 '기한 내 최소 지불 금액(MINIMUM_PAYMENTS)'의 결측 값(Null)을 변수의 평균값으로 치환하시오.

전처리 수행 결과를 base 객체로 지칭하고 다음 문항에서 해당 객체를 기반으로 문제를 풀이하시오.

데이터 개요



set_05_data.csv : 1000 rows, 18 columns, UTF-8

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
cust_id	int	고객 ID
balance	float	연간 평균 잔고액
balance_freq	float	연중 잔고액 갱신 개월 수 비율(0~1 사이값)
purchases	float	구매 총액
oneoff_p	float	일시불 구매 총액
installments_p	float	할부 구매 총액
cash_advance	float	현금서비스 구매 총액
p_freq	float	연중 구매 개월 수 비율(0~1 사이값)
oneoff_p_freq	float	연중 일시불 구매 개월 수 비율(0~1 사이값)
p_installments_freq	float	연중 할부 구매 개월 수 비율(0~1 사이값)

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
cash_advance_freq	float	연중 현금서비스 구매 개월 수 비율
cash_advance_trx	int	현금 서비스 구매 횟수
p_trx	int	구매 횟수
credit_limit	int	신용카드 한도
payments	float	지불 총액
minimum_payments	float	기한 내 최소 지불 금액
pre_full_payment	float	연중 기한 내 전액 지불 개월 수 비율 (0~1 사이값)
tenure	float	신용카드 서비스 이용기간

2) 문제

필요 라이브러리 함수 및 클래스 목록

목록
from sklearn.cluster **import** KMeans
from sklearn.metrics **import** silhouette_score
from sklearn.tree **import** DecisionTreeRegressor
from statsmodels.api **import** OLS
from statsmodels.api **import** add_constant

※ 최신버전

- **from** statsmodels.regression.linear_model **import** OLS
- **from** statsmodels.tools **import** add_constant

2) 문제

Q01. (base를 사용하여)연간 평균 잔고액과 신용카드 서비스 이용기간 간의 관계를 파악하여, 추후 고객의 신용카드 한도 조정에 근거 자료로 활용하고자 한다. 신용 카드 서비스 이용기간(tenure) 별로 연간 평균 잔고액 (balance)과 신용카드 한도(credit_limit) 간 피어슨(Pearson) 상관 분석을 실시하고, 이 중 가장 큰 상관계수를 구하시오.

※ 구매 총액(purchases)이 0인 고객 데이터는 분석에서 제외하시오.

※ 정답은 반올림하여 소수점 둘째 자리까지 산출하시오.

(정답 예시: 0.12)

2) 문제

**Q02. (base를 사용하여)전략을 수립하기 위해 고객 세분화를 수행하고자 한다.
일시불 구매 금액이 높은 고객군을 도출하기 위해 다음 단계에 따라 분석을 수행하고자 한다.
다음의 지시사항에 따라 k-means 군집분석을 활용하여 각 군집별 일시불 구매 총액(oneoff_p)의 평균을 산출하고 그 중 최댓값을 확인하시오.**

단계1) 고객 ID(cust_id)를 제외한 모든 변수에 대해 Z-score 표준화(Standardization) 실시
단계2) 단계1의 데이터를 사용하여 k-means 군집 분석 실시
단계3) 단계2에서 k(군집 개수)을 2에서 5까지 1씩 증가시키며 실루엣 점수(silhouette score)를 산출
단계4) 단계3에서 산출한 실루엣 점수를 기반으로 최적의 k를 확인
단계5) 단계4에서 확인한 최적의 k를 기반으로 k-means 모델을 확보하며 이를 “model_best”로 지칭
단계6) “model_best”로 도출한 각 군집 별로 일시불 구매 총액(oneoff_p)의 평균의 최댓값을 산출

※ 정규화를 실시하지 않은 일시불 구매 총액 데이터를 기준으로 “단계 6”의 평균값을 산출하시오.

※ seed는 1234로 설정하시오.

※ 정답은 반올림하여 소수점 둘째 자리까지 산출하시오.

(정답 예시: 0.12)

2) 문제

Q03. (base를 사용하여) 일시불 구매 총액(oneoff_p)을 예측하는 모델을 마케팅에 활용하고자 한다. 그런데 예측 모델에 사용할 알고리즘을 결정하지 못하여 간단히 알고리즘별 성능을 비교하고자 한다. 여기서 비교해볼 알고리즘은 "의사결정나무 회귀모델"과 "선형회귀모델"이다. 다음의 지시사항에 따라 각 모델을 평가하기 위한 지표 "R"을 모델별로 산출하고 그 차이를 확인하시오.

단계1) "oneoff_p"변수와 "freq" 글자가 포함된 변수를 준비하시오
단계2) 고객 ID(cust_id)가 4의 배수가 아닌 데이터를 Train Set으로, 4의 배수인 데이터를 Test Set으로 분할
단계3) 독립 변수(고객 ID, 일시불 구매 총액을 제외한 모든 변수)와 종속 변수(일시불 구매 총액) 준비
단계4) 의사결정나무 회귀모델로 "R"값을 산출
단계5) 선형 회귀모델로 "R"값을 산출
단계6) 단계3과 단계4에서 산출한 R값의 차이 계산

$$R = \left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y_i})^2\right)^{\frac{1}{2}}, \qquad \hat{y_i}: \text{예측값}, \ y_i: \text{실제값}$$

※ 의사결정나무 모델의 경우 최대 가지 깊이를 5로 설정하시오.
※ 선형회귀 모델의 경우 statsmodels 라이브러리의 OLS() 를 사용하시오.
※ 절편이 있는 선형회귀 모델 적합을 위해 학습/평가 데이터에 statsmodels 라이브러리의 add_constant() 함수를 사용하시오.
※ 선형회귀의 경우 음수로 예측된 값은 0으로 치환 후 R값 계산
※ seed는 1234로 설정하시오.
※ 정답은 절대값을 반올림하여 소수점 둘째 자리까지 산출하시오.
(정답 예시: 0.12)



실기 대비

실전 문제풀이
set 6



1) 데이터 및 시나리오

교육 수강자 분석

▶ 삼성전자 임직원의 체계적인 커리어 패스 설계를 위해 데이터 분석과 같은 Hard Skill 역량과 Soft Skill 역량을 조화롭게 함양하기 위해 HRD 부서의 조프로는 전산팀의 협조를 받아 데이터를 확보하였다.

※ 분석을 수행하기 전, 상기 데이터를 이용하여 아래의 전처리를 수행하시오.

단계1) 분석에 사용하지 않을 city, company_size, company_type 변수를 제거하시오.
단계2) 각 문자형 변수에 결측치가 하나라도 존재하는 행은 모두 제거하시오.
단계3) exp변수 값이 '>20' 또는 '<1'이 있는 행을 제거하고 exp변수의 유형을 정수로 변환하시오.
단계4) last_new_job 변수의 값이 '>4' 또는 'never'인 행을 제거하고 해당변수의 유형을 정수로 변환하시오.

전처리 수행 후 행 개수는 7,522이며 해당 데이터를 base 객체로 지정하고 이를 사용하여 문제를 풀이하시오.

데이터 개요



set_06_data.csv : 19158 rows, 15 columns, UTF-8

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
enrollee_id	int	수료자 ID
city	string	도시 코드
city_development_index	float	도시 발전 지표
gender	string	성별
relevant_exp	string	관련 분야 경험 여부
enrolled_university	string	수강 과목명
edu_level	string	학력
major_discipline	string	전공
exp	string	경력
company_size	string	현 직장 직원 수

1) 데이터 및 시나리오

변수 상세

변수명	유형	설명
company_size	string	현 직장 직원 수
company_type	string	현 직장 유형
last_new_job	string	전 직장 근속연수
training_hours	int	수료 시간
target	int	전배 희망 여부 (0: 비희망, 1: 희망)
Xgrp	string	Train/Test Set 구분

2) 문제

필요 라이브러리 함수 및 클래스 목록

목록
from sklearn.linear_model **import** LogisticRegression
from sklearn.neighbors **import** KNeighborsClassifier

2) 문제

Q01. (base를 사용하여)관련 분야 경험 여부(relevant_exp)에 따른 전배 희망 여부(target)를 기술통계량으로 확인하고자 한다. 관련 분야 경험이 없는 수료자 중 전배를 희망하는 수료자의 비율을 A, 관련 분야 경험이 있는 수료자 중 전배를 희망하는 수료자의 비율을 B라 할 때, A/B를 구하시오.

※ 분석 대상은 학력(edu_level)이 석사(Masters)와 박사(Phd)인 사람을 대상으로 한다.
※ 관련 경험이 없는 사람은 relevant_exp 변수의 값이 'No'인 사람으로 정의한다.
※ 관련 경험이 있는 사람은 relevant_exp 변수의 값이 'Has'인 사람으로 정의한다.
※ 정답은 반올림하여 소수점 둘째 자리까지 산출하시오.
(정답 예시: 0.12)

2) 문제

Q02. (base를 사용하여) 전배 희망 여부(target)에 영향을 주는 변수들을 확인하고자 한다. 다음 절차에 따라 로지스틱 회귀모델을 사용한 분석을 수행하고 해당 모델에서 산출하는 각 독립변수의 승산비(Odds Ratio) 중 가장 큰 값을 확인하시오.

단계1) gender, relevant_exp, enrolled_university, edu_level, major_discipline 변수를 대상으로 One Hot Encoding을 실시
단계2) 각 변수로부터 더미 변수를 생성할 때 마지막(사전순, 가장 오른쪽)에 위치한 더미 변수 제거
단계3) 단계2에서 생성한 더미 변수와 city_development_index, exp, last_new_job, training_hours, target, Xgrp 변수를 결합하여 새로운 데이터셋 (데이터셋명: job2, 이 데이터셋은 문제 3에서도 활용)을 구성한다. 이 때, target, Xgrp를 제외한 데이터셋의 변수는 아래 순서를 따른다.

- city_development_index
- exp
- last_new_job
- training_hours
- gender의 더미 변수
- relevant_exp의 더미 변수
- enrolled_university의 더미 변수
- education_level의 더미 변수
- major_discipline의 더미 변수

2) 문제

Q02. (base를 사용하여) 전배 희망 여부(target)에 영향을 주는 변수들을 확인하고자 한다. 다음 절차에 따라 로지스틱 회귀모델을 사용한 분석을 수행하고 해당 모델에서 산출하는 각 독립변수의 승산비(Odds Ratio) 중 가장 큰 값을 확인하시오.

단계4) 단계 3에서 구성한 데이터셋 job2로 다음 조건에 따라 상수항(Intercept)이 포함된 로지스틱 회귀분석 실시
- 종속 변수 : target
- 독립 변수(총 16개) : target과 Xgrp를 제외한 나머지 변수
- 회귀식에 포함되는 독립 변수의 순서를 컬럼의 순서와 일치시킨다.

$$x_i\text{의 Odds Ratio} = \frac{odds(P(Y=1|x_1,\dots,x_i+1,\dots,x_n))}{odds(P(Y=1|x_1,\dots,x_i,\dots,x_n))}$$

※ LogisticRegression() 클래스 사용 시 C=100000, max_iter=1000, solver='liblinear'으로 지정하시오.

※ seed는 1234로 설정하시오.

※ 정답은 소수점 셋째 자리에서 버림하여 둘째 자리까지 산출하시오.

(정답 예시: 0.12)

2) 문제

Q03. (job2를 이용하여) 전체 데이터를 학습 및 평가 데이터로 분할하고 k-NN모델을 사용했을 때 그 성능을 확인하고자 한다. 성능은 평가 데이터의 실제값과 예측값을 지표 A를 기준으로 확인하고자 한다.

단계1) job2에서 Xgrp 컬럼의 값이 'train'과 'test'인 행의 집합을 각각 학습/평가 데이터로 정의
단계2) 종속 변수(target)와 독립 변수("target", "Xgrp"를 제외한 모든 변수) 준비
단계3) k-NN 모델과 단계1, 2의 데이터를 사용하여 예측값 산출
단계4) 단계 3의 산출값을 바탕으로 지표 A 산출

$$A = \frac{(\#\text{ of true positive}) + (\#\text{ of true negative})}{(\#\text{ of total data})}$$

※ k-NN 모델의 경우 가장 가까운 이웃 3개를 사용하며 Euclidean 거리를 기반으로 동작하도록 설정하시오.
※ 정답은 반올림하여 소수점 둘째 자리까지 산출하시오.
(정답 예시: 0.12)



문제 답안

필기 객관식



1) 통계 분석

번호	정답
1	③
2	③
3	①
4	②
5	①
6	①
7	③
8	③
9	②
10	②

번호	정답
11	④
12	③
13	①
14	②
15	③
16	②
17	④

2) 데이터 처리

번호	정답
1	②
2	③
3	③
4	②
5	②

3) 머신러닝

번호	정답
1	④
2	③
3	①
4	④
5	④
6	③
7	④
8	③
9	②
10	④

번호	정답
11	①
12	③
13	②
14	④
15	④
16	②
17	③



문제 답안

실기 주관식



Set 01 ~ Set 06

Python: 3.13.12

NumPy: 2.4.3
Pandas: 3.0.1
SciPy: 1.16.1
Scikit Learn: 1.8.0

버전 기준

세트	문제	정답
1	1	493
	2	55
	3	할인율

세트	문제	정답
2	1	3.28
	2	0.0005
	3	0.58

세트	문제	정답
3	1	11.01
	2	2.66
	3	0.65

세트	문제	정답
4	1	0.295
	2	0.03
	3	0.17

세트	문제	정답
5	1	0.97
	2	2156.47
	3	916.85

세트	문제	정답
6	1	1.59
	2	1.67
	3	0.69

Set 01 ~ Set 06

Python: 3.7.4

NumPy: 1.18
Pandas: 0.25.0
SciPy: 1.5.2
Scikit Learn: 0.21

버전 기준

세트	문제	정답
1	1	493
	2	55
	3	할인율

세트	문제	정답
2	1	3.28
	2	0.0005
	3	0.59

세트	문제	정답
3	1	11.01
	2	2.38
	3	0.65

세트	문제	정답
4	1	0.295
	2	0.03
	3	0.18

세트	문제	정답
5	1	0.97
	2	3946.19
	3	916.85

세트	문제	정답
6	1	1.59
	2	1.67
	3	0.69